

NO. 03022643/INF/2025

**MEMPREDIKSI *DEMAND* ENERGI LISTRIK REGIONAL
MENGUNAKAN *MACHINE LEARNING* DAN *DEEP LEARNING*:
STUDI KASUS JAWA-BALI**

SKRIPSI

Diajukan untuk memenuhi persyaratan penyelesaian program Strata 1
Program Studi Informatika Fakultas Teknologi Industri
Universitas Kristen Petra

Oleh:
Michael Adi Pratama
NRP: C14210016

PROGRAM STUDI INFORMATIKA



**FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS KRISTEN PETRA
SURABAYA
2025**

LEMBAR PENGESAHAN

SKRIPSI

**Memprediksi *Demand* Energi Listrik Regional Menggunakan
Machine Learning dan *Deep Learning*: Studi Kasus Jawa-Bali**

Oleh:


Michael Adi Pratama NRP: C14210016

Diterima oleh:

Program Studi Informatika Fakultas Teknologi Industri
Universitas Kristen Petra

Surabaya, 24 Juni 2025

Dosen Pembimbing 1


Dr. Gregorius Satia Budhi, S.T., M.T.
NIP: 02030

Dosen Pembimbing 2


Yusak Tanoto, S.T., M.Eng., Ph.D.
NIP: 04020

Ketua Tim Penguji:


Stephanus A. Ananda, S.T., M.Sc. Ph.D.
NIP: 93026



**LEMBARAN PERNYATAAN PERSETUJUAN PUBLIKASI
KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS**

Sebagai mahasiswa Universitas Kristen Petra, yang bertanda tangan dibawah ini, saya:

Nama : Michael Adi Pratama

NRP : C14210016

Demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Kristen Petra Hak Bebas Royalti Non-Eksklusif (*Non-Exclusive Royalty-Free Right*) atas karya ilmiah saya yang berjudul “Memprediksi *Demand* Energi Listrik Regional Menggunakan *Machine Learning* dan *Deep Learning*: Studi Kasus Jawa-Bali”. Dengan Hak Bebas Royalti Non-Eksklusif ini Universitas Kristen Petra berhak menyimpan, mengalih-mediakan/formatkan, mengelolanya dalam bentuk pangkalan data (*database*), mendistribusikannya dan menampilkan/mempublikasinya di internet atau media lain untuk kepentingan akademik tanpa perlu meminta izin dari saya selama tetap mencantumkan saya sebagai penulisnya.

Saya bersedia untuk menanggung secara pribadi, tanpa melibatkan pihak Universitas Kristen Petra, segala bentuk tuntutan hukum yang timbul atas pelanggaran Hak Cipta dalam karya ilmiah saya ini.

Demikian pernyataan ini yang saya buat dengan sebenarnya.

Surabaya, 24 Juni 2025

Yang menyatakan,



Michael Adi Pratama

KATA PENGANTAR

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karuniaNya, sehingga peneliti dapat menyelesaikan laporan Tugas Akhir ini. Tugas Akhir ini diajukan untuk memenuhi salah satu persyaratan guna meraih gelar Sarjana Strata-1 di Jurusan *Data Science and Analytics*, Program Studi Informatika, Fakultas Teknologi Industri, Universitas Kristen Petra, Surabaya.

Rasa terima kasih yang tak terhingga penulis sampaikan kepada berbagai pihak yang telah membantu peneliti selama ini, khususnya:

1. Tuhan Yesus Kristus yang selalu menyertai penulis selama proses pengerjaan skripsi ini.
2. Bapak Dr. Gregorius Satia Budhi, S.T., M.T., selaku dosen pembimbing 1 yang telah memberikan waktu, ilmu, dan pengarahan dalam penyusunan tugas akhir ini.
3. Bapak Yusak Tanoto, S.T., M.Eng., Ph.D., selaku dosen pembimbing 2 yang telah memberikan waktu, ilmu, dan pengarahan dalam penyusunan tugas akhir ini.
4. Papa, Mama, Almarhum Nenek saya dan Christian Adi Pratama serta seluruh anggota keluarga penulis atas semua dukungan dan doa yang diberikan kepada penulis.
5. Segenap dosen dan staf pengajar di Jurusan Teknik Informatika Universitas Kristen Petra Surabaya.
6. Teman-teman yang sudah membantu memberikan semangat dan keterbukaan ide untuk penulis.

Peneliti menyadari bahwa penulisan skripsi ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan segala petunjuk, kritik, dan saran yang membangun dari pembaca agar dapat menunjang pengembangan dan perbaikan penulisan selanjutnya.

Akhir kata penulis mohon maaf apabila ada kekurangan dalam penulisan tugas akhir ini dan penulis dengan senang hati menerima saran dan kritik yang membangun dari pembaca. Semoga penyajian Tugas Akhir ini bisa memberikan manfaat kepada berbagai pihak. Amin.

Surabaya, 24 Juni 2025



Michael Adi Pratama

ABSTRAK

Michael Adi Pratama

Skripsi

Memprediksi *Demand* Energi Listrik Regional Menggunakan *Machine Learning* dan *Deep Learning*: Studi Kasus Jawa-Bali

Permintaan energi listrik di Indonesia mengalami peningkatan setiap tahunnya. Pulau Jawa dan Bali merupakan wilayah yang memiliki permintaan energi listrik terbesar di Indonesia. Terdapat beberapa faktor yang mempengaruhi permintaan energi listrik di Pulau Jawa dan Bali diantaranya jumlah penduduk, jumlah pelanggan listrik dan beberapa faktor lainnya. Sehingga, dalam memprediksi permintaan energi listrik di Pulau Jawa dan Bali memiliki kendala dan tantangan karena permintaan energi listrik dipengaruhi oleh beberapa faktor.

Penelitian ini bertujuan untuk membuat sebuah dashboard interaktif berbasis website yang dapat memberikan gambaran dan informasi mengenai permintaan energi listrik dan persebaran permintaan energi listrik yang ada pada Pulau Jawa dan Bali. Prediksi permintaan energi listrik pada Pulau Jawa dan Bali meliputi Jakarta-Banten, Jawa Barat, Jawa Tengah-DI Yogyakarta, Jawa Timur, dan Bali. Fitur utama dalam dashboard mencakup visualisasi data, pengujian metrik kesalahan (rmse, mae, dan r^2), dan prediksi permintaan energi listrik dengan menggunakan beberapa model machine learning dan deep learning. Model yang digunakan dalam memprediksi permintaan energi listrik meliputi 3 model machine learning dan 2 model deep learning.

Berdasarkan pengujian yang telah dilakukan menunjukkan bahwa lstm merupakan model terbaik dalam memprediksi permintaan energi listrik regional pada Pulau Jawa dan Bali. Model lstm memiliki nilai rmse 90.18, mae 76.29, dan r^2 0.51 pada pengujian untuk Provinsi Bali. Terdapat beberapa parameter yang berpengaruh dalam memprediksi permintaan energi listrik regional pada Pulau Jawa dan Bali. Parameter yang berpengaruh tersebut meliputi jumlah penduduk, pdrb, listrik terjual, daya terpasang, dan jumlah pelanggan listrik.

Kata kunci: permintaan energi listrik, machine learning, deep learning, metrik kesalahan, lstm

ABSTRACT

Michael Adi Pratama

Undergraduate Thesis

Predicting Regional Electricity Demand Using Machine Learning and Deep Learning: A Case Study of Java-Bali

Electricity demand in Indonesia has increased annually. Java and Bali are the regions with the highest electricity demand in Indonesia. Several factors influence electricity demand in these regions, including total population, number of electricity customers and other contributing variables. Consequently, predicting electricity demand in Java and Bali presents challenges, as it is affected by multiple dynamic factors.

This study aims to develop an interactive web-based dashboard that provides insights and information on electricity demand and its distribution across Java and Bali. The electricity demand predictions focus on several provinces such as Jakarta-Banten, West Java, Central Java-DI Yogyakarta, East Java, and Bali. The main features of the dashboard include data visualization, error metric evaluations (RMSE, MAE, and R^2), and electricity demand forecasting using various machine learning and deep learning models. A total of 3 machine learning models and 2 deep learning models were utilized for this purpose.

The evaluation results indicate that lstm is the best-performing model for predicting regional electricity demand in Java and Bali. For the Bali province, the lstm model achieved an RMSE of 90.18, an MAE of 76.29, and an R^2 of 0.51. Several parameters significantly influence regional electricity demand in Java and Bali, such as total population, pdrb, electricity sold, installed capacity, and number of electricity customers.

Keywords: electricity demand, machine learning, deep learning, error metric, lstm

DAFTAR ISI

HALAMAN JUDUL	i
LEMBARAN PENGESAHAN.....	ii
LEMBARAN PERNYATAAN PERSETUJUAN PUBLIKASI	iii
KATA PENGANTAR.....	iv
ABSTRAK	v
ABSTRACT	vi
DAFTAR ISI	vii
DAFTAR TABEL.....	ix
DAFTAR GAMBAR	x
DAFTAR LAMPIRAN	xii
1. PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah.....	3
1.3. Tujuan Penelitian	4
1.4. Ruang Lingkup.....	4
1.5. Sistematika Penulisan	6
2. METODOLOGI PENELITIAN	8
3. ANALISIS DAN DESAIN SISTEM	9
3.1 Analisa Permasalahan.....	9
3.2 Analisa Kebutuhan	10
3.3 Analisa Dataset	10
3.4 Desain Sistem.....	17
3.4.1. Business and Data Understanding	18
3.4.2. Data Preprocessing	19
3.4.2.2 Data Cleaning.....	20
3.4.2.3 Data Formatting.....	21
3.4.2.3.1 Interpolasi Data.....	22
3.4.3. Data Merging.....	23
3.4.4. Training and Evaluation Model	23
3.4.4.1 Hyperparameter Tuning	24
3.4.4.2 Evaluation Model.....	25
3.4.5. Selection Model	26
3.4.6. Prediction and Visualization.....	26
3.5 Analisa Model	27
3.5.1 Random Forest	27
3.5.2 Extreme Gradient Boosting (XGBoost).....	28
3.5.3 Support Vector Regression (SVR)	28

3.5.4 LSTM Deep Learning.....	29
3.5.5 Transformer Deep Learning	30
3.5.6 Grid Search	31
4. PENGUJIAN SISTEM	32
4.1 Pengujian Hyperparameter Tuning (Modelling)	32
4.1.1 Model Random Forest.....	32
4.1.2 Model Extreme Gradient Boosting (XGBoost)	33
4.1.3 Model Support Vector Regression (SVR).....	34
4.1.4 Model LSTM	35
4.1.5 Model Transformer	36
4.2 Pengujian Model	37
4.3 Pengujian Aplikasi Dashboard berbasis Website.....	53
5. ANALISA DAN EVALUASI HASIL.....	60
6. KESIMPULAN DAN SARAN	74
6.1 Kesimpulan	74
6.2 Saran	74
DAFTAR REFERENSI	76
LAMPIRAN	80

DAFTAR TABEL

Tabel 3.1 Atribut Dataset Demand Energi Listrik.....	11
Tabel 3.2 Atribut Dataset Jumlah Penduduk.....	12
Tabel 3.3 Atribut Dataset Jumlah Penduduk Miskin	13
Tabel 3.4 Atribut Dataset PDRB	14
Tabel 3.5 Atribut Dataset Jumlah Pelanggan Listrik.....	15
Tabel 3.6 Atribut Dataset Jumlah Listrik Terjual	15
Tabel 3.7 Atribut Dataset Daya Terpasang, Listrik Terjual, dan Produksi Listrik	16
Tabel 4.1 Parameter model Random Forest	32
Tabel 4.2 10 Parameter Terbaik Random Forest pada Provinsi Bali	33
Tabel 4.3 Parameter model XGBoost	33
Tabel 4.4 10 Parameter Terbaik XGBoost pada Provinsi Bali.....	34
Tabel 4.5 Parameter model SVR.....	34
Tabel 4.6 10 Parameter Terbaik SVR pada Provinsi Bali	35
Tabel 4.7 Parameter model LSTM	35
Tabel 4.8 10 Parameter Terbaik LSTM pada Provinsi Bali	35
Tabel 4.9 Parameter model Transformer.....	36
Tabel 4.10 10 Parameter Terbaik Transformer pada Provinsi Bali	36
Tabel 4.11 Hasil Pengujian Model All Parameter pada Jakarta-Banten.....	37
Tabel 4.12 Hasil Pengujian Model Top 5 Important Parameter pada Jakarta-Banten	39
Tabel 4.13 Hasil Pengujian Model All Parameter pada Jawa Barat	41
Tabel 4.14 Hasil Pengujian Model Top 5 Important Parameter pada Jawa Barat	42
Tabel 4.15 Hasil Pengujian Model All Parameter pada Jawa Tengah-DIY.....	44
Tabel 4.16 Hasil Pengujian Model Top 5 Parameter pada Jawa Tengah-DIY	45
Tabel 4.17 Hasil Pengujian Model All Parameter pada Jawa Timur.....	47
Tabel 4.18 Hasil Pengujian Model Top 5 Parameter pada Jawa Timur	48
Tabel 4.19 Hasil Pengujian Model All Parameter pada Bali	50
Tabel 4.20 Hasil Pengujian Model Top 5 Parameter pada Bali	51

DAFTAR GAMBAR

Gambar 3.1 Dataset yang telah di merge	10
Gambar 3.2 Raw dataset electricity demand di Bali tahun 2021.....	11
Gambar 3.3 Raw Dataset jumlah penduduk	12
Gambar 3.4 Raw Dataset Jumlah Penduduk Miskin	13
Gambar 3.5 Raw dataset PDRB	14
Gambar 3.6 Raw dataset jumlah pelanggan listrik	14
Gambar 3.7 Raw dataset jumlah listrik terjual.....	15
Gambar 3.8 Raw dataset daya terpasang, listrik terjual, dan produksi listrik	16
Gambar 3.9 Alur Desain Sistem.....	17
Gambar 3.10 Tahapan Data preprocessing.....	20
Gambar 3.12 Tahapan data cleaning	20
Gambar 3.13 Tahapan pada data formatting.....	21
Gambar 3.14 Tahapan Interpolasi Data	22
Gambar 3.15 Tahapan pada Data merging	23
Gambar 3.16 Tahapan training and evaluation model	24
Gambar 3.17 Tahapan hyperparameter tuning	24
Gambar 3.18 Tahapan Evaluation model.....	25
Gambar 3.19 Tahapan Selection Model.....	26
Gambar 3.20 Tahapan Prediction and Visualization	26
Gambar 3.21 Cara Kerja Random Forest.....	27
Gambar 3.22 Arsitektur LSTM.....	29
Gambar 3.23 Arsitektur Transformer.....	30
Gambar 4.1 Actual vs Modelled Line Chart using LSTM All Parameter	37
Gambar 4.2 Feature Important All Parameter pada Jakarta-Banten.....	38
Gambar 4.3 Actual vs Modelled Line Chart using LSTM Top 5 Parameter	39
Gambar 4.4 Feature Important Top 5 Parameter pada Jakarta-Banten.....	40
Gambar 4.5 Actual vs Modelled Line Chart using SVR All Parameter	41
Gambar 4.6 Feature Important All Parameter pada Jawa Barat.....	41
Gambar 4.7 Actual vs Modelled Line Chart using SVR Top 5 Parameter	42
Gambar 4.8 Feature Important Top 5 Parameter pada Jawa Barat.....	43
Gambar 4.9 Actual vs Modelled Line Chart using Transformer All Parameter	44
Gambar 4.10 Feature Important All Parameter pada Jawa Tengah-DIY.....	44
Gambar 4.11 Actual vs Modelled Line Chart using Transformer Top 5 Parameter	45
Gambar 4.12 Feature Important Top 5 Parameter pada Jawa Tengah-DIY.....	46
Gambar 4.13 Actual vs Modelled Line Chart using Random Forest All Parameter.....	47
Gambar 4.14 Feature Important All Parameter pada Jawa Timur.....	47

Gambar 4.15 Actual vs Modelled Line Chart using LSTM Top 5 Parameter	48
Gambar 4.16 Feature Important Top 5 Parameter pada Jawa Timur.....	49
Gambar 4.17 Actual vs Modelled Line Chart using LSTM All Parameter	50
Gambar 4.18 Feature Important All Parameter pada Bali	50
Gambar 4.19 Actual vs Modelled Line Chart using Random Forest Top 5 Parameter.....	51
Gambar 4.20 Feature Important Top 5 Parameter Random Forest pada Bali.....	52
Gambar 4.21 Halaman Explanatory Dataset 1	53
Gambar 4.22 Halaman Explanatory Dataset 2	53
Gambar 4.23 Halaman Explanatory Dataset 3	54
Gambar 4.24 Halaman Modelling Pages 1	55
Gambar 4.25 Halaman Modelling Pages 2	56
Gambar 4.26 Halaman Prediction Pages 1.....	56
Gambar 4.27 Halaman Prediction Pages 2.....	57
Gambar 4.28 Halaman Prediction Pages 3.....	58
Gambar 4.29 Halaman Credits Pages 1	58
Gambar 4.30 Halaman Credits Pages 2	59
Gambar 5.1 Line chart daily electricity demand in Bali.....	60
Gambar 5.2 Bar Chart Number of Electricity Customer in Bali	61
Gambar 5.3 Line chart daily electricity demand in Bali.....	62
Gambar 5.4 Bar Chart Electricity Sold in Bali	62
Gambar 5.5 Line chart Electricity Demand All Parameter in Bali.....	63
Gambar 5.6 Line chart Electricity Demand Top 5 important Parameter in Bali	64
Gambar 5.7 Line chart daily electricity demand in Jakarta-Banten	65
Gambar 5.8 Bar Chart Total Poor Population in Jakarta-Banten	66
Gambar 5.9 Line chart daily electricity demand in Jakarta-Banten	66
Gambar 5.10 Bar Chart Number of Electricity Customer in Jakarta-Banten.....	67
Gambar 5.11 Line chart Electricity Demand All Parameter in Jakarta-Banten	68
Gambar 5.12 Line chart Electricity Demand Top 5 Important Parameter in Jakarta-Banten.....	69
Gambar 5.13 Line chart electricity demand in Jawa Barat	70
Gambar 5.14 Bar chart Electricity Sold in Jawa Barat	71
Gambar 5.15 Line chart weekly electricity demand in Jawa Barat	71
Gambar 5.16 Bar chart Number of Electricity Customer in Jawa Barat.....	73
Gambar 5.17 Line chart Electricity Demand All Parameter in Jawa Barat	73

DAFTAR LAMPIRAN

Lampiran 1 Tabel Hyperparameter Tuning Model Random Forest	80
Lampiran 2 Tabel Hyperparameter Tuning Model XGBoost	82
Lampiran 3 Tabel Hyperparameter Tuning Model Support Vector Regression.....	83
Lampiran 4 Tabel Hyperparameter Tuning Model LSTM	85
Lampiran 5 Tabel Hyperparameter Tuning Model Transformer.....	86
Lampiran 6 Analisa dan Evaluasi Hasil	88

1. PENDAHULUAN

1.1. Latar Belakang

Menurut Kuncoro (2005), energi listrik merupakan kebutuhan dasar yang sangat penting dan sangat berguna bagi setiap manusia karena energi listrik tidak mudah untuk disimpan dan memiliki banyak kegunaan dalam berbagai aspek kehidupan manusia (dalam Rifais, 2019, p. 1). Di Indonesia, masyarakat sangat membutuhkan energi listrik dalam menjalankan aktivitas sehari-hari. Hal ini dikarenakan, beberapa aktivitas manusia memerlukan konektivitas dari energi listrik dalam penggunaannya seperti, memasak nasi, menyalakan lampu, AC, dan kulkas. Konsumsi energi listrik di Indonesia mengalami peningkatan setiap tahunnya.

Konsumsi energi listrik sangat dipengaruhi oleh pertumbuhan ekonomi nasional dan pertumbuhan jumlah penduduk dalam suatu negara (Ardilla, Y., 2016). Hal ini disebabkan karena semakin meningkatnya ekonomi nasional dalam suatu negara, maka konsumsi energi listrik masyarakat akan semakin bertambah untuk menjalankan dan memenuhi aktivitas sehari-harinya. *Trend* penjualan dan jumlah pelanggan pengguna tenaga listrik nasional di Indonesia mengalami peningkatan setiap tahunnya. Berdasarkan data yang diperoleh dari Kementerian ESDM mencatat bahwa penjualan listrik nasional mencapai 285,23 TWh pada tahun 2023 dan penjualan listrik nasional mencapai 270,82 TWh pada tahun 2022 (Kementerian ESDM, 2024 February 20). Penjualan listrik nasional pada tahun 2023 mengalami peningkatan sebanyak 14,41 TWh atau 5,32% dibandingkan dengan tahun 2022 (Kementerian ESDM, 2024 February 20).

Pulau Jawa dan Bali merupakan dua wilayah terpenting yang memiliki *demand* energi listrik terbesar yang ada di Indonesia. Hal ini dapat dilihat berdasarkan data *statistic* dari PT. PLN, dimana Pulau Jawa dan Bali mencakup sekitar 71% dari keseluruhan kebutuhan energi listrik yang ada di Indonesia (Perusahaan Listrik Negara, 2024). PT. PLN (Persero) adalah perusahaan milik negara yang hadir menyediakan beberapa layanan diantaranya yaitu penyedia rantai nilai energi mulai dari pembangkit listrik dan pembangunan pembangkit listrik hingga transmisi, distribusi, dan penjualan eceran Listrik (Global Data, 2023). PLN mendistribusikan layanan energi listrik ke berbagai jenis pelanggan di seluruh wilayah di Indonesia. Pelanggan pengguna listrik nasional terdiri dari berbagai bidang usaha seperti,

rumah tangga, industri, bisnis, sosial, gedung kantor pemerintah, dan penerangan jalan umum.

Namun dalam memenuhi kebutuhan *demand* energi listrik pada Pulau Jawa dan Bali masih memiliki kendala dan tantangan dalam memprediksi *demand* energi listrik yang dibutuhkan oleh masyarakat. Menurut Diyono et al. (2023), *demand* energi listrik yang ada pada di Pulau Jawa dan Bali dipengaruhi oleh beberapa parameter/faktor kunci diantaranya yaitu jumlah penduduk, jumlah rumah tangga, Produk Domestik Regional Bruto (PDRB) atau pendapatan per kapita regional, dan jumlah pelanggan listrik.

Sehingga, memprediksi *demand* energi listrik regional pada Pulau Jawa dan Bali tidak mudah dilakukan, karena dipengaruhi oleh berbagai faktor. Tujuan dalam memprediksi *demand* energi listrik nasional pada Pulau Jawa dan Bali dapat dibagi menjadi 2 hal; tujuan jangka pendek untuk kebutuhan operasional PLN Unit Jawa dan Bali, dan tujuan jangka panjang untuk perencanaan konsumsi energi listrik masyarakat di Pulau Jawa dan Bali. Prediksi kebutuhan *demand* energi listrik dalam jangka pendek dapat membantu PLN dalam menyediakan dan mendistribusikan kebutuhan energi listrik bagi masyarakat di Pulau Jawa dan Bali. Sedangkan prediksi kebutuhan *demand* energi Listrik dalam jangka panjang dapat membantu pemerintah dalam menetapkan tujuan dan keputusan investasi yang tepat di masa mendatang, khususnya dalam bidang energi listrik.

Penelitian sebelumnya yang dilakukan oleh Sahin et al. (2024) menggunakan 3 metode *Machine Learning* yaitu *Multivariate Polynomial Regression (MPR)*, *Random Forest Regression (RFR)*, dan *Gradient Boosting Regression (GBR)*. Peneliti membandingkan 3 metode *Machine Learning* untuk memprediksi *demand* energi listrik setiap jam pada negara bagian Connecticut di Amerika Serikat dalam rentang waktu tahun 2011 hingga tahun 2021. Pada penelitian ini, menggunakan beberapa features diantaranya waktu (temporal), *demand*, dan kecepatan angin. Dalam penelitian ini diperoleh model *Machine Learning* terbaik dalam memprediksi *demand* energi listrik setiap jam pada negara bagian di Amerika Serikat. Model *Machine Learning* tersebut adalah *Gradient Boosting Regression (GBR)*.

Penelitian yang dilakukan oleh Banik et al. (2020) memprediksi kebutuhan rata-rata konsumsi listrik di Kota Agartala, India dimana *forecasting demand electricity energy* dilakukan dalam jangka waktu short-term maupun long-term. Dalam melakukan *forecasting demand electricity energy* menggunakan metode *Machine Learning*, dimana terdapat 7 model *Machine Learning* yang digunakan. Model tersebut diantaranya adalah *Support Vector Regression (SVR)*, *Neural Network*, *Random Forest*, *Tuned Random Forest*, *AdaBoost*

Regressor, *XGBoost*, dan *proposed method (Random Forest - XGBoost Ensemble)*. Dalam penelitian ini diperoleh model *Machine Learning* terbaik dalam memprediksi kebutuhan rata-rata konsumsi energi listrik di Kota Agartala, India. Model *Machine Learning* terbaik adalah *Random Forest - XGBoost Ensemble*, karena memiliki nilai akurasi prediksi yang terbaik dan nilai *RMSE (Root Mean Square Error)* terendah dibandingkan dengan 6 model lainnya.

Berdasarkan permasalahan yang ada diatas, maka diperlukan sebuah perencanaan dalam bentuk prediksi *demand* energi listrik yang dapat membantu pihak terkait dalam menyediakan pasokan energi listrik bagi masyarakat khususnya di Pulau Jawa dan Bali. Sejauh ini, penelitian terkait prediksi *demand* energi listrik regional pada Pulau Jawa dan Bali masih jarang dijumpai di Indonesia. Didukung oleh penelitian-penelitian sebelumnya, pada skripsi ini dilakukan prediksi *demand* energi listrik regional pada Pulau Jawa dan Bali dengan menggunakan metode *Machine Learning* dan *Deep Learning*. Model *Machine Learning* dan *Deep Learning* yang digunakan untuk memprediksi *demand* energi listrik regional adalah *Random Forest*, *Extreme Gradient Boosting (XGBoost)*, *Support Vector Regression (SVR)*, *LSTM*, dan *Transformers*. Model *Machine Learning* dan *Deep Learning* tersebut dipilih, karena berdasarkan penelitian sebelumnya memiliki nilai persentase error yang rendah. Diharapkan dengan adanya model *Machine Learning* dan *Deep Learning*, maka dapat membantu pihak terkait dalam memprediksi *demand* energi listrik regional pada Pulau Jawa dan Bali di masa yang akan datang, serta membantu pengambilan keputusan.

1.2. Rumusan Masalah

Berdasarkan latar belakang permasalahan, maka rumusan masalah dari skripsi ini adalah sebagai berikut:

- Parameter apa saja yang dapat digunakan dalam membentuk model prediksi *demand* energi listrik regional dan bagaimana pengaruh parameter tersebut terhadap prediksi *demand* energi listrik regional dalam konteks *Machine Learning* atau *Deep Learning*?
- Bagaimana mengukur performa model berdasarkan nilai error nya untuk prediksi *demand* energi listrik regional dengan metode *Random Forest*, *Extreme Gradient Boosting (XGBoost)*, *Support Vector Regression*, *LSTM*, dan *Transformers*?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang ada, tujuan dari skripsi ini adalah memprediksi *demand* energi listrik regional pada Pulau Jawa dan Bali dalam jangka pendek di masa yang akan datang dengan menggunakan metode terbaik dari beberapa metode yang telah dipilih.

Metode-metode yang telah dipilih diantaranya adalah *Random Forest*, *Extreme Gradient Boosting (XGBoost)*, *Support Vector Regression*, *LSTM*, dan *Transformers*.

Dengan adanya data-data terkait dengan demografi penduduk, pdrb dan *demand* energi listrik maka dapat membantu pihak terkait dalam mengetahui kebutuhan pasokan energi listrik serta membantu pengambilan keputusan terhadap *demand* energi listrik regional Pulau Jawa dan Bali di masa depan.

1.4. Ruang Lingkup

Batasan yang ditetapkan pada skripsi ini sebagai berikut:

1. Bahasa Pemrograman yang digunakan adalah *Python*.
2. *Integrated Development Environment* yang digunakan adalah *Visual Studio Code*.
3. *Dataset* yang digunakan adalah Data *Demand* Energi Listrik, Data Demografi dan PDRB, dan Data Jumlah Pelanggan Listrik.
4. *Dataset* yang digunakan pada pengujian akan di *sampling* berdasarkan skala provinsi. Karena analisa terkait prediksi *demand* energi listrik hanya dilakukan terhadap level provinsi. *Sampling* data pada tiap provinsi dilakukan dengan menggunakan data dari beberapa titik lokasi yang ada pada beberapa kota di setiap provinsi.
5. Data *Demand* Energi Listrik Regional diambil dari <https://web.pln.co.id/>.
 - a. Data *demand* energi listrik regional diambil sejak 1 Januari 2021 hingga 31 Desember 2023.
 - b. Atribut pada data meliputi:
 - i. *demand* energi listrik.
 - c. Data *demand* energi listrik yang digunakan dalam penelitian ini merupakan *demand* energi listrik setiap jam dalam setiap hari dan dalam satuan MWh.
6. Data demografi dan PDRB diambil dari *website* BPS pada setiap Provinsi, meliputi: <https://jakarta.bps.go.id/id>, <https://jabar.bps.go.id/id>, <https://banten.bps.go.id/id>, <https://jateng.bps.go.id/id>, <https://yogyakarta.bps.go.id/id>, <https://jatim.bps.go.id/id>, dan <https://bali.bps.go.id/id>. Data demografi dan PDRB meliputi 7 provinsi yang ada di Pulau Jawa dan Bali.
 - a. Data demografi dan PDRB setiap provinsi diambil sejak tahun 2021 hingga 2023.
 - b. Data demografi dan PDRB mencakup, data-data terkait:
 - i. Data PDRB Provinsi
 - ii. Data Jumlah Penduduk tiap Provinsi
 - iii. Data Jumlah Penduduk Miskin tiap Provinsi

- c. Data PDRB Provinsi, Data Jumlah Penduduk tiap Provinsi, dan Data Jumlah Penduduk Miskin tiap Provinsi dalam bentuk data tahunan.
7. Data Jumlah Pelanggan Listrik diambil dari *website* PT. PLN pada <https://web.pln.co.id/>.
- a. Data Jumlah Pelanggan Listrik setiap provinsi diambil sejak tahun 2021 hingga 2023.
 - b. Data Jumlah Pelanggan Listrik mencakup, data-data terkait:
 - i. Data Jumlah Pelanggan Listrik menurut Jenis Pelanggan di tiap Ibukota Provinsi yang ada di tiap Provinsi.
 - ii. Data Jumlah Listrik Terjual menurut Area Pelayanan di tiap Provinsi.
 - iii. Data Daya Terpasang, Produksi, dan Listrik Terjual menurut Jenis Pelanggan dan Area Pelayanan di tiap Provinsi.
 - c. Data Jumlah Pelanggan Listrik menurut Jenis Pelanggan di tiap Ibukota Provinsi yang ada di tiap Provinsi, Data Jumlah Listrik Terjual menurut Area Pelayanan di tiap Provinsi, Data Daya Terpasang, Produksi, dan Listrik Terjual menurut Jenis Pelanggan dan Area Pelayanan di tiap Provinsi dalam bentuk data tahunan.
8. Karena *Dataset Demand* energi listrik dalam bentuk satuan setiap jam dalam setiap hari, maka *dataset* tersebut dilakukan interpolasi dalam satuan setiap jam. Metode yang digunakan untuk interpolasi adalah regresi.
9. Karena *Dataset* Demografi-PDRB dan *Dataset* Jumlah Pelanggan Listrik dalam bentuk satuan tahunan, maka 2 *dataset* tersebut dilakukan interpolasi dalam bentuk satuan bulan. Metode yang digunakan untuk interpolasi adalah regresi.
- a. Training dan Pemilihan Model:**
- 1. Melakukan *data preprocessing* pada data *demand* energi listrik.
 - 2. *Library* yang digunakan adalah *Scikit-Learn*, *xgboost*, dan *tensorflow*.
 - 3. Model *Machine Learning* yang digunakan adalah *Random Forest*, *Extreme Gradient Boosting*, dan *Support Vector Regression*.
 - 4. Model *Deep Learning* yang digunakan adalah LSTM dan *Transformers*.
 - 5. Setiap model akan dilakukan *tuning parameter* menggunakan *Grid Search (machine learning)* atau *Optuna (deep learning)*.
 - 6. Semua model akan di *training* dengan *dataset* yang sama. 80% data dari *dataset* akan digunakan untuk *training*. Sedangkan 20% data dari *dataset* akan digunakan untuk *testing*.
 - 7. Hasil prediksi dari setiap model akan diuji performanya dengan:

- a. Mengukur tingkat *error* yang dihasilkan menggunakan perhitungan *rmse* dan *mae*.
 - b. Mengukur seberapa baik suatu model regresi dapat menjelaskan variasi dalam variable dependen (yang di prediksi) menggunakan perhitungan R^2 (*coefficient of determination*).
8. Model terbaik dari hasil pengujian akan dipilih sebagai model dalam aplikasi.

b. Aplikasi:

1. Aplikasi ini akan dibuat berbasis *website*.
2. *Library* yang digunakan adalah *Dash*, *Scikit-learn*, *xgboost*, *tensorflow*.
3. Input yang digunakan adalah nama provinsi, tahun, dan nama model.
4. Model yang digunakan adalah model terbaik dari hasil *training* dan pemilihan model.
5. *Output* berupa data hasil prediksi yang dipresentasikan dalam bentuk grafik.
6. Implementasi sistem dibangun dengan basis *web application* dengan menggunakan *Dash*.

1.5. Sistematika Penulisan

Adapun sistematika penulisan yang digunakan untuk menyusun skripsi ini adalah sebagai berikut:

BAB 1: PENDAHULUAN

Bab ini membahas terkait latar belakang masalah, perumusan masalah, tujuan penelitian, dan ruang lingkup.

BAB 2: METODOLOGI PENELITIAN

Bab ini membahas terkait metodologi penelitian.

BAB 3: ANALISA DAN DESAIN SISTEM

Bab ini menjelaskan terkait dengan analisa permasalahan yang dihadapi dan perencanaan pembuatan keseluruhan sistem yang akan dibuat.

BAB 4: PENGUJIAN SISTEM

Bab ini membahas tentang pengujian sistem dan pengujian model pada aplikasi berbasis *website* yang telah dibuat.

BAB 5: ANALISA DAN EVALUASI HASIL

Bab ini membahas tentang analisa dan evaluasi hasil berdasarkan pengujian sistem pada pada Bab 4.

BAB 6: KESIMPULAN DAN SARAN

Bab ini berisi kesimpulan yang dapat diambil terhadap hasil yang telah dicapai, dan saran-saran untuk pengembangan selanjutnya.

2. METODOLOGI PENELITIAN

1. Studi Literatur

- 1.1. Teori *Demand* Energi Listrik.
- 1.2. Teori bahasa pemrograman *Python*.
- 1.3. Teori metode *Machine Learning: Random Forest, XGBoost, dan Support Vector Regression*.
- 1.4. Teori metode *Deep Learning: LSTM dan Transformers*.
- 1.5. Teori Library *Dash, Scikit-Learn, tensorflow dan xgboost*.

2. Analisis Kebutuhan dan Pengumpulan Data

- 2.1. Melakukan analisis kebutuhan sistem dengan berdiskusi dengan pihak PT. PLN.
- 2.2. Mengumpulkan *Dataset demand* energi listrik regional Pulau Jawa dan Bali yang diperoleh dari *website* PLN.
- 2.3. Melengkapi data-data pendukung seperti, jumlah penduduk, PDRB provinsi, jumlah pelanggan listrik, data jumlah listrik terjual menurut area pelayanan, dan data daya terpasang, produksi, dan listrik terjual menurut jenis pelanggan dan area pelayanan.

3. Perancangan dan Implementasi Program

- 3.1. Melakukan *data preprocessing*.
- 3.2. Implementasi model *Machine Learning* atau *Deep Learning* terbaik untuk memprediksi *demand* energi listrik regional pada Pulau Jawa dan Bali.

4. Pengujian dan Evaluasi Program

- 4.1. Melakukan pengujian fungsionalitas dan kinerja sistem secara menyeluruh.
- 4.2. Mengidentifikasi dan memperbaiki *bug* yang ditemukan pada program.
- 4.3. Melakukan pengujian untuk mengetahui dan menganalisa apakah program sudah menjawab rumusan masalah.

5. Pengambilan Kesimpulan

- 5.1. Pembuatan kesimpulan terkait hasil penelitian dari analisis yang telah dilakukan.
- 5.2. Memberikan saran untuk penelitian yang akan datang.

6. Pembuatan Laporan

3. ANALISIS DAN DESAIN SISTEM

3.1 Analisa Permasalahan

Energi listrik telah menjadi salah satu kebutuhan primer masyarakat yang ada di Indonesia, yang sulit untuk digantikan. Energi listrik juga memiliki keterbatasan, dikarenakan jumlah nya sangat bergantung pada jumlah produksi listrik yang dihasilkan oleh pihak terkait dalam hal ini PT. PLN. Demand energi listrik khususnya di Pulau Jawa dan Bali mengalami peningkatan setiap tahunnya. Demand energi listrik dipengaruhi oleh pertumbuhan ekonomi nasional dan pertumbuhan jumlah penduduk dalam suatu negara. Hal ini disebabkan karena semakin meningkatnya ekonomi nasional dalam suatu negara, maka konsumsi energi listrik masyarakat akan semakin bertambah untuk menjalankan dan memenuhi aktivitas sehari-harinya. Selain itu, beberapa aktivitas masyarakat banyak yang memerlukan konektivitas energi listrik, misalnya penggunaan AC, operasional pabrik maupun kantor, dan pemakaian kendaraan listrik. Dalam kehidupan sehari-hari, masyarakat selalu bergantung pada pemanfaatan energi listrik.

Demand energi listrik di setiap Provinsi yang ada di Pulau Jawa dan Bali berbeda beda nilainya, dan hal ini disebabkan oleh beberapa faktor diantaranya Jumlah Penduduk dan Jumlah Pelanggan Listrik. Sehingga kebutuhan energi listrik yang ada di tiap provinsi di Pulau Jawa dan Bali sulit untuk diprediksi atau diperkirakan di masa depan. Oleh karena itu prediksi demand energi listrik di Pulau Jawa dan Bali pada masa depan sangat dibutuhkan. Agar kebutuhan demand energi listrik di Pulau Jawa dan Bali dapat terpenuhi, dan tidak ada provinsi yang mengalami kekurangan energi listrik. Selain itu, penggunaan energi listrik perlu untuk digunakan sebijak dan seefisien mungkin. Agar tidak ada masyarakat di daerah yang mengalami kendala atau keterbatasan dalam mengakses atau memanfaatkan energi listrik di Pulau Jawa dan Bali khususnya.

3.2 Analisa Kebutuhan

Berdasarkan permasalahan dalam memenuhi kebutuhan demand energi listrik pada Pulau Jawa dan Bali, maka dibutuhkan sebuah sistem prediksi demand energi listrik yang mampu memberikan gambaran yang lebih jelas tentang demand energi listrik yang dibutuhkan pada setiap provinsi yang ada di Pulau Jawa dan Bali. Sehingga kebutuhan

demand energi listrik yang ada pada setiap provinsi di Pulau Jawa dan Bali di masa depan dapat diprediksi atau diperkirakan. Dengan adanya sistem ini, diharapkan dapat membantu pengambilan keputusan dan menentukan kebijakan dalam memenuhi kebutuhan demand energi listrik yang ada di Pulau Jawa dan Bali. Selain itu, dengan adanya sistem ini maka dapat membantu pihak terkait dalam melakukan penyediaan pasokan energi listrik di masa depan pada tiap provinsi yang ada di Pulau Jawa dan Bali, sehingga mencegah terjadinya *over supply* energi listrik di Pulau Jawa dan Bali.

3.3 Analisa Dataset

	Date	Time	Demand	Monthly_Rate	Month	Year	Province	Total_Population	Total_Poor_Population	PDRB	Number_OF_Electricity_Customer	Electricity_Sold	Installed_Capacity	Electricity_Production	Percentage_Poor_Population
1	Sunday, January 1, 2023	12:00:00 AM	672	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
2	Sunday, January 1, 2023	1:00:00 AM	677	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
3	Sunday, January 1, 2023	2:00:00 AM	682	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
4	Sunday, January 1, 2023	3:00:00 AM	686	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
5	Sunday, January 1, 2023	4:00:00 AM	691	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
6	Sunday, January 1, 2023	5:00:00 AM	696	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
7	Sunday, January 1, 2023	6:00:00 AM	701	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
8	Sunday, January 1, 2023	7:00:00 AM	706	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
9	Sunday, January 1, 2023	8:00:00 AM	711	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
10	Sunday, January 1, 2023	9:00:00 AM	716	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
11	Sunday, January 1, 2023	10:00:00 AM	721	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
12	Sunday, January 1, 2023	11:00:00 AM	726	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
13	Sunday, January 1, 2023	12:00:00 PM	731	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
14	Sunday, January 1, 2023	1:00:00 PM	736	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
15	Sunday, January 1, 2023	2:00:00 PM	741	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
16	Sunday, January 1, 2023	3:00:00 PM	746	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
17	Sunday, January 1, 2023	4:00:00 PM	751	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
18	Sunday, January 1, 2023	5:00:00 PM	756	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
19	Sunday, January 1, 2023	6:00:00 PM	761	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
20	Sunday, January 1, 2023	7:00:00 PM	766	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
21	Sunday, January 1, 2023	8:00:00 PM	771	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
22	Sunday, January 1, 2023	9:00:00 PM	776	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
23	Sunday, January 1, 2023	10:00:00 PM	781	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
24	Sunday, January 1, 2023	11:00:00 PM	786	January	1	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
25	Monday, January 2, 2023	12:00:00 AM	791	January	2	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
26	Monday, January 2, 2023	1:00:00 AM	796	January	2	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
27	Monday, January 2, 2023	2:00:00 AM	801	January	2	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
28	Monday, January 2, 2023	3:00:00 AM	806	January	2	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
29	Monday, January 2, 2023	4:00:00 AM	811	January	2	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276
30	Monday, January 2, 2023	5:00:00 AM	816	January	2	2023	Bali	4886200	205360	50892000	16305120	1470011	4213	5059849	0.0406276

Gambar 3.1 Dataset yang telah di merge

Dataset yang digunakan dalam skripsi ini meliputi *Dataset Demand* Energi Listrik, *Dataset* Demografi dan PDRB, dan *Dataset* Jumlah Pelanggan Listrik. *Dataset* yang digunakan diambil sejak tahun 2021 hingga tahun 2023. Gambar 3.1 merupakan contoh *dataset* yang telah dilakukan *preprocessing*, *merging* dan akan digunakan dalam skripsi ini. *Dataset* tersebut merupakan contoh data pada provinsi Bali pada tahun 2021 hingga tahun 2023. Dalam dataset tersebut terdiri dari beberapa parameter diantaranya *Date*, *Time*, *Province*, *Demand*, Jumlah Penduduk, Jumlah Penduduk Miskin, PDRB, Jumlah Pelanggan Listrik, Listrik Terjual, Daya Terpasang, Produksi Listrik.

Parameter *Date*, *Time*, *Province*, dan *Demand* berasal dari *dataset demand* energi listrik yaitu data beban UP2B Jawa-Bali dari tahun 2021-2023, yang diperoleh dari pihak PT. PLN. Sedangkan data parameter Jumlah Penduduk, Jumlah Penduduk Miskin, dan PDRB diperoleh dari *website* BPS (Badan Pusat Statistik) setiap provinsi. Data parameter Jumlah Pelanggan Listrik, Listrik Terjual, Daya Terpasang, dan Produksi Listrik diperoleh dari pihak

PT. PLN setiap provinsi. Gambar 3.2 merupakan salah satu contoh *raw data* yang akan digunakan sebagai *dataset* dalam skripsi ini.

Tanggal	0:00	0:30	1:00	1:30	2:00	2:30	3:00	3:30	4:00	4:30	5:00	5:30	6:00	6:30	7:00	7:30	8:00	8:30	9:00	9:30	10:00	10:30	11:00	11:30	12:00	12:30	13:00	13:30	14:00	14:30	15:00	15:30	16:00	16:30	17:00
1/1/2021	551	578	567	552	535	524	520	516	508	507	505	509	505	501	504	518	537	549	574	587	598	612	617	626	624	623	620	623	617	615	605	601	594	591	589
1/2/2021	539	534	522	517	508	502	494	489	487	484	490	495	496	500	506	514	530	555	581	605	616	628	640	643	640	633	633	635	631	627	625	620	615	611	608
1/3/2021	528	524	513	507	497	487	484	476	472	473	474	481	484	488	490	499	517	538	552	565	569	580	587	587	578	572	579	578	583	584	590	592	591	591	587
1/4/2021	513	515	503	491	486	480	470	463	456	456	460	467	471	485	496	508	530	559	577	591	606	613	617	618	613	610	619	633	634	641	639	635	632	619	607
1/5/2021	499	504	490	480	471	465	461	457	454	455	457	472	481	487	495	510	532	566	587	606	614	615	616	609	602	601	603	611	608	608	603	597	593	587	582
1/6/2021	527	481	471	464	459	452	447	445	442	446	451	465	472	479	488	503	526	556	582	599	616	629	637	638	636	634	638	649	656	652	647	643	628	617	603
1/7/2021	502	510	499	490	483	476	465	457	455	456	458	467	473	481	492	505	530	572	593	601	603	594	596	592	583	581	588	603	604	604	604	602	594	586	576
1/8/2021	481	488	486	468	461	455	448	442	443	442	446	444	463	474	481	490	507	532	551	567	577	576	577	575	572	565	564	572	574	569	571	570	568	564	555
1/9/2021	502	462	455	448	441	438	435	429	430	432	438	448	455	459	460	473	488	516	541	557	570	581	587	589	587	588	589	598	600	593	589	585	579	575	568
1/10/2021	504	493	484	475	469	462	457	452	450	451	452	458	463	463	465	476	494	515	534	550	562	566	573	578	574	574	568	575	573	572	570	565	552	547	544
1/11/2021	523	488	478	469	462	455	450	448	445	448	452	458	471	473	483	501	529	565	588	603	617	629	638	644	639	641	644	654	658	659	648	639	627	611	602
1/12/2021	512	508	496	486	480	476	468	463	460	462	466	476	483	489	493	505	528	557	581	606	616	622	638	642	640	642	648	661	659	654	654	642	626	614	599
1/13/2021	508	499	488	480	472	464	462	458	456	459	464	477	479	478	478	489	503	530	546	566	576	585	590	600	597	597	601	610	610	607	601	592	590	584	569
1/14/2021	542	499	481	475	468	461	461	454	450	449	453	462	471	479	488	503	528	554	580	593	609	618	627	634	632	636	642	651	654	656	657	646	636	619	596
1/15/2021	474	520	510	499	491	479	475	469	462	464	464	472	480	488	494	505	532	558	584	611	618	629	640	643	639	627	625	631	630	631	625	622	614	605	594
1/16/2021	449	464	456	451	446	442	437	432	429	431	437	445	452	456	458	466	483	506	515	524	532	532	532	531	520	517	516	519	517	522	520	519	515	512	509

Gambar 3.2 Raw dataset electricity demand di Bali tahun 2021

Atribut-atribut penting yang dimiliki oleh dataset beserta deskripsinya tertera dalam tabel sebagai berikut:

Tabel 3.1 Atribut Dataset Demand Energi Listrik

Variabel	Jenis/ Tipe Data	Deskripsi
Date	Date	Dataset <i>date</i> dalam satuan tanggal,bulan dan tahun.
Time	Time	Dataset <i>time</i> dalam satuan jam (WIB/Waktu Indonesia Barat).
Demand (MW)	Kontinu	Jumlah energi listrik (beban listrik) dalam satuan Mega Watt(MW).

No	Nama Provinsi	2019	2020	2021	2022	2023
1	Aceh	5.274,87	5.334,90	5.409,19	5.482,53	5.554,82
2	Sumatera Utara	14.799,36	14.970,50	15.180,53	15.386,64	15.588,53
3	Sumatera Barat	5.534,47	5.597,31	5.677,55	5.757,21	5.836,16
4	Riau	6.394,09	6.466,76	6.555,75	6.642,87	6.728,05
5	Jambi	3.548,23	3.586,40	3.633,19	3.679,17	3.724,28
6	Sumatera Selatan	8.467,43	8.548,61	8.647,26	8.743,52	8.837,30
7	Bengkulu	2.010,67	2.032,38	2.059,37	2.086,01	2.112,24
8	Lampung	9.007,85	9.096,52	9.206,26	9.313,98	9.419,58
9	Kepulauan Bangka Belitung	1.455,68	1.471,79	1.491,99	1.511,90	1.531,53
10	Kepulauan Riau	2.064,66	1.591,53	2.121,48	2.152,63	2.183,29
11	DKI Jakarta	10.562,09	10.605,44	10.640,51	10.672,10	10.684,95
12	Jawa Barat	48.274,16	48.738,81	49.306,78	49.860,33	50.345,19
13	Jawa Tengah	36.516,04	36.811,14	37.180,41	37.540,96	37.892,28
14	DI Yogyakarta	3.668,72	3.687,77	3.712,67	3.736,49	3.768,50
15	Jawa Timur	40.665,70	40.921,08	41.229,98	41.527,93	41.814,50
16	Banten	11.904,56	12.022,95	12.167,04	12.307,73	12.431,39
17	Bali	4.317,40	4.343,45	4.374,31	4.404,26	4.433,26
18	Nusa Tenggara Barat	5.320,09	5.387,15	5.473,97	5.560,29	5.646,02
19	Nusa Tenggara Timur	5.325,57	5.394,38	5.481,79	5.569,07	5.656,04

Gambar 3.3 Raw Dataset jumlah penduduk

Gambar 3.3 merupakan salah satu contoh dari data parameter jumlah penduduk pada tahun 2019 hingga tahun 2023. Namun, dalam skripsi ini data yang akan digunakan hanya

pada tahun 2021 hingga 2023 saja. *Dataset* Demografi dan PDRB terdiri atas parameter Jumlah Penduduk, Jumlah Penduduk Miskin, dan PDRB. Atribut-atribut penting yang dimiliki oleh dataset beserta deskripsinya tertera dalam tabel sebagai berikut:

Tabel 3.2 Atribut Dataset Jumlah Penduduk

Variabel	Jenis/ Tipe Data	Deskripsi
Nama Provinsi	Kategorikal	Provinsi di seluruh Pulau Jawa dan Bali, dengan total provinsi sebanyak 7 provinsi.
Tahun	Numerikal	Data yang digunakan untuk merepresentasikan tahun dari setiap data Jumlah Penduduk yang ada pada setiap Provinsi.
Jumlah Penduduk	Numerikal	Representasi numerik dari Jumlah Penduduk yang ada pada setiap provinsi, pada tahun tertentu. Jumlah Penduduk dalam satuan Ribu Jiwa.

Dataset Jumlah Penduduk & PDRB Provinsi (2018 - 2023)

File Edit View Insert Format Data Tools Extensions Help

Gambar 3.4 Raw Dataset Jumlah Penduduk Miskin

Gambar 3.4 merupakan data parameter Jumlah Penduduk Miskin. Untuk parameter Jumlah Penduduk Miskin dalam satuan Ribu Jiwa. Atribut-atribut penting yang dimiliki oleh dataset beserta deskripsinya tertera dalam tabel sebagai berikut:

Tabel 3.3 Atribut Dataset Jumlah Penduduk Miskin

Variabel	Jenis/ Tipe Data	Deskripsi
Nama Provinsi	Kategorikal	Provinsi di seluruh Pulau Jawa dan Bali, dengan total provinsi sebanyak 7 provinsi.
Tahun	Numerikal	Data yang digunakan untuk merepresentasikan tahun dari setiap data Jumlah Penduduk yang ada pada setiap

		Provinsi.
Jumlah Penduduk Miskin	Numerikal	Representasi numerik dari Jumlah Penduduk Miskin yang ada pada setiap provinsi, pada tahun tertentu. Jumlah Penduduk Miskin dalam satuan Ribu Jiwa.

Dataset Jumlah Penduduk & PDRB Provinsi (2018 - 2023)

File Edit View Insert Format Data Tools Extensions Help

65% Arial 12

No	Nama Provinsi	2019	2020	2021	2022	2023	Produk Domestik Regional Bruto per Kapita Atas Dasar Harga Berlaku Menurut Provinsi (Ribu rupiah), 2018-2023
1	Aceh	30.879	31.033	34.674	38.9	41.424	
2	Sumatera Utara	54.62	54.979	57.442	62.822	68.306	
3	Sumatera Barat	44.886	43.826	45.218	50.264	54.327	
4	Riau	111.227	114.167	129.741	151.259	154.522	
5	Jambi	60.829	57.958	64.771	76.164	79.836	
6	Sumatera Selatan	53.359	53.843	57.745	68.237	71.95	
7	Bengkulu	36.565	36.552	39.167	43.757	46.285	
8	Lampung	42.172	39.29	40.807	44.984	48.194	
9	Kepulauan Bangka Belitung	52.233	52.023	58.406	63.872	67.885	
10	Kepulauan Riau	119.385	123.465	131.884	145.579	154.179	
11	DKI Jakarta	268.052	262.615	274.66	299.675	322.615	
12	Jawa Barat	43.309	43.237	45.234	49.137	52.651	
13	Jawa Tengah	38.388	36.965	38.568	41.946	45.199	
14	DI Yogyakarta	36.46	37.094	40.516	44.637	48.355	
15	Jawa Timur	59.015	56.641	59.988	66.247	71.122	
16	Banten	52.014	52.729	55.383	61.414	66.147	
17	Bali	57.796	52.015	59.758	66.092	62.293	
18	Nusa Tenggara Barat	25.710	25.184	26.009	28.671	29.626	
19	Nusa Tenggara Timur	19.63	20.057	20.555	21.657	23.078	
20	Kalimantan Barat	42.045	39.622	42.253	46.062	48.809	
21	Kalimantan Tengah	56.825	57.145	62.834	72.889	75.294	
22	Kalimantan Selatan	42.824	44.101	48.066	60.244	63.779	

Data Jumlah Penduduk Data Jumlah Penduduk Miskin Data PDRB per Kapita Atas Dasar Harga Berlaku Data PD

Gambar 3.5 Raw dataset PDRB

Gambar 3.5 merupakan data *parameter* PDRB yang ada pada setiap provinsi. Untuk *parameter* PDRB dalam bentuk satuan Ribu Rupiah. Atribut-atribut penting yang dimiliki oleh dataset beserta deskripsinya tertera dalam tabel sebagai berikut:

Tabel 3.4 Atribut Dataset PDRB

Variabel	Jenis/ Tipe Data	Deskripsi
Nama Provinsi	Kategorikal	Provinsi di seluruh Pulau Jawa dan Bali, dengan total provinsi sebanyak 7 provinsi.
Tahun	Numerikal	Data yang digunakan untuk merepresentasikan tahun dari setiap data Jumlah Penduduk yang ada pada setiap Provinsi.
PDRB	Numerikal	Representasi numerik dari nilai PDRB per Kapita Atas Dasar Harga Berlaku yang ada pada setiap provinsi, pada tahun tertentu. Nilai PDRB pada setiap provinsi dalam satuan Ribu Rupiah.

PROVINSI	2020	2021	2022	2023
JAKARTA	4,755,494	4,915,913	5,064,418	5,225,077
BANTEN	3,496,958	3,669,187	3,828,077	3,994,766
JABAR	15,167,973	15,765,747	16,310,301	16,937,850
JATENG	10,727,635	11,100,297	11,438,105	11,820,721
DI YOGYAKARTA	1,309,877	1,364,263	1,413,515	1,475,831
JATIM	12,431,589	12,864,784	13,275,133	13,721,107
BALI	1,528,854	1,579,283	1,630,528	1,701,512
Kenaikan Jumlah Pelanggan Bali		3.298483701	3.244526925	4.353436433

Gambar 3.6 Raw dataset jumlah pelanggan listrik

Gambar 3.6 merupakan data parameter Jumlah Pelanggan Listrik pada tahun 2020 hingga tahun 2023. Data Jumlah Pelanggan Listrik yang akan digunakan hanya pada tahun 2021 hingga 2023 saja. Dataset Jumlah Pelanggan Listrik terdiri atas parameter Jumlah Pelanggan Listrik, Listrik Terjual, Daya Terpasang, dan Produksi Listrik. Parameter-parameter tersebut dalam bentuk data tahunan. Atribut-atribut penting yang dimiliki oleh dataset beserta deskripsinya tertera dalam tabel sebagai berikut:

Tabel 3.5 Atribut Dataset Jumlah Pelanggan Listrik

Variabel	Jenis/ Tipe Data	Deskripsi
Nama Provinsi	Kategorikal	Provinsi di seluruh Pulau Jawa dan Bali, dengan total provinsi sebanyak 7 provinsi.
Tahun	Numerikal	Data yang digunakan untuk merepresentasikan tahun dari setiap data Jumlah Penduduk yang ada pada setiap Provinsi.
Jumlah Pelanggan Listrik	Numerikal	Representasi numerik dari Jumlah Pelanggan Listrik yang ada pada setiap provinsi, pada tahun tertentu. Nilai Jumlah Pelanggan Listrik pada setiap provinsi dalam satuan Tiap Pelanggan.

PROVINSI	2020	2021	2022	2023
JAKARTA	32,194,868	32,709,300	34,578,290	36,992,350
BANTEN	22,352,110	23,830,910	26,705,670	26,971,400
JABAR	49,882,910	53,318,020	56,226,110	58,564,310
JATENG	25,279,078	26,661,160	27,564,640	28,431,750
DI YOGYAKARTA	3,029,221	3,108,380	3,326,610	3,564,230
JATIM	37,613,562	39,457,190	40,546,880	41,886,300
BALI	4,963,632	4,708,020	5,470,511	6,354,530
JAWA		183,792,980	194,418,711	202,764,870
BALI		179,084,960	188,948,210	196,410,340
ALL		4,708,020	5,470,511	6,354,530

Gambar 3.7 Raw dataset jumlah listrik terjual

Data parameter Listrik Terjual, Daya Terpasang, dan Produksi Listrik memiliki kondisi *raw* data yang sama, hanya terdapat perbedaan pada value data dan satuan dalam dataset nya. Gambar 3.7 merupakan salah satu contoh dari data parameter Jumlah Listrik Terjual pada tahun 2020 hingga tahun 2023. Namun data parameter yang digunakan dalam skripsi ini, hanya pada tahun 2021 hingga tahun 2023 saja. Parameter Listrik Terjual dalam satuan MWh. Atribut-atribut penting yang dimiliki oleh dataset beserta deskripsinya tertera dalam tabel sebagai berikut:

Tabel 3.6 Atribut Dataset Jumlah Listrik Terjual

Variabel	Jenis/ Tipe Data	Deskripsi
Nama Provinsi	Kategorikal	Provinsi di seluruh Pulau Jawa dan Bali, dengan total provinsi sebanyak 5 provinsi. Untuk provinsi Jakarta digabung dengan Banten dan provinsi Jawa Tengah digabung dengan DI Yogyakarta.
Tahun	Numerikal	Data yang digunakan untuk merepresentasikan tahun dari setiap data Jumlah Penduduk yang ada pada setiap Provinsi.
Jumlah Listrik Terjual	Numerikal	Representasi numerik dari Jumlah Listrik Terjual yang ada pada setiap provinsi, pada tahun tertentu. Nilai Jumlah Listrik Terjual pada setiap provinsi dalam satuan MWh.

DATA LISTRIK PT. PLN (JAWA-BALI) 2021-2023

File Edit View Insert Format Data Tools Extensions Help

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

75%

123

Calibri

14

B

I

A

Gambar 3.8 Raw dataset daya terpasang, listrik terjual, dan produksi listrik


Gambar 3.8 merupakan salah satu contoh dari Data parameter Daya Terpasang, Listrik Terjual, dan Produksi Listrik pada tahun 2020 hingga tahun 2023. Data parameter yang digunakan dalam skripsi, hanya pada tahun 2021 hingga tahun 2023 saja. Parameter Daya Terpasang dalam satuan MegaWatt. Sedangkan parameter Listrik Terjual dan Produksi Listrik dalam satuan MWh. Atribut-atribut penting yang dimiliki oleh dataset beserta deskripsinya tertera dalam tabel sebagai berikut:

Tabel 3.7 Atribut Dataset Daya Terpasang, Listrik Terjual, dan Produksi Listrik

Variabel	Jenis/ Tipe Data	Deskripsi
Nama Provinsi	Kategorikal	Provinsi di seluruh Pulau Jawa dan Bali, dengan total provinsi sebanyak 5 provinsi. Untuk provinsi Jakarta digabung dengan Banten dan provinsi Jawa Tengah digabung dengan DI Yogyakarta.
Tahun	Numerikal	Data yang digunakan untuk merepresentasikan tahun dari setiap data Jumlah Penduduk yang ada pada setiap Provinsi.
Daya Terpasang	Numerikal	Representasi numerik dari Daya Terpasang yang ada pada setiap provinsi, pada tahun tertentu. Nilai Daya Terpasang pada setiap provinsi dalam satuan MegaWatt.
Produksi Listrik	Numerikal	Representasi numerik dari Produksi Listrik yang ada pada setiap provinsi, pada tahun tertentu. Nilai Produksi Listrik pada setiap provinsi dalam satuan MWh.
Listrik Terjual	Numerikal	Representasi numerik dari Listrik Terjual yang ada pada setiap provinsi, pada tahun tertentu. Nilai Listrik Terjual pada setiap provinsi dalam satuan MWh.

3.4 Desain Sistem

Desain sistem menjelaskan terkait tahapan yang akan dikerjakan dalam skripsi secara berurutan. Penggambaran desain sistem akan dilakukan dengan menggunakan *flowchart*, yang akan membahas terkait seluruh proses, *input*, dan *output* yang akan dilakukan dalam skripsi ini. *Flowchart* dapat dilihat pada Gambar 3.9.



Gambar 3.9 Alur Desain Sistem

Gambar 3.9 menunjukkan alur tahapan pengerjaan pada skripsi ini. Dimulai dengan tahapan pemahaman permasalahan, dimana berinteraksi dengan *problem owner* untuk memahami permasalahan yang terjadi dan tujuan akhir yang akan diselesaikan. Selain itu, dilakukan pemahaman terkait karakteristik *dataset* yang digunakan dalam skripsi ini, sehingga mampu mengidentifikasi masalah dan mampu menentukan teknik pemrosesan data yang tepat terhadap *dataset* yang ada. Setelah itu, dilakukan *data preprocessing* untuk membersihkan dan melakukan transformasi data, serta pemilihan fitur yang relevan dan tepat dalam tahapan pemilihan model dan *training* model. Kemudian dilanjutkan dengan tahapan *data merging*, dimana melakukan penggabungan *Dataset Demand* Energi Listrik dengan data-data pendukung seperti *Dataset Demografi* dan PDRB, *Dataset Jumlah Pelanggan Listrik*, *Dataset Listrik Terjual*, dan *Dataset Daya Terpasang-Listrik Terjual-Produksi Listrik*. Setelah *dataset* berhasil di *merge*, maka tahapan berikutnya adalah *training and evaluation model*. Pada tahapan *training* dan *evaluation*, setiap model akan di *training* menggunakan *dataset* yang sudah di *merge* dan akan dievaluasi menggunakan beberapa metode pengujian seperti *rmse*, *mae*, dan *r-squared*.

Kemudian dilanjutkan dengan tahapan *selection model*. Model yang dipilih merupakan model terbaik dari hasil *training and evaluation model*. Model terbaik dipilih berdasarkan hasil *evaluation* yang telah dilakukan. Tahapan terakhir adalah *visualization and prediction*, pada tahapan ini akan dilakukan prediksi terhadap *demand* energi listrik di masa depan dengan menggunakan model terbaik yang telah dipilih pada tahapan sebelumnya. Sehingga

dalam tahapan *prediction*, hanya model terbaik saja yang akan diaplikasikan dalam bentuk berbasis *website*. Selain itu, prediksi *demand* energi listrik akan ditampilkan menggunakan *data visualization*, agar mempermudah penyampaian informasi serta menghasilkan *insight* yang menarik dari *dataset*.

3.4.1. Business and Data Understanding

Tahapan pertama adalah memahami permasalahan dan studi literatur agar mampu menentukan tujuan dan pemilihan model terbaik dalam setiap metode yang dilakukan dalam skripsi ini. Proses dimulai dengan memahami dan menganalisa informasi yang berkaitan dengan permasalahan yang akan diselesaikan dengan berdiskusi dengan *problem owner* yaitu Dr. Gregorius Satia Budhi, S.T., M.T. selaku dosen pembimbing 1 dan Yusak Tanoto, S.T., M.Eng., Ph.D. selaku dosen pembimbing 2. Melalui prosesi ini, diperoleh informasi bagaimana memperoleh sumber data dan tujuan akhir yang akan dicapai dalam penelitian ini yaitu memprediksi *demand* energi listrik pada pulau jawa dan bali. Memprediksi *demand* energi listrik pada pulau jawa dan bali akan dilakukan dengan membandingkan beberapa model *machine learning* dan *deep learning* yang telah dipilih, dimana nantinya hanya model terbaik yang akan dipilih sebagai model untuk memprediksi *demand* energi listrik pada pulau jawa dan bali.


Model *machine learning* dan *deep learning* yang akan digunakan dalam skripsi ini meliputi *Random Forest*, *Support Vector Regression*, *XGboost*, *LSTM*, dan *Transformers*. Dalam skripsi ini, juga akan dilakukan analisis dan visualisasi data dari model terbaik yang telah dipilih dan dari *dataset* yang telah diolah, sehingga mampu memberikan gambaran terkait *demand* energi listrik pada pulau jawa dan bali di masa depan. Dengan hasil tersebut diharapkan dapat membantu memberikan gambaran dan informasi kepada pengambil keputusan terkait dengan *demand* energi listrik pada pulau jawa dan bali di masa depan. Kemudian dilanjutkan dengan mempelajari studi literatur terkait dengan teori dan metode yang akan digunakan di dalam penelitian skripsi ini. Dalam penelitian ini teori yang akan dipelajari meliputi *Demand* energi listrik, *Random Forest*, *Support Vector Regression*, *XGBoost*, *LSTM*, *Transformers*, *Dash*, dan *Grid Search*.

3.4.2. Data Preprocessing

Tahapan *data preprocessing* dimulai dengan menghapus data *demand* energi listrik yang tidak digunakan. *Raw dataset demand* energi listrik berupa data setiap 30 menit, maka untuk data yang berada pada jam yang berkelipatan 30 menit perlu di *cleaning* karena tidak

digunakan dalam penelitian ini. Hasil akhir dari *data preprocessing* adalah *dataset demand* energi listrik yang akan digunakan dalam bentuk satuan setiap jam dalam setiap hari selama tahun 2021-2023. Karena pada *dataset* awal, *parameter* pdrb dalam bentuk satuan ribu rupiah, maka perlu diubah menjadi satuan rupiah, dimana *data parameter* pdrb perlu dikalikan 1000. Agar nantinya *parameter* pdrb dalam bentuk satuan rupiah.


Karena *parameter* jumlah penduduk dan jumlah penduduk miskin, mula-mula dalam satuan ribu jiwa, maka perlu diubah menjadi dalam bentuk satuan jiwa. Sehingga data *parameter* jumlah penduduk dan jumlah penduduk miskin, perlu dikalikan 1000 pada setiap *value* data nya. *Parameter* listrik terjual dan produksi listrik awalnya dalam satuan MWh (*Megawatt per hour*). *Parameter* daya terpasang mulanya dalam bentuk satuan MW (*Megawatt*). Pada *dataset* demografi dan pdrb, dan *dataset* jumlah pelanggan listrik akan dilakukan interpolasi data pada tahapan *data formatting*. Sehingga *dataset* demografi dan pdrb, dan *dataset* jumlah pelanggan listrik dapat berbentuk data bulanan. Proses *data preprocessing* dapat dilihat pada Gambar 3.10.



Gambar 3.10 Tahapan Data preprocessing

Langkah pertama dalam tahapan *data preprocessing* adalah *Data Preparation*. Langkah ini meliputi menyiapkan *raw data demand* energi listrik dan data-data pendukung seperti *dataset* demografi dan pdrb, serta data jumlah pelanggan listrik.

3.4.2.2 Data Cleaning



Gambar 3.12 Tahapan data cleaning


Gambar 3.12 merupakan tahapan *data cleaning dataset* pada *dataset demand energi listrik*. *Raw dataset* yang telah diperoleh dilakukan *cleaning data*, dimana *parameter-parameter* yang tidak digunakan dalam skripsi, tidak dimasukkan ke dalam *dataframe*. Setelah dilakukan *data cleaning*, dilanjutkan dengan *data transformation*. Teknik *data transformation* yang digunakan adalah *data normalization*. Metode *data normalization* yang digunakan yaitu *standardization*, menggunakan *library StandardScaler*. *StandardScaler* melakukan transformasi data dengan cara mengurangi *mean* dan membaginya dengan standar deviasi dari distribusi data. Hasil dari teknik *standardization* adalah data akan memiliki nilai *mean* = 0 dan standar deviasi = 1, tetapi *range* nilainya tidak terbatas seperti pada *Min-Max Scaling*.

Apabila seluruh *dataset demand energi listrik* telah di *preprocessing*, maka *dataset* tersebut akan disimpan dalam 1 *file csv*. Dalam *file csv* tersebut, terdiri atas *dataset demand energi listrik* pada tahun 2021 hingga tahun 2023 di seluruh provinsi yang ada di Jawa-Bali. Provinsi tersebut meliputi Jakarta-Banten, Jawa Barat, Jawa Tengah-DI Yogyakarta, Jawa Timur, dan Bali. Khusus 4 provinsi yaitu Jakarta,Banten, Jawa Tengah dan DI Yogyakarta akan digabung menjadi 2 provinsi besar, karena *dataset demand energi listrik* yang berasal dari data beban UP2B pada provinsi tersebut dijadikan 1 provinsi saja. Sehingga provinsi Jakarta

dan Banten akan menjadi Jakarta-Banten. Sedangkan provinsi Jawa Tengah dan DI Yogyakarta akan digabung menjadi Jawa Tengah-DI Yogyakarta.

3.4.2.3 Data Formatting


Pada tahapan ini *dataset* demografi dan pdrb, serta *dataset* jumlah pelanggan listrik dilakukan interpolasi data. Interpolasi data yang dilakukan menggunakan metode regresi linear, dimana *raw dataset* dari 2 *dataset* tersebut mulanya berbentuk data tahunan, kemudian dilakukan interpolasi data menjadi data bulanan, agar satuan data nya sama dengan *dataset demand* energi listrik. Tahapan interpolasi data pada *dataset* demografi dan pdrb, serta *dataset* jumlah pelanggan listrik dapat dilihat pada *flowchart* dibawah ini.



Gambar 3.13 Tahapan pada data formatting

Tahapan *data formatting* dimulai dengan memperoleh *dataset* hasil *cleaning*, kemudian dilanjutkan dengan melakukan interpolasi data menggunakan metode regresi linear. Dalam melakukan interpolasi data diperlukan data awal dan data akhir dari setiap *parameter* yang terdapat pada *dataset* demografi dan pdrb, serta *dataset* jumlah pelanggan listrik. Sehingga hasil interpolasi data dalam setiap bulan sesuai dengan data tahunan yang diperoleh dari masing-masing sumber *dataset*. Interpolasi data dilakukan menggunakan metode regresi linear, karena metode regresi linear cukup sederhana dan implementasinya mudah dilakukan. Selanjutnya, setelah dilakukan interpolasi data, maka setiap hasil data bulanan nya akan disimpan dalam *csv file*. Dimana dalam *csv file* tersebut terdiri atas *parameter-parameter* seperti pada *dataset* demografi dan pdrb, serta *dataset* jumlah pelanggan listrik, dan parameter *date*. Kemudian *csv file* tersebut yang akan digunakan untuk *data merging* dengan *dataset demand* energi listrik.


3.4.2.3.1 Interpolasi Data



Gambar 3.14 Tahapan Interpolasi Data

Tahapan interpolasi data dimulai dengan memperoleh data awal dan data akhir dari setiap *parameter* yang terdapat pada *dataset* demografi dan pdrb, serta *dataset* jumlah pelanggan listrik. Kemudian setiap data *parameter* tersebut dilakukan interpolasi data menggunakan metode regresi linear, agar dapat mengubah data tahunan menjadi data bulanan. Data tahunan setiap parameter diubah menjadi dalam bentuk setiap bulan dalam setahun, sehingga terdapat 12 data dalam setahun, karena terdapat 12 bulan dalam setahun. Setelah data tahunan selesai dilakukan interpolasi menjadi data bulanan, maka data hasil interpolasi akan disimpan dalam bentuk *dataframe*, kemudian akan disimpan dalam bentuk *file csv*.

3.4.3. Data Merging




Gambar 3.15 Tahapan pada Data merging

Setelah *dataset* selesai dilakukan *preprocessing*, tahapan berikutnya adalah melakukan *data merging* dari beberapa *dataset* yang ada, meliputi *dataset demand* energi listrik, *dataset* demografi dan pdrb, dan *dataset* jumlah pelanggan listrik. *Merging dataset*

dilakukan agar pada saat melakukan *training* dan *evaluation model*, dapat berjalan dengan efisien dan menghemat *memory*, karena jika dilakukan *training* pada setiap *dataset* tentunya akan memakan lebih banyak waktu dan *memory*. *Merging dataset* dilakukan dengan menggunakan *python*. Setelah *dataset* selesai dilakukan *merging*, kemudian *dataset* tersebut di *extract* dalam bentuk *file parquet*. File dalam bentuk *parquet* yang akan digunakan dalam proses *training and evaluation model*.


3.4.4. Training and Evaluation Model



Gambar 3.16 Tahapan training and evaluation model

Pada tahap ini, *dataset* yang sudah di *preprocessing* akan digunakan untuk melatih dan mengevaluasi beberapa model yang telah dipilih dalam penelitian ini. Model tersebut diantaranya adalah *random forest*, *support vector regression*, *xgboost*, *lstm*, dan *transformers*. Tahapan dimulai dengan memilih salah satu *province* yang ada pada *dataset*, dan akan digunakan untuk melakukan *training and evaluation model*. Setelah salah satu *province*, telah dipilih kemudian dilanjutkan dengan melakukan *hyperparameter tuning*. *Hyperparameter tuning* digunakan untuk memperoleh parameter terbaik dalam model yang akan di *training*. Langkah berikutnya adalah melakukan evaluasi model dengan menggunakan metode *cross validation* dengan tujuan untuk memperoleh model yang memiliki nilai *error* yang paling rendah. Tahap *evaluation model* akan me-return nilai *rmse*, *mae*, *r-squared*, dan *training time* dari hasil *training* dan *testing* data. Hasil *evaluation model*, akan disimpan untuk tahapan berikutnya, yaitu memilih model terbaik yang akan digunakan untuk memprediksi *demand* energi listrik pada Pulau Jawa dan Bali.


3.4.4.1 Hyperparameter Tuning



Gambar 3.17 Tahapan hyperparameter tuning

Tujuan dari *hyperparameter tuning* adalah mencari konfigurasi parameter terbaik dalam algoritma *machine learning* pada saat *training model*, agar dapat meningkatkan nilai performa model. Tahapan dimulai dengan melakukan inisialisasi beberapa model yang akan digunakan dan melakukan inisialisasi terhadap parameter-parameter yang ada dalam *dataset*. Kemudian, masuk pada pengulangan yang pertama dimulai dengan *parameter* pertama dengan *parameter* yang lain dalam keadaan *default*. Selanjutnya, dilakukan *Grid Search* dengan menggunakan metode *cross validation* dimana jumlah $cv = 5$ dan $random_state=42$, serta penilaian menggunakan hasil dari *rmse*. Setelah proses *grid search* selesai, maka hasil *parameter* dan nilai *rmse* nya akan dicatat dan disimpan untuk mempermudah dalam evaluasi model. Kemudian akan dipilih nilai pada *parameter* pertama untuk digunakan dalam iterasi pencarian *parameter* berikutnya. Proses pengulangan kedua selesai, ketika telah memperoleh seluruh nilai *parameter* optimal dari setiap model. Kemudian pengulangan pertama memulai proses yang sama dengan model yang lain. Setelah semua model memiliki *parameter* yang optimal, maka hasil akan di *return* pada proses utama dalam model dan *parameter* akan digunakan dalam proses *evaluation model*.


3.4.4.2 Evaluation Model



Gambar 3.18 Tahapan Evaluation model

Tahapan evaluation model dimulai dengan melakukan inisialisasi metode *cross validation*. Dalam skripsi ini metode *cross validation* menggunakan *grid search*, setelah itu melakukan inisialisasi pada model. Apabila model dan *cross validation* telah di inisialisasi, selanjutnya melakukan *training* data menggunakan data yang telah di *preprocessing*. Dalam tahapan ini, *training data* diuji dengan pengukuran *error matrix* dan *time training*. *Error matrix* yang digunakan untuk menguji model yaitu *rmse*, *mae*, dan *r-squared*. Apabila *training data* telah dilakukan, maka hasil *training* tersebut akan disimpan untuk digunakan dalam mencari model terbaik pada tahapan berikutnya. Setiap model akan dilakukan *training* data seperti pada Gambar 3.18 tersebut.

3.4.5. Selection Model




Gambar 3.19 Tahapan Selection Model

Tahapan *selection model* dilakukan untuk memperoleh model terbaik yang akan digunakan untuk *prediction and visualization*. Tahap ini dimulai dengan menggunakan hasil *evaluation* model yang telah dilakukan pada tahap sebelumnya, untuk memilih model *machine learning* atau *deep learning* terbaik. Model terbaik dipilih berdasarkan nilai *error matrix* dan *training timenya*. Model yang memiliki nilai *error matrix* terendah dan nilai *time training* terendah, yang akan dipilih sebagai model terbaik. Apabila model terbaik telah

dipilih, selanjutnya model akan disimpan untuk digunakan dalam *prediction and visualization*.

3.4.6. Prediction and Visualization



Gambar 3.20 Tahapan Prediction and Visualization


Setelah memperoleh model terbaik dalam tahapan *selection model*, langkah berikutnya yaitu melakukan prediksi dan visualisasi terhadap *demand* energi listrik pada pulau Jawa dan Bali. Proses dimulai dengan mengambil model terbaik dari tahapan *selection model* dan mengambil *data sampling* dari *dataset* yang telah di *preprocessing* dan dilakukan transformasi, kemudian melakukan prediksi terhadap *demand* energi listrik pada salah satu provinsi yang ada di Pulau Jawa dan Bali. Setelah melakukan prediksi terhadap *demand* energi listrik, langkah berikutnya yaitu melakukan visualisasi data hasil prediksi *demand* energi listrik dengan berbasis *website*. Visualisasi data akan berisi terkait informasi mengenai *demand* energi listrik yang ada pada salah satu provinsi yang ada di Pulau Jawa dan Bali di masa depan, dan informasi terkait energi listrik, seperti jumlah penduduk, jumlah penduduk miskin dan pdrb.

3.5 Analisa Model

3.5.1 Random Forest

Menurut Breiman (2011), algoritma Random Forest merupakan suatu ansambel acak dari suatu *Decision Tree* (dalam Wuryani and Agustiani, 2021, p. 189). *Random Forest* merupakan salah satu metode *machine learning* yang menyatukan hasil dari beberapa algoritma *Decision Tree*. Setiap *tree* pada model *Random Forest* terbentuk secara independen menggunakan sampel data yang diperoleh secara random, dan distribusi sampel data tersebut seragam untuk seluruh *tree* dalam *forest* (Freund & Schapire, 1996). *Random Forest* dapat digunakan dalam beberapa jenis masalah, baik klasifikasi maupun regresi. *Random Forest* merupakan salah satu algoritma *machine learning* yang memiliki

performa akurasi yang terbaik dan mampu menangani dataset dalam jumlah besar. *Random Forest* juga mampu mengurangi risiko *overfitting* pada model pada saat *dataset* akan di *training*.



Gambar 3.21 Cara Kerja Random Forest

Sumber: Jain et al. *TensorFlow Machine Learning Projects*. O'Reilly Online Learning, p.113.

Cara kerja *random forest* dimulai dengan memilih titik sampling data secara *random* dari training set, hal ini sering disebut dengan *bootstrap sampling*. Kemudian membuat *decision tree* untuk setiap sampel dengan titik data yang sudah dipilih. Selanjutnya, memilih seberapa banyak jawaban *decision tree* yang ingin disertakan untuk membangun model *random forest*. Kemudian menghitung hasil akhir prediksi berdasarkan nilai rata-rata dari seluruh prediksi pada setiap pohon yang sudah dibangun. Library yang akan digunakan dalam skripsi ini adalah *scikit-learn* dengan melakukan pemanggilan library menggunakan *syntax* berikut *from sklearn.ensemble import RandomForestRegressor*.

3.5.2 Extreme Gradient Boosting (XGBoost)

Algoritma ini dikembangkan oleh Tianqi Chen asal China pada tahun 2014. *Extreme Gradient Boosting (XGBoost)* adalah algoritma yang mampu menemukan solusi yang optimal pada beberapa permasalahan khususnya pada masalah terkait dengan regresi, klasifikasi, dan ranking (Yulianti et al., 2022). Menurut Wang (2020), algoritma *XGBoost* mampu memberikan keunggulan dalam hal performa kinerja, efisiensi waktu, dan efisiensi memori yang sudah digunakan pada beberapa bidang penelitian, misalnya seperti bidang kesehatan, risiko kredit perbankan, dan metagenomik (dalam Saputra et al., 2024, p. 28). Terdapat beberapa keuntungan pada model *XGBoost* dalam analisa data diantaranya adalah mampu menangani dataset dalam jumlah yang besar, memiliki performa yang tinggi, dan mampu

mengkombinasikan variabel numerik maupun categorical tanpa data preprocessing tambahan.

Algoritma XGBoost bekerja dengan menggunakan teknik *gradient boosting*, dimana tiap model machine learning yang dibangun akan diambil residual error nya sebagai variabel target. Selain itu, algoritma ini juga menggunakan teknik regularization untuk mencegah overfitting pada model, dimana overfitting disebabkan karena model terlalu fokus pada saat training sehingga akurasi performanya menurun pada saat data testing. Teknik regularization yang digunakan pada algoritma XGBoost adalah L1 dan L2 Regularization, dimana setiap fitur akan diberikan bobot yang berbeda tergantung dari nilai signifikansinya terhadap variabel target (Adimanggala, 2023). *Loss function* berfungsi untuk mengukur dan mencocokkan model dengan *set* pada data *training*. Menurut Hsia and Lin (2020), *regularization* berfungsi untuk mencegah *overfitting* pada data *training*. Library yang akan digunakan dalam skripsi ini adalah *xgboost* dengan melakukan pemanggilan library menggunakan syntax berikut *import xgboost as xgb*.

3.5.3 Support Vector Regression (SVR)


Support Vector Regression merupakan salah satu algoritma dari *supervised learning* pada *machine learning* yang cukup sering digunakan untuk permasalahan terkait regresi. Tujuan dari algoritma SVR adalah untuk menemukan sebuah fungsi sebagai suatu *hyperplane* (garis pemisah) berupa fungsi regresi yang mana sesuai dengan semua input data dengan sebuah *error* dan membuatnya sekecil mungkin (Scholkopf & Smola, 2004). Algoritma ini bekerja dengan cara mencari garis (*hyperplane*) terbaik yang sesuai dengan data serta mampu meminimalkan nilai error antara hasil prediksi dengan nilai aktual. Algoritma *Support Vector Regression* memanfaatkan fungsi kernel untuk melakukan transformasi data input menjadi ruang berdimensi tinggi, dimana mengizinkan untuk menangkap lebih banyak hubungan yang lebih kompleks. Algoritma ini juga menggunakan teknik regularization untuk mencegah terjadinya overfitting pada data saat melakukan *training dataset* (Reddy et al., 2023). Pada algoritma SVR fungsi regresi $f(x)$ dapat dinotasikan sebagai berikut (Scholkopf & Smola, 2004):

$$f(x) = w \cdot \phi(x) + b \quad (3.3)$$

Dimana w merupakan vektor pembobot, sedangkan $\phi(x)$ adalah fungsi yang memetakan x dalam suatu dimensi, dan variabel b merupakan vektor bias. Library yang akan digunakan dalam skripsi ini adalah *scikit-learn* dengan melakukan pemanggilan library menggunakan syntax *from sklearn.svm import SVR*.

3.5.4 LSTM Deep Learning

LSTM merupakan salah satu jenis dari *Recurrent Neural Network (RNN)* dimana dilakukan modifikasi pada *RNN* dengan menambahkan *memory cell* yang dapat menyimpan informasi untuk jangka waktu yang lama (Manaswi, 2018). Algoritma *LSTM* merupakan solusi untuk menangani permasalahan terkait *vanishing gradient* pada *RNN* ketika memproses *data sequential* yang cukup panjang. *LSTM* menyelesaikan permasalahan menghilang atau meledaknya gradien dengan menggunakan *additional gate (output gate)*, *input gate*, dan *forget gate* yang memungkinkan kontrol yang lebih baik pada gradien, dengan memperbolehkan informasi apa yang harus disimpan dan apa yang harus diabaikan, sehingga mengontrol akses informasi ke *state cell* saat ini (Goyal et al., 2018).



Gambar 3.22 Arsitektur LSTM


Sumber: Chung, H., & Shin, K. (2018). Genetic Algorithm-Optimized Long Short-Term Memory Network for stock market prediction. *Sustainability*, p. 7.

Dalam algoritma LSTM terdapat 3 jenis gate yaitu *Input Gate*, *Forget Gate*, dan *Output Gate*. Library yang akan digunakan dalam skripsi ini adalah *keras* dengan *syntax from tensorflow.keras.layers import LSTM, Dense* (untuk memanggil model LSTM pada Deep Learning) dan *from tensorflow.keras.models import Sequential*.

3.5.5 Transformer Deep Learning

Transformers merupakan model *Deep Learning* yang dipublikasikan oleh Vaswani et al. pada tahun 2017 dalam jurnal yang berjudul "Attention is all you need". *Transformers* dikenal karena kemampuannya dalam menangani pemrosesan bahasa alami. Sejak dipublikasikan pada tahun 2017, model *Transformers* telah menggantikan model *RNN* maupun *CNN* dalam beberapa tugas atau penyelesaian permasalahan. *Transformers* merupakan model *Deep Learning* pertama yang sepenuhnya didasarkan pada mekanisme *self-attention*, untuk melakukan komputasi *input* maupun *output* (Li et al., 2022). Dengan menggunakan model ini, *Transformers* mampu memproses dan menangani data yang jauh

lebih panjang dibandingkan dengan model lainnya seperti, *RNN*. Hal ini dikarenakan, 22 model *Transformers* mampu memperoleh informasi dari tiap *word* pada setiap posisi dalam setiap waktu.



Gambar 3.23 Arsitektur Transformer

Sumber: Vaswani et al. (2017). *Attention is all you need*. Advances in Neural Information Processing Systems. p. 3.

Pada gambar 2.3 menunjukkan arsitektur dari model *Transformer*, dimana arsitekturnya terdiri atas dua bagian yaitu *encoder* dan *decoder*. Arsitektur *encoder Transformer* terdiri atas 6 *layer*. Pada setiap *layer encoder* terdiri atas 2 *sub-layer*. *Layer* pertama merupakan *multi-head self-attention* dan *layer* kedua merupakan *feed forward*. Masing-masing *sub-layer* diikuti oleh mekanisme koneksi residual dan normalisasi yang sering disebut dengan *Add & Norm*. Untuk arsitektur *decoder Transformer* juga terdiri atas 6 *layer*. Pada setiap *layer decoder* terdiri atas 3 *sub-layer*. *Layer* pertama merupakan *masked multi-head self-attention*, *layer* kedua merupakan *multi-head self-attention* (yang memperhatikan *output* dari *encoder*), dan *layer* ketiga merupakan *feed forward*. Sama seperti pada bagian *encoder*, di bagian *decoder* setiap *sub-layer* juga diikuti oleh mekanisme koneksi residual dan normalisasi *Add & Norm*. Library yang akan digunakan dalam skripsi ini adalah *pytorch_forecasting* dengan syntax `from pytorch_forecasting.models import Transformer`.

3.5.6 Grid Search

Menurut Müller dan Guido (2016), Grid Search merupakan metode yang digunakan untuk mencari parameter terbaik dari suatu model dengan mencoba semua kombinasi hyperparameter yang disediakan, dengan tujuan untuk meningkatkan performa model. Parameter terbaik yang diambil merupakan parameter yang memiliki nilai error terkecil dari

hasil prediksi model dengan nilai 23 actual atau sebenarnya. Grid search juga menyediakan fitur cross validation. Grid search dapat diilustrasikan menggunakan metode brute force dimana metode ini melakukan percobaan terhadap seluruh kombinasi dari hyperparameter yang disediakan ke konfigurasi grid (Belete & Huchaiah, 2021). Dalam skripsi ini, performa model terbaik dipilih berdasarkan nilai RMSE terendah, karena permasalahan dalam skripsi ini berbentuk permasalahan regresi. Penggunaan metode Grid Search membutuhkan banyak waktu serta memerlukan sumber daya komputasi yang tinggi, karena harus mencoba semua kombinasi yang telah ditentukan, apalagi jika jumlah parameter pada model berjumlah banyak.

4. PENGUJIAN SISTEM

4.1 Pengujian *Hyperparameter Tuning* (Modelling)

Tahap ini bertujuan untuk memperoleh kombinasi parameter terbaik dalam membangun sebuah model prediksi yang optimal sehingga mampu meningkatkan performa dan akurasi model. Parameter terbaik yang diperoleh dari proses *hyperparameter tuning* akan digunakan untuk memprediksi demand energi listrik. Metode yang digunakan untuk mencari parameter terbaik dari model *machine learning* adalah *Grid Search*, sedangkan metode yang digunakan untuk mencari parameter terbaik dari model *deep learning* adalah *optuna*. 2 metode tersebut akan diuji terlebih dahulu dengan data sampel pada provinsi Jakarta. Untuk provinsi lainnya, memiliki proses mencari kombinasi parameter terbaik sama seperti pada provinsi Jakarta yaitu dengan *Grid Search* untuk model *machine learning* dan *Optuna* untuk model *deep learning*. Proses ini menggunakan 80% *dataset* untuk *training*, sedangkan sisanya 20% untuk *testing*. Kemudian akan dilakukan proses *ranking* berdasarkan nilai *RMSE* terendah.

4.1.1 Model *Random Forest*

Tabel 4.1 Parameter model Random Forest

Random Forest	
Jenis Parameter	Parameter yang diuji
<i>n_estimator</i>	[15, 18, 20, 30, 40, 50, 100, 150, 200]
<i>max_depth</i>	[1, 2, 3, 4, 5, 6, 8, 10, 15, 20]
<i>max_features</i>	[0.2, 0.3, 0.5, 0.8, 1.0]
<i>min_samples_leaf</i>	[10, 15, 25, 50, 100, 120, 140, 150, 400, 450, 500, 550, 600]
<i>min_samples_split</i>	[2, 5, 10]

Parameter yang akan diuji pada model *Random Forest* meliputi:

- *n_estimator*: Banyaknya jumlah pohon dalam forest
- *max_depth*: Kedalaman maksimum setiap pohon
- *max_features*: Jumlah *features* maksimum yang dipertimbangkan saat membagi *node*
- *min_samples_leaf*: Jumlah minimum sampel yang dibutuhkan di *leaf tree*
- *min_samples_split*: Jumlah minimum sampel yang dibutuhkan untuk membagi *node*

Tabel 4.2 10 Parameter Terbaik Random Forest pada Provinsi Bali

Ran k	Parameter	RMSE	MAE	R ²
1	max_depth: 4, max_features: 0.5, min_samples_leaf: 25, min_samples_split: 5, n_estimators: 18	90.59	77.84	0.22
2	max_depth: 4, max_features: 0.5, min_samples_leaf: 25, min_samples_split: 10, n_estimators: 18	90.59	77.84	0.22
3	max_depth: 4, max_features: 0.5, min_samples_leaf: 15, min_samples_split: 10, n_estimators: 18	90.59	77.84	0.22
4	max_depth: 4, max_features: 0.5, min_samples_leaf: 10, min_samples_split: 2, n_estimators: 18	90.59	77.84	0.22
5	max_depth: 4, max_features: 0.5, min_samples_leaf: 15, min_samples_split: 5, n_estimators: 18	90.59	77.84	0.22
6	max_depth: 4, max_features: 0.5, min_samples_leaf: 10, min_samples_split: 10, n_estimators: 18	90.59	77.84	0.22
7	max_depth: 4, max_features: 0.5, min_samples_leaf: 15, min_samples_split: 2, n_estimators: 18	90.59	77.84	0.22
8	max_depth: 4, max_features: 0.5, min_samples_leaf: 10, min_samples_split: 5, n_estimators: 18	90.59	77.84	0.22
9	max_depth: 4, max_features: 0.5, min_samples_leaf: 25, min_samples_split: 2, n_estimators: 18	90.59	77.84	0.22
10	max_depth: 4, max_features: 0.5, min_samples_leaf: 10, min_samples_split: 5, n_estimators: 20	90.64	77.88	0.22

Berdasarkan pengujian pada model *Random Forest*, diketahui bahwa kombinasi parameter terbaik adalah max_depth:4, max_features:0.5, min_samples_leaf:25, min_samples_split:5, n_estimators:18. Karena memiliki nilai *rmse* terendah dengan skor 90.59, nilai *mae* sebesar 77.84, dan nilai *R*² sebesar 0.22. Detail perbandingan kombinasi parameter pada model *random forest* dapat dilihat pada Lampiran 1.

4.1.2 Model *Extreme Gradient Boosting (XGBoost)*

Tabel 4.3 Parameter model XGBoost

XGBoost	
Jenis Parameter	Parameter yang diuji
<i>n_estimator</i>	[50, 100, 125, 150, 160, 200, 250, 260, 270, 300]
<i>learning_rate</i>	[0.01, 0.02, 0.03, 0.05, 0.1, 0.5]
<i>max_depth</i>	[2, 3, 4, 5, 10, 15, 20]
<i>subsample</i>	[0.3, 0.4, 0.5, 0.7, 0.8, 1.0]
<i>colsample_bytree</i>	[0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 1.0]

Parameter yang akan diuji pada model *XGBoost* meliputi:

- *n_estimator*: Banyaknya jumlah pohon dalam forest yang akan dibangun
- *learning_rate*: Ukuran langkah pembelajaran untuk mengurangi pengaruh parameter
- *max_depth*: Kedalaman maksimum setiap pohon
- *subsample*: Proporsi jumlah *data* yang digunakan untuk membangun model

- *colsample_bytree*: Proporsi jumlah *feature* yang digunakan saat membangun model

Tabel 4.4 10 Parameter Terbaik XGBoost pada Provinsi Bali

Rank	Parameter	RMSE	MAE	R ²
1	colsample_bytree: 0.6, learning_rate: 0.05, max_depth: 2, 'n_estimators': 160, 'subsample': 0.3	90.89	78.60	0.22
2	colsample_bytree: 0.5, learning_rate: 0.05, max_depth: 2, n_estimators: 160, subsample: 0.3	90.89	78.60	0.22
3	colsample_bytree: 0.6, learning_rate: 0.05, max_depth: 2, n_estimators: 125, subsample: 0.3	90.91	78.62	0.22
4	colsample_bytree: 0.5, learning_rate: 0.05, max_depth: 2, n_estimators: 125, subsample: 0.3	90.91	78.62	0.22
5	colsample_bytree: 0.5, learning_rate: 0.05, max_depth: 2, n_estimators: 150, subsample: 0.3	90.92	78.62	0.22
6	colsample_bytree: 0.6, learning_rate: 0.05, max_depth: 2, n_estimators: 150, subsample: 0.3	90.92	78.62	0.22
7	colsample_bytree: 0.5, learning_rate: 0.1, max_depth: 2, n_estimators: 160, subsample: 0.3	90.96	78.61	0.22
8	colsample_bytree: 0.6, learning_rate: 0.1, max_depth: 2, n_estimators: 160, subsample: 0.3	90.96	78.61	0.22
9	colsample_bytree: 0.5, learning_rate: 0.1, max_depth: 2, n_estimators: 150, subsample: 0.3	90.97	78.60	0.22
10	colsample_bytree: 0.6, learning_rate: 0.1, max_depth: 2, n_estimators: 150, subsample: 0.3	90.97	78.60	0.22

Berdasarkan pengujian pada model *XGBoost*, diketahui bahwa kombinasi parameter terbaik adalah *colsample_bytree*:0.6, *learning_rate*:0.05, *max_depth*:2, *n_estimators*:160, *subsample*:0.3. Karena memiliki nilai *rmse* terendah dengan skor 90.89, nilai *mae* sebesar 78.60, dan nilai *R*² sebesar 0.22. Detail perbandingan kombinasi parameter pada model *xgboost* dapat dilihat pada Lampiran 2.

4.1.3 Model Support Vector Regression (SVR)

Tabel 4.5 Parameter model SVR

Support Vector Regression (SVR)	
Jenis Parameter	Parameter yang diuji
<i>kernel</i>	["linear", "rbf"]
C	[0.01, 0.1, 0.5, 1, 2, 3, 4, 100, 200, 500]
<i>epsilon</i>	[0.01, 0.1, 0.3, 0.5, 1, 100, 200, 500]

Parameter yang akan diuji pada model SVR meliputi:

- *kernel*: Jenis kernel yang berfungsi untuk mengubah data ke dimensi yang lebih tinggi
- C: Tingkat toleransi terhadap *error*. Semakin besar, semakin sedikit toleransi terhadap *error*.
- *epsilon*: Margin toleransi di sekitar garis prediksi di mana tidak ada penalti terhadap *error*

Tabel 4.6 10 Parameter Terbaik SVR pada Provinsi Bali

Ran k	Parameter	RMSE	MAE	R ²
1	'C': 4, 'epsilon': 0.3, 'kernel': 'rbf'	92.95	77.94	0.11
2	'C': 4, 'epsilon': 0.1, 'kernel': 'rbf'	92.97	77.95	0.11
3	'C': 4, 'epsilon': 0.01, 'kernel': 'rbf'	92.97	77.95	0.11
4	'C': 3, 'epsilon': 0.01, 'kernel': 'rbf'	93.01	78.00	0.11
5	'C': 3, 'epsilon': 0.1, 'kernel': 'rbf'	93.01	78.00	0.11
6	'C': 3, 'epsilon': 0.3, 'kernel': 'rbf'	93.02	78.00	0.11
7	'C': 2, 'epsilon': 0.1, 'kernel': 'rbf'	93.17	78.18	0.11
8	'C': 2, 'epsilon': 0.01, 'kernel': 'rbf'	93.17	78.18	0.11
9	'C': 2, 'epsilon': 0.3, 'kernel': 'rbf'	93.18	78.17	0.11
10	'C': 2, 'epsilon': 0.01, 'kernel': 'linear'	94.58	79.57	0.09

Berdasarkan pengujian pada model SVR, diketahui bahwa kombinasi parameter terbaik adalah 'C':4, 'epsilon':0.3, 'kernel': 'rbf'. Karena memiliki nilai *rmse* terendah dengan skor 92.95, nilai *mae* sebesar 77.94, dan nilai *R*² sebesar 0.11. Detail perbandingan kombinasi parameter pada model svr dapat dilihat pada Lampiran 3.

4.1.4 Model LSTM

Tabel 4.7 Parameter model LSTM

LSTM	
Jenis Parameter	Parameter yang diuji
<i>num_units</i>	[10, 128] # nilai <i>num_units</i> dirandom dari angka 10 hingga 128
<i>learning_rate</i>	(0.2, 0.002] # nilai <i>learning_rate</i> dirandom dari 0.2 hingga 0.002
<i>batch_size</i>	[16, 32, 64, 128]

Parameter yang akan diuji pada model LSTM meliputi:

- *num_units*: Jumlah unit neuron di setiap layer LSTM
- *learning_rate*: Ukuran langkah pembaruan bobot selama *training*.
- *batch_size*: Jumlah sampel yang diproses sebelum model diperbarui sekali

Tabel 4.8 10 Parameter Terbaik LSTM pada Provinsi Bali

Trial	Parameter	loss	val_loss
1	'num_units': 40, 'learning_rate': 0.064, 'batch_size': 128	8915.07	8025.24
2	'num_units': 78, 'learning_rate': 0.013, 'batch_size': 32	8709.67	7957.53
3	'num_units': 28, 'learning_rate': 0.005, 'batch_size': 32	8420.38	7980.61
4	'num_units': 84, 'learning_rate': 0.016, 'batch_size': 64	8588.46	8001.76
5	'num_units': 104, 'learning_rate': 0.002, 'batch_size': 64	8800.87	8023.09
6	'num_units': 74, 'learning_rate': 0.024, 'batch_size': 32	8803.63	7995.29
7	'num_units': 44, 'learning_rate': 0.004, 'batch_size': 128	8733.44	7994.59
8	'num_units': 68, 'learning_rate': 0.003, 'batch_size': 32	9587.971	7978.50
9	'num_units': 23, 'learning_rate': 0.121, 'batch_size': 16	9281.27	7960.78
10	'num_units': 90, 'learning_rate': 0.003, 'batch_size': 64	8655.98	7992.20

Berdasarkan pengujian pada model *LSTM* diketahui bahwa kombinasi parameter terbaik adalah 'num_units': 78, 'learning_rate': 0.013, 'batch_size': 32. Karena memiliki nilai *val_loss* terendah dengan skor 7957.53 dan nilai *loss* sebesar 8709.67. Detail perbandingan kombinasi parameter pada model *lstm* dapat dilihat pada Lampiran 4.

4.1.5 Model Transformer

Tabel 4.9 Parameter model Transformer

Transformer	
Jenis Parameter	Parameter yang diuji
<i>num_layers</i>	[1, 2, 3, 4, 5, 6]
<i>d_model</i>	[32, 224, step= 16] #step = kelipatan 16
<i>num_heads</i>	[2, 3, 4, 5, 6]
<i>dff</i>	[64, 224, step= 16] #step = kelipatan 16
<i>rate</i>	[0.1, 0.6] # nilai rate dirandom dari angka 0.1 hingga 0.8

Parameter yang akan diuji pada model *Transformer* meliputi:

- *num_layers*: Jumlah blok *encoder/decoder* dalam model
- *d_model*: Dimensi representasi vektor (ukuran *embedding*)
- *num_heads*: Jumlah *head* dalam mekanisme *multi-head attention*
- *dff*: Ukuran lapisan *feed-forward* setelah *attention*
- *rate*: Rasio *dropout rate* untuk mencegah *overfitting*

Tabel 4.10 10 Parameter Terbaik Transformer pada Provinsi Bali


Trial	Parameter	<i>loss</i>	<i>val_loss</i>
1	'num_layers': 4, 'd_model': 48, 'num_heads': 4, 'dff': 192, 'rate': 0.332, 'batch_size': 64	151924.56	13325.94
2	'num_layers': 3, 'd_model': 208, 'num_heads': 2, 'dff': 224, 'rate': 0.257, 'batch_size': 64	88337.84	11264.14
3	'num_layers': 4, 'd_model': 112, 'num_heads': 2, 'dff': 192, 'rate': 0.275, 'batch_size': 128	18819.48	12009.429
4	'num_layers': 6, 'd_model': 48, 'num_heads': 2, 'dff': 224, 'rate': 0.139, 'batch_size': 32	18643.20	9454.74
5	'num_layers': 1, 'd_model': 224, 'num_heads': 2, 'dff': 128, 'rate': 0.132, 'batch_size': 32	8915.96	7966.91
6	'num_layers': 3, 'd_model': 32, 'num_heads': 5, 'dff': 80, 'rate': 0.215, 'batch_size': 128	18763.02	9012.65
7	'num_layers': 4, 'd_model': 48, 'num_heads': 2, 'dff': 128, 'rate': 0.396, 'batch_size': 32	18953.82	14232.82
8	'num_layers': 5, 'd_model': 96, 'num_heads': 5, 'dff': 112, 'rate': 0.192, 'batch_size': 16	18980.74	9501.87
9	'num_layers': 4, 'd_model': 32, 'num_heads': 2, 'dff': 144, 'rate': 0.322, 'batch_size': 64	17564.00	10246.54
10	'num_layers': 5, 'd_model': 80, 'num_heads': 2, 'dff': 224, 'rate': 0.449, 'batch_size': 16	19024.73	13592.46

Berdasarkan pengujian pada model *Transformer* diketahui bahwa kombinasi parameter terbaik adalah 'num_layers':1, 'd_model':224, 'num_heads':2, 'dff':128, 'rate':0.132, 'batch_size':32. Karena memiliki nilai *val_loss* terendah dengan skor 7966.91 dan nilai *loss* sebesar 8915.96. Detail perbandingan kombinasi parameter pada model *transformer* dapat dilihat pada Lampiran 5.

4.2 Pengujian Model

a. Provinsi Jakarta-Banten:

- Menggunakan All Parameter:




Gambar 4.1 Actual vs Modelled Line Chart using LSTM All Parameter

Tabel 4.11 Hasil Pengujian Model All Parameter pada Jakarta-Banten

Rank	Model	<i>RMSE</i>	<i>MAE</i>	R^2	<i>Training Time</i>
1	LSTM	1110.33	945.30	0.16	133.63
2	Random Forest	1119.09	945.00	0.15	0.63
3	Support Vector Regression	1119.88	943.88	0.15	39.47
4	XGBoost	1122.49	945.26	0.149	1.23
5	Transformer	1217.42	1005.71	-0.002	191.89

Berdasarkan pengujian model pada Jakarta dengan menggunakan seluruh parameter, diperoleh model terbaik yaitu LSTM. LSTM memiliki nilai *rmse* terendah sebesar 1110.33, nilai *mae* sebesar 945.30, dan nilai R^2 sebesar 0.16 dengan *training time* selama 133.63 detik. Model *machine learning* terbaik adalah *Random Forest*

dengan nilai *rmse* sebesar 1119.09, nilai *mae* sebesar 945.00, dan nilai R^2 sebesar 0.15 dengan *training time* selama 0.63 detik.




Gambar 4.2 Feature Important All Parameter pada Jakarta-Banten

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population*, *Electricity Sold*, *PDRB*, *Installed Capacity*, dan *Number Of Electricity Customer* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting kedua adalah *Electricity Sold*. Berdasarkan Gambar 4.2 dapat diketahui bahwa ketika Provinsi yang memiliki populasi penduduk yang besar maka cenderung akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat.

Parameter *Total Poor Population* dan *Electricity Production* memiliki pengaruh yang relatif sedang terhadap prediksi demand energi listrik. Hal ini berarti wilayah dengan jumlah penduduk miskin yang tinggi memiliki kebutuhan energi listrik/*electricity demand* yang rendah. Karena masyarakat yang berada pada kategori miskin, masih kesulitan dalam memenuhi kebutuhan pokok sehari-hari, apalagi memenuhi kebutuhan terkait energi listrik (AC dan kipas angin). Kecuali, pemerintah melakukan pemberian subsidi listrik kepada pihak penduduk miskin, mungkin *electricity demand* pada wilayah tersebut dapat meningkat, namun kontribusinya terhadap prediksi *electricity demand* tidak dominan.

- Menggunakan Top 5 Highest Important Parameter:



Matrix Evaluation Table using Top 5 Highest Feature Important Parameter


Root Mean Squared Error (RMSE)	=	1083.66
Mean Absolute Error (MAE)	=	916.20
R ² Score	=	0.11

Gambar 4.3 Actual vs Modelled Line Chart using LSTM Top 5 Parameter

Tabel 4.12 Hasil Pengujian Model Top 5 Important Parameter pada Jakarta-Banten

Rank	Model	RMSE	MAE	R ²	Training Time
1	LSTM_Top5	1106.92	945.97	0.17	107.83
2	Transformer_Top5	1113.16	935.85	0.16	651.45
3	Random Forest_Top5	1119.41	945.09	0.15	0.55
4	Support Vector Regression_Top5	1119.91	943.86	0.15	31.55
5	XGBoost_Top5	1122.52	945.08	0.14	0.67

Berdasarkan pengujian model pada Jakarta dengan menggunakan Top 5 *important* parameter, diperoleh model terbaik yaitu LSTM. LSTM memiliki nilai *rmse* terendah sebesar 1106.92, nilai *mae* sebesar 945.97, dan nilai R² sebesar 0.17 dengan *training time* selama 107.83 detik. Model *machine learning* terbaik adalah *Random Forest* dengan nilai *rmse* sebesar 1119.41, nilai *mae* sebesar 945.09, dan nilai R² sebesar 0.15 dengan *training time* selamac0.55 detik.




Gambar 4.4 Feature Important Top 5 Parameter pada Jakarta-Banten

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population*, *Electricity Sold*, PDRB, *Installed Capacity*, dan *Number Of Electricity Customer* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting adalah PDRB. Hal ini menandakan bahwa semakin besar nilai PDRB sebuah provinsi, maka akan meningkatkan konsumsi listrik masyarakat pada provinsi tersebut. Berdasarkan Gambar 4.4 dapat diketahui bahwa ketika Provinsi yang memiliki populasi penduduk yang besar maka cenderung akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat.

b. Provinsi Jawa Barat:

- o Menggunakan All Parameter:




Gambar 4.5 Actual vs Modelled Line Chart using SVR All Parameter

Tabel 4.13 Hasil Pengujian Model All Parameter pada Jawa Barat

Rank	Model	RMSE	MAE	R ²	Training Time
1	Support Vector Regression	580.19	464.78	0.116	50.84
2	Random Forest	582.51	470.06	0.109	1.82
3	XGBoost	583.85	472.53	0.105	0.66
4	Transformer	591.32	473.23	0.081	213.29
5	LSTM	598.97	476.12	0.058	128.59

Berdasarkan pengujian model pada Jawa Barat dengan menggunakan seluruh parameter, diperoleh model terbaik yaitu SVR. SVR memiliki nilai *rmse* terendah sebesar 580.19, nilai *mae* sebesar 464.78, dan nilai R² sebesar 0.11 dengan *training*


time selama 50.84 detik. Model *deep learning* terbaik adalah Transformer dengan nilai *rmse* sebesar 591.32, nilai *mae* sebesar 473.23, dan nilai R^2 sebesar 0.08 dengan *training time* selama 213.29 detik.



Gambar 4.6 Feature Important All Parameter pada Jawa Barat

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population*, *Electricity Sold*, *PDRB*, *Installed Capacity*, dan *Number Of Electricity Customer* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting kedua adalah *PDRB*. Berdasarkan Gambar 4.6 dapat diketahui bahwa Provinsi yang memiliki populasi penduduk yang besar maka cenderung akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat. Parameter *Total Poor Population* dan *Electricity Production* memiliki pengaruh yang relatif sedang terhadap prediksi demand energi listrik. Hal ini berarti wilayah dengan jumlah penduduk miskin yang tinggi memiliki kebutuhan energi listrik/*electricity demand* yang rendah. Karena masyarakat yang berada pada kategori miskin, masih kesulitan dalam memenuhi kebutuhan pokok sehari-hari, apalagi memenuhi kebutuhan terkait energi listrik (AC dan kipas angin).

- Menggunakan Top 5 Highest Important Parameter:




Gambar 4.7 Actual vs Modelled Line Chart using SVR Top 5 Parameter

Tabel 4.14 Hasil Pengujian Model Top 5 Important Parameter pada Jawa Barat

Rank	Model	RMSE	MAE	R ²	Training Time
1	LSTM_Top5	570.09	461.91	0.14	146.73
2	Random Forest_Top5	583.41	471.00	0.10	1.87
3	Support Vector Regression_Top5	585.12	468.46	0.10	48.61
4	XGBoost_Top5	586.23	473.23	0.09	0.72
5	Transformer_Top5	619.33	492.46	-0.007	1545.38

Berdasarkan pengujian model pada Jawa Barat dengan menggunakan Top 5 *important* parameter, diperoleh model terbaik yaitu LSTM. LSTM memiliki nilai *rmse* terendah sebesar 570.09, nilai *mae* sebesar 461.91, dan nilai R² sebesar 0.14 dengan *training time* selama 146.73 detik. Model *machine learning* terbaik adalah *Random Forest* dengan nilai *rmse* sebesar 583.41, nilai *mae* sebesar 471.00, dan nilai R² sebesar 0.10 dengan *training time* selama 1.87 detik.




Gambar 4.8 Feature Important Top 5 Parameter pada Jawa Barat

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population, Electricity Sold, PDRB, Installed Capacity, dan Number Of Electricity Customer* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting adalah PDRB. Hal ini menandakan bahwa semakin besar nilai PDRB sebuah provinsi, maka akan meningkatkan konsumsi listrik masyarakat pada provinsi tersebut. Berdasarkan Gambar 4.8 dapat diketahui bahwa ketika Provinsi yang memiliki populasi penduduk yang besar maka cenderung akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat.

c. Provinsi Jawa Tengah-DIY:

- o Menggunakan All Parameter:




Gambar 4.9 Actual vs Modelled Line Chart using Transformer All Parameter

Tabel 4.15 Hasil Pengujian Model All Parameter pada Jawa Tengah-DIY

Rank	Model	RMSE	MAE	R^2	Training Time
1	Transformer	440.72	373.82	0.138	342.53
2	Random Forest	449.79	378.95	0.10	1.01
3	Support Vector Regression	450.38	379.41	0.09	45.80
4	XGBoost	453.75	380.98	0.08	0.72
5	LSTM	457.27	383.69	0.07	140.60


Berdasarkan pengujian model pada Jawa Tengah-DIY dengan menggunakan seluruh parameter, diperoleh model terbaik yaitu Transformer. Transformer memiliki nilai *rmse* terendah sebesar 440.72, nilai *mae* sebesar 373.82, dan nilai R^2 sebesar 0.18 dengan *training time* selama 342.53 detik. Model *machine learning* terbaik adalah *Random Forest* dengan nilai *rmse* sebesar 449.79, nilai *mae* sebesar 378.95, dan nilai R^2 sebesar 0.10 dengan *training time* selama 1.01 detik.



Gambar 4.10 Feature Important All Parameter pada Jawa Tengah-DIY

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population*, *Electricity Sold*, *PDRB*, *Installed Capacity*, dan *Percentage Poor Population* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting kedua adalah *PDRB*. Berdasarkan Gambar 4.10 dapat diketahui bahwa Provinsi yang memiliki populasi penduduk yang besar maka cenderung akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat. Parameter *Total Poor Population* dan *Electricity Production* memiliki pengaruh yang relatif sedang terhadap prediksi demand energi listrik. Hal ini berarti wilayah dengan jumlah penduduk miskin yang tinggi memiliki kebutuhan energi listrik/*electricity demand* yang rendah. Karena masyarakat yang berada pada kategori miskin, masih kesulitan dalam memenuhi kebutuhan pokok sehari-hari, apalagi memenuhi kebutuhan terkait energi listrik (AC dan kipas angin).

- Menggunakan Top 5 Highest Important Parameter:




Gambar 4.11 Actual vs Modelled Line Chart using Transformer Top 5 Parameter

Tabel 4.16 Hasil Pengujian Model Top 5 Parameter pada Jawa Tengah-DIY

Rank	Model	RMSE	MAE	R^2	Training Time
1	Transformer_Top5	439.65	373.07	0.14	101.97
2	Random Forest_Top5	449.83	378.97	0.10	0.55
3	Support Vector Regression_Top5	452.51	380.61	0.09	41.19
4	XGBoost_Top5	454.29	381.28	0.08	0.92
5	LSTM_Top5	458.40	383.25	0.06	102.28

Berdasarkan pengujian model pada Jawa Tengah-DIY dengan menggunakan *Top 5 Important* parameter, diperoleh model terbaik yaitu Transformer. Transformer memiliki nilai *rmse* terendah sebesar 439.65, nilai *mae* sebesar 373.07, dan nilai R^2 sebesar 0.14 dengan *training time* selama 101.97 detik. Model *machine learning* terbaik adalah *Random Forest* dengan nilai *rmse* sebesar 449.83, nilai *mae* sebesar 378.97, dan nilai R^2 sebesar 0.10 dengan *training time* selama 0.55 detik.




Gambar 4.12 Feature Important Top 5 Parameter pada Jawa Tengah-DIY

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population*, *Electricity Sold*, *PDRB*, *Installed Capacity*, dan *Number Of Electricity Customer* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting adalah *Number Of Electricity Customer*. Hal ini menandakan bahwa semakin banyak jumlah pelanggan listrik pada sebuah provinsi, maka akan meningkatkan konsumsi listrik masyarakat pada provinsi tersebut. Berdasarkan Gambar 4.12 dapat diketahui bahwa ketika Provinsi yang memiliki populasi penduduk yang besar maka akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat.

d. Provinsi Jawa Timur:

- o Menggunakan All Parameter:




Gambar 4.13 Actual vs Modelled Line Chart using Random Forest All Parameter

Tabel 4.17 Hasil Pengujian Model All Parameter pada Jawa Timur

Rank	Model	RMSE	MAE	R^2	Training Time
1	Transformer	522.96	434.81	0.11	214.35
2	Random Forest	524.42	435.51	0.11	2.11
3	Support Vector Regression	526.38	436.91	0.10	59.97
4	XGBoost	527.36	437.45	0.10	0.69
5	LSTM	531.87	442.85	0.08	172.57

Berdasarkan pengujian model pada Jawa Timur dengan menggunakan *All* parameter, diperoleh model terbaik yaitu Transformer. Transformer memiliki nilai *rmse* terendah sebesar 522.96, nilai *mae* sebesar 434.81, dan nilai R^2 sebesar 0.11


dengan *training time* selama 214.35 detik. Model *machine learning* terbaik adalah *Random Forest* dengan nilai *rmse* sebesar 524.42, nilai *mae* sebesar 435.51 dan nilai R^2 sebesar 0.11 dengan *training time* selama 2.11 detik.



Gambar 4.14 Feature Important All Parameter pada Jawa Timur

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population*, *Electricity Sold*, *PDRB*, *Installed Capacity*, dan *Percentage Poor Population* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting kedua adalah *Electricity Sold*. Berdasarkan Gambar 4.14 dapat diketahui bahwa Provinsi yang memiliki populasi penduduk yang besar maka cenderung akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat. Parameter *Total Poor Population* dan *Electricity Production* memiliki pengaruh yang relatif sedang terhadap prediksi demand energi listrik. Hal ini berarti wilayah dengan jumlah penduduk miskin yang tinggi memiliki kebutuhan energi listrik/*electricity demand* yang rendah. Karena masyarakat yang berada pada kategori miskin, masih kesulitan dalam memenuhi kebutuhan pokok sehari-hari, apalagi memenuhi kebutuhan terkait energi listrik (AC dan kipas angin).

- Menggunakan Top 5 Highest Important Parameter:




Gambar 4.15 Actual vs Modelled Line Chart using LSTM Top 5 Parameter

Tabel 4.18 Hasil Pengujian Model Top 5 Parameter pada Jawa Timur

Rank	Model	RMSE	MAE	R ²	Training Time
1	LSTM_Top5	517.50	431.57	0.13	151.98
2	Random Forest_Top5	524.40	435.49	0.11	1.08
3	XGBoost_Top5	527.41	437.47	0.10	0.65
4	Support Vector Regression_Top5	528.01	437.92	0.09	48.16
5	Transformer_Top5	529.99	439.81	0.09	83.16

Berdasarkan pengujian model pada Jawa Timur dengan menggunakan *Top 5 Important* parameter, diperoleh model terbaik yaitu LSTM. LSTM memiliki nilai *rmse* terendah sebesar 517.50, nilai *mae* sebesar 431.57, dan nilai R^2 sebesar 0.13 dengan *training time* selama 151.98 detik. Model *machine learning* terbaik adalah *Random Forest* dengan nilai *rmse* sebesar 524.40, nilai *mae* sebesar 435.49, dan nilai R^2 sebesar 0.11 dengan *training time* selama 1.08 detik.




Gambar 4.16 Feature Important Top 5 Parameter pada Jawa Timur

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population*, *Electricity Sold*, *PDRB*, *Installed Capacity*, dan *Number Of Electricity Customer* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting adalah *Number Of Electricity Customer*. Hal ini menandakan bahwa semakin banyak jumlah pelanggan listrik pada sebuah provinsi, maka akan meningkatkan konsumsi listrik masyarakat pada provinsi tersebut. Berdasarkan Gambar 4.16 dapat diketahui bahwa ketika Provinsi yang memiliki populasi penduduk yang besar maka akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat.

e. Provinsi Bali:

- o Menggunakan All Parameter:




Gambar 4.17 Actual vs Modelled Line Chart using LSTM All Parameter

Tabel 4.19 Hasil Pengujian Model All Parameter pada Bali

Rank	Model	RMSE	MAE	R ²	Training Time
1	Random Forest	91.36	77.84	0.50	0.35
2	XGBoost	91.71	78.60	0.50	0.66
3	Transformer	91.72	78.18	0.50	429.14
4	Support Vector Regression	93.37	77.49	0.48	92.41
5	LSTM	94.92	82.39	0.46	163.22

Berdasarkan pengujian model pada Bali dengan menggunakan seluruh parameter, diperoleh model terbaik yaitu *Random Forest*. *Random Forest* memiliki


nilai *rmse* terendah sebesar 91.36, nilai *mae* sebesar 77.84, dan nilai R^2 sebesar 0.50 dengan *training time* selama 0.35 detik. Model *deep learning* terbaik adalah *Transformer* dengan nilai *rmse* sebesar 91.72, nilai *mae* sebesar 78.18, dan nilai R^2 sebesar 0.50 dengan *training time* selama 429.14 detik.



Gambar 4.18 Feature Important All Parameter pada Bali

Berdasarkan pengujian *Feature Importance* dapat dilihat bahwa parameter *Total Population*, *PDRB*, *Installed Capacity*, *Number Of Electricity Customer* dan *Electricity Sold* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting kedua adalah *PDRB*. Berdasarkan Gambar 4.18 dapat diketahui bahwa Provinsi yang memiliki jumlah penduduk yang besar maka cenderung akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat. Parameter *Total Poor Population* dan *Electricity Production* memiliki pengaruh yang relatif rendah terhadap prediksi demand energi listrik. Hal ini berarti wilayah dengan jumlah penduduk miskin yang tinggi memiliki kebutuhan energi listrik/*electricity demand* yang rendah. Karena masyarakat yang berada pada kategori miskin, masih kesulitan dalam memenuhi kebutuhan pokok sehari-hari, apalagi memenuhi kebutuhan terkait energi listrik (AC dan kipas angin).

- Menggunakan Top 5 Highest Important Parameter:




Gambar 4.19 Actual vs Modelled Line Chart using Random Forest Top 5 Parameter

Tabel 4.20 Hasil Pengujian Model Top 5 Parameter pada Bali

Rank	Model	RMSE	MAE	R ²	Training Time
1	LSTM_Top5	90.18	76.29	0.51	144.81
2	Random Forest_Top5	91.29	77.75	0.50	1.40
3	XGBoost_Top5	92.77	79.12	0.48	0.58
4	Support Vector Regression_Top5	93.56	77.69	0.48	79.02
5	Transformer_Top5	94.63	79.68	0.46	702.0

Berdasarkan pengujian model pada Jawa Timur dengan menggunakan *Top 5 Important* parameter, diperoleh model terbaik yaitu LSTM. LSTM memiliki nilai *rmse* terendah sebesar 90.18, nilai *mae* sebesar 76.29, dan nilai R^2 sebesar 0.51 dengan *training time* selama 144.81 detik. Model *machine learning* terbaik adalah *Random Forest* dengan nilai *rmse* sebesar 91.29, nilai *mae* sebesar 77.75, dan nilai R^2 sebesar 0.50 dengan *training time* selama 1.40 detik.




Gambar 4.20 Feature Important Top 5 Parameter Random Forest pada Bali

Berdasarkan pengujian *Feature Importance*, dapat dilihat bahwa parameter *Number Of Electricity Customer*, *PDRB*, *Installed Capacity*, *Total Population*, dan *Electricity Sold* memiliki korelasi yang sangat tinggi, oleh karena itu *parameter-parameter* tersebut merupakan fitur terpenting. Parameter terpenting adalah *Number Of Electricity Customer*. Hal ini menandakan bahwa semakin banyak jumlah pelanggan listrik pada sebuah provinsi, maka akan meningkatkan konsumsi listrik masyarakat pada provinsi tersebut. Berdasarkan Gambar 4.20 dapat diketahui bahwa ketika Provinsi yang memiliki jumlah penduduk yang besar maka akan memiliki konsumsi listrik yang tinggi atau konsumsi energi listrik cenderung naik. Hal ini dikarenakan, semakin banyak populasi masyarakat, maka jumlah peralatan listrik yang digunakan seperti AC dan kipas angin akan semakin meningkat.

4.3 Pengujian Aplikasi *Dashboard* berbasis *Website*

a. Explanatory Dataset Pages



Gambar 4.21 Halaman Explanatory Dataset 1

Halaman ini menjelaskan terkait dengan *explanatory dataset* yang sudah di *preprocessing* dan di *merge* dan akan digunakan untuk prediksi model. Gambar 4.21 memberikan informasi terkait dengan grafik *demand* energi listrik di provinsi Bali pada tahun 2023. Grafik *line chart* dapat diubah tampilan nya menjadi *daily*, *weekly*, atau *monthly*. Gambar 4.21 merupakan grafik *line chart demand* energi listrik dalam frekuensi *daily*.



Gambar 4.22 Halaman Explanatory Dataset 2

Gambar 4.22 menampilkan data-data pendukung dalam memprediksi demand energi listrik berdasarkan filter input yang dipilih. Data-data pendukung meliputi data Jumlah Penduduk, Jumlah Penduduk Miskin, PDRB, Jumlah Penduduk Miskin,


Persentase Penduduk Miskin, Produksi Listrik, Listrik Terjual, dan Daya Terpasang. Pada Gambar 4.22 juga terdapat informasi terkait grafik data-data pendukung setiap bulan berdasarkan filter input yang dipilih. Terdapat *bar chart* Total Penduduk Miskin dan Jumlah Pelanggan Listrik berdasarkan filter provinsi dan tahun yang dipilih. Serta terdapat line chart jumlah penduduk dan pdrb berdasarkan provinsi dan tahun yang dipilih.



Gambar 4.23 Halaman Explanatory Dataset 3


Gambar 4.23 menampilkan *bar chart* Daya Terpasang dan Listrik Terjual yang berada pada provinsi berdasarkan filter input yang dipilih. Dalam *bar chart* menampilkan data setiap bulan berdasarkan filter input nama provinsi dan tahun yang dipilih. Dalam *bar chart* tersebut juga terdapat *legend* nilai dari setiap data pendukung/parameter pada setiap bulan. Pada Gambar 4.23 juga terdapat informasi terkait *table* dari *dataset* yang digunakan berdasarkan filter parameter yang dipilih. Tabel tersebut menampilkan data *demand* energi listrik dan data-data pendukung berdasarkan filter input nama parameter yang dipilih.

b. Modelling Pages



Gambar 4.24 Halaman Modelling Pages 1


Halaman ini menjelaskan terkait dengan *train model* yang dilakukan pada skripsi ini. Pada *pages* ini terdapat 3 *dropdown* yang berfungsi sebagai *input*, diantaranya yaitu nama provinsi, nama model, dan *train size*, serta *button train*. Ketika 3 *dropdown* tersebut telah dipilih dan *button train* telah ditekan, maka akan melakukan proses *hyperparameter tuning* dengan *grid search* pada model *machine learning* dan *optuna* pada model *deep learning*. Pada Gambar 4.24 terdapat sebuah *matrix evaluation table* yang berisi hasil pengukuran terhadap kinerja model, *matrix* tersebut berisi nilai *rmse*, *mae*, dan *r²*. Selanjutnya, terdapat juga *correlation matrix* antar parameter yang ada pada *dataset* ketika dilakukan *train model*.



Gambar 4.25 Halaman Modelling Pages 2


Pada Gambar 4.32 terdapat pula sebuah *table* yang menyimpan informasi terkait *history* dari proses *train model* yang telah dilakukan pada *modelling pages*. Tabel tersebut terdiri atas kolom nama model, *best parameter* setiap model, nilai *rmse*, *mae*, dan r^2 , serta *training time*. Pada bagian bawah halaman terdapat 3 *button* yang terdiri dari *button download csv file*, *button download excel file*, dan *button download trained model*. Sehingga, apabila telah melakukan proses *train model*, maka *table history*nya dapat disimpan dalam bentuk *file csv/excel*. Serta model yang sudah di *train* dapat disimpan juga.

c. Prediction Pages




Gambar 4.26 Halaman Prediction Pages 1

Halaman ini menjelaskan terkait dengan prediksi dan visualisasi dari *electricity demand* berdasarkan *filter input* yang dipilih. *Filter input* terdiri atas sebuah *year slider* dari tahun 2021 hingga tahun 2025 dan 3 *dropdown button* yang terdiri atas nama provinsi, nama frekuensi, dan nama model, serta sebuah *button predict*. Gambar 4.26 menampilkan grafik *line chart electricity demand* berdasarkan filter input dan *slide year* yang dipilih. Grafik yang ditampilkan pada Gambar 4.26 merupakan *electricity demand* di Bali pada tahun 2021-2023 dengan menggunakan model *Random Forest*. Dapat dilihat bahwa model *Random Forest* memiliki nilai *error metric* yaitu *rmse* 79.71, *mae* 69.02, dan *r-squared* 0.36.



Gambar 4.27 Halaman Prediction Pages 2


Gambar 4.27 menampilkan grafik *line chart* antara *actual data* dengan *modelled data* dan *data predicted electricity demand* menggunakan seluruh parameter yang ada pada *dataset* (dengan frekuensi *monthly*). *Actual data* digambarkan dengan garis berwarna merah, sedangkan *modelled data* digambarkan dengan garis berwarna biru, dan *predicted data* digambarkan dengan garis putus-putus berwarna hitam. *Data actual* yang digunakan berasal dari tahun 2021 hingga tahun 2023. *Modelled data* merupakan grafik *line chart* yang menggunakan *data actual* dari tahun 2021-2022 untuk melakukan *train model*, dan prediksi model untuk tahun 2023 tanpa melihat data *actual*/historis pada tahun 2023. Gambar 4.27 merupakan grafik *line chart electricity demand* pada provinsi Bali di tahun 2021-2023. Dibawah grafik *line chart* terdapat *matrix evaluation table* yang mengukur performa model, dimana terdiri dari *metric rmse*, *mae*, dan r^2 .



Gambar 4.28 Halaman Prediction Pages 3

Gambar 4.28 menampilkan grafik *line chart* antara *actual data* dengan *modelled data* dan *data predicted electricity demand* dengan hanya menggunakan Top 5 parameter yang memiliki *correlation matrix* tertinggi yang ada pada *dataset*. *Actual data* digambarkan dengan garis berwarna merah, sedangkan *modelled data* digambarkan dengan garis berwarna biru, dan *predicted data* digambarkan dengan garis putus-putus berwarna hitam. *Modelled data* merupakan grafik *line chart* yang menggunakan *data actual* dari tahun 2021-2022 untuk melakukan *train model*, dan prediksi model untuk tahun 2023 tanpa melihat data *actual*/historis pada tahun 2023. Dibawah grafik *line chart* terdapat *matrix evaluation table* yang mengukur performa model, dimana terdiri dari *metric rmse*, *mae*, dan r^2 .

d. Credits Pages



Gambar 4.29 Halaman Credits Pages 1

Halaman ini (Gambar 4.29) menjelaskan terkait latar belakang permasalahan, *goals*, penjelasan terkait *dashboard interaktif* dan *tools* serta *library* yang digunakan dalam proses pembuatan *dashboard aplikasi* berbasis *website*. *About* terkait dengan informasi *project* yang akan dikerjakan, model-model yang digunakan dalam *dashboard* visualisasi. Selain itu, *about* juga menjelaskan terkait dengan permasalahan yang ingin diselesaikan beserta dengan *goals* yang ingin dicapai melalui *dashboard* interaktif berbasis *website*.

Contributors



Gregorius Satia Budhi, S. T., M. T.
Petra Christian University

Dr. Gregory Satia Budhi, S.T., M.T. is a Lecturer in Informatics Departments, Petra Christian University. His research interests focus on Artificial Intelligence, Machine Learning, Data & Text Mining.



Yusak Tanoto, S. T., M. Eng.
Petra Christian University

Yusak Tanoto, S.T., M.Eng., Ph.D. is a Lecturer in Electrical Engineering Departments, Petra Christian University. His research interests focus on Energy Management System & Data Analytics in Renewable Energy.



Michael Adi Pratama
Petra Christian University

Michael Adi Pratama is Final Year Student in major Data Science and Analytics, Petra Christian University. He concentrates in Big Data and Analytics.

Library or Tools



[Python](#)



[TensorFlow](#)



[Scikit-Learn](#)



[Bootstrap](#)



[Plotly Dash](#)



[Numpy](#)



[Pandas](#)




[XGBoost](#)

Gambar 4.30 Halaman Credits Pages 2


Pada *credits pages* juga terdapat nama beserta foto *contributor* dan *author* yang terlibat dalam proses pembuatan dashboard interkatif ini. Pada bagian bawah *pages* terdapat *list tools* dan gambar *library* yang digunakan untuk membuat *dashboard* interkatif berbasis *website* ini. *Library* yang digunakan meliputi *library* untuk membangun *dashboard* visualisasi data berbasis *website* dengan *python* dan *library* untuk *train* dan *predict* model. *Library* untuk membangun *dashboard* visualisasi berbasis *website* adalah *dash* dan *bootstrap*. Sedangkan *library* untuk *train* dan *predict* model adalah *scikit-learn*, *pandas*, *tensorflow*, *numpy*, *xgboost*.

5. ANALISA DAN EVALUASI HASIL




Gambar 5.1 Line chart daily electricity demand in Bali 2021

Berdasarkan pengujian sistem diperoleh 2 model terbaik dalam memprediksi demand energi listrik regional pada Pulau Jawa dan Bali, model tersebut adalah *Random Forest* dan *LSTM*. *Random Forest* dan *LSTM* memiliki nilai *rmse*, *mae*, dan r^2 terendah dibandingkan dengan model-model lainnya. Model *Random Forest* dan *LSTM* memiliki nilai *rmse* dan *mae* yang terendah dan nilai r^2 yang tertinggi pada provinsi Bali. Saat dilakukan *prediction* untuk provinsi Bali pada tahun 2021 hingga 2023, *Random Forest* memiliki nilai *rmse* 91.36, *mae* 77.84, dan r^2 0.50 (dapat dilihat pada Tabel 4.19). Hasil pengukuran *error metric* dari model *Random Forest* pada provinsi Bali, merupakan hasil terbaik dari beberapa pengujian yang telah dilakukan dengan menggunakan seluruh fitur atau parameter. Sedangkan model *LSTM* memiliki nilai *rmse* 90.18, *mae* 76.29, dan r^2 0.51 (dapat dilihat pada Tabel 4.20) ketika dilakukan pengujian *error metric* pada provinsi Bali. Berikut hasil evaluasi dan analisa data berdasarkan pengujian sistem dan pengujian model yang telah dilakukan pada bab sebelumnya.




Gambar 5.2 Bar Chart Number of Electricity Customer in Bali 2021

Gambar 5.1 merupakan *line chart daily electricity demand* pada provinsi Bali di tahun 2021. Berdasarkan gambar tersebut, *electricity demand* pada provinsi Bali mengalami peningkatan dalam frekuensi *daily* selama 2021. Hal tersebut, disebabkan salah satunya karena pada tahun 2021 terjadi peningkatan aktivitas dan kegiatan ekonomi pasca pandemi Covid-19 yang terjadi di seluruh dunia pada tahun 2020. Pada tahun 2021, banyak tempat wisata, hotel, restaurant, bar, dan perkantoran di Bali yang mulai recovery dan kembali dibuka untuk wisatawan, sehingga menyebabkan konsumsi energi listrik di Bali meningkat pasca pandemi Covid-19. Karena hotel, tempat wisata, *restaurant*, *bar*, dan perkantoran membutuhkan *demand* energi listrik yang cukup besar dalam operasional hariannya. Hal ini di dukung juga dengan Jumlah Pelanggan Listrik di Bali pada tahun 2021 mengalami kenaikan (Gambar 5.2). Data tersebut mendukung peningkatan *electricity demand* di Bali karena semakin tinggi Jumlah Pelanggan Listrik maka akan menyebabkan nilai *electricity demand* pada provinsi tersebut akan meningkat.




Gambar 5.3 Line chart daily electricity demand in Bali 2022

Pada Gambar 5.3 dapat dilihat bahwa terjadi kenaikan *electricity demand* di Bali pada tahun 2022. Dari Gambar 5.1 dan Gambar 5.3 dapat dilihat juga bahwa ketika memasuki bulan April-Mei pada tahun 2021 dan 2022, selalu terjadi peningkatan *electricity demand* di Bali. Hal ini salah satunya disebabkan karena bulan April-Mei 2021 dan 2022 merupakan tanggal Hari Raya Idul Fitri, dimana banyak hotel, *restaurant*, *bar*, dan tempat wisata yang mengalami *full capacity/occupancy*, sehingga *electricity demand* di Bali akan mengalami lonjakan permintaan/meningkatnya *electricity demand*. Oleh karena itu, ketika memasuki bulan April-Mei, *electricity demand* di Bali selalu meningkat dibandingkan bulan Maret.



Gambar 5.4 Bar Chart Electricity Sold in Bali 2022


Pada Gambar 5.1 dan Gambar 5.3 dapat dilihat bahwa terdapat kemiripan dari kedua grafik *electricity demand* di provinsi Bali, dimana terjadi penurunan *electricity demand* di Bali ketika memasuki bulan Maret. Salah satu penyebab dari penurunan *electricity demand* di Bali pada bulan Maret adalah pada bulan tersebut terdapat hari raya Nyepi, dimana seluruh aktivitas dan kegiatan yang menggunakan listrik harus dipadamkan/dimatikan. Sehingga *electricity demand*, pada bulan Maret tentunya akan menurun, jika seluruh perangkat elektronik dan aktivitas yang menggunakan listrik, mesti dimatikan atau berhenti. *Electricity demand* di Bali tahun 2022 meningkat salah satunya disebabkan karena Jumlah Listrik terjual di Bali mengalami peningkatan setiap bulannya pada tahun 2022 (dapat dilihat pada Gambar 5.4). Karena semakin tinggi jumlah listrik terjual pada suatu provinsi, maka *electricity demand* pada provinsi tersebut juga akan meningkat.



Gambar 5.5 Line chart Electricity Demand (Weekly) All Parameter in Bali

Gambar 5.5 merupakan grafik *line chart*(weekly) dari prediksi *electricity demand* pada provinsi Bali pada tahun 2021 hingga 2025 dengan menggunakan model *LSTM* dan menggunakan seluruh parameter data pendukung. Data pendukung lainnya meliputi Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain. Garis berwarna merah merupakan grafik *actual* berdasarkan *data real electricity demand* di Bali pada tahun 2021 hingga 2023. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan.

Sedangkan grafik garis hitam merupakan prediksi dari *electricity demand* di Bali pada tahun 2024 hingga 2025 dalam frekuensi *weekly*. Pada Gambar 5.5 dapat dilihat bahwa *electricity demand* mengalami *bottom* nya pada awal minggu kedua bulan Juli-pertengahan bulan Agustus 2021,2022, dan 2023. Berdasarkan Gambar 5.5, *electricity demand* berada pada *peaknya* pada pertengahan April- awal Mei 2021,2022, dan 2023. Hal tersebut menunjukkan pola bahwa setiap memasuki bulan April-Mei, maka *electricity demand* di Bali mengalami peningkatan. Salah satu penyebabnya karena pada bulan tersebut, sedang terjadi libur lebaran/idul fitri, sehingga menyebabkan tempat wisata, hotel, restaurant, dan bar di Bali mengalami peningkatan aktivitas dan kegiatan ekonomi. Hal tersebut, turut meningkatkan *electricity demand* di Bali pada bulan tersebut.




Gambar 5.6 Line chart Electricity Demand (Weekly) Top 5 important Parameter in Bali

Gambar 5.6 merupakan grafik *line chart(weekly)* dari prediksi *electricity demand* pada provinsi Bali pada tahun 2021 hingga 2025 dengan menggunakan model *LSTM* dan hanya menggunakan 5 parameter data pendukung yang memiliki *correlation matrix* tertinggi. Data pendukung lainnya meliputi Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain. Garis berwarna merah merupakan grafik *actual* berdasarkan *data real electricity demand* di Bali pada tahun 2021 hingga 2023. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan.

Sedangkan grafik garis hitam merupakan prediksi dari *electricity demand* di Bali pada tahun 2024 hingga 2025 dalam frekuensi *weekly*. Pada Gambar 5.6 dapat dilihat bahwa *electricity demand* mengalami *bottom* nya pada awal minggu kedua bulan Juli-pertengahan bulan Agustus tahun 2021,2022, dan 2023. Berdasarkan Gambar 5.5, *electricity demand* berada pada *peaknya* pada pertengahan bulan April- awal Mei tahun 2021,2022, dan 2023. Hal tersebut menunjukkan pola bahwa setiap memasuki bulan April-Mei, maka *electricity demand* di Bali mengalami peningkatan. Salah satu penyebabnya karena pada bulan tersebut, sedang terjadi libur lebaran/idul fitri, sehingga menyebabkan tempat wisata, hotel, restaurant, dan bar di Bali mengalami peningkatan aktivitas dan kegiatan ekonomi. Hal tersebut, turut meningkatkan *electricity demand* di Bali pada bulan tersebut. Karena pada musim libur lebaran, tempat wisata, hotel, restaurant, dan bar mengalami *full capacity* atau ketersediannya mencapai 100%, sehingga menyebabkan *electricity demand* di Bali mengalami lonjakan. Grafik *line chart electricity demand* pada Gambar 5.5 dan Gambar 5.6 memiliki pola grafik yang mirip, hanya saja Gambar 5.5 memiliki grafik prediksi demand


listrik pada tahun 2024-2025 yang lebih baik dibandingkan Gambar 5.6. Karena grafik prediksi *electricity demand* pada Gambar 5.6 cenderung menurun, dan model tidak mampu menangkap pola *electricity demand* yang ada pada tahun 2021-2023. Sehingga hasil prediksi demand energi listrik pada Gambar 5.6 menjadi buruk.




Gambar 5.7 Line chart daily electricity demand in Jakarta-Banten 2021

Gambar 5.7 merupakan *line chart daily electricity demand* pada provinsi Jakarta-Banten di tahun 2021. Berdasarkan gambar tersebut, *electricity demand* pada provinsi Jakarta-Banten tidak terlalu mengalami banyak peningkatan *electricity demand* selama 2021. Dari Gambar 5.7, dapat dilihat bahwa selama tahun 2021, *electricity demand* di Jakarta-Banten mengalami penurunan/*bottom* pada tanggal 13-14 Mei 2021. Hal ini disebabkan karena pada bulan tersebut sedang terjadi libur idul fitri/lebaran. Hal tersebut, menyebabkan banyak perusahaan dan pabrik-pabrik yang berhenti beroperasi dan memproduksi, sehingga *electricity demand* di Jakarta pada bulan Mei mengalami penurunan. Data tersebut juga didukung dengan Jumlah Penduduk Miskin di Jakarta pada tahun 2021, yang tidak mengalami penurunan yang signifikan (Gambar 5.8). Berdasarkan Gambar 5.8 dapat dilihat bahwa Total penduduk miskin di Jakarta-Banten pada Januari 2021 bernilai 677.240 jiwa, sedangkan di akhir tahun 2021 Total penduduk miskin di Jakarta-Banten mencapai 675.285. Hal ini berarti, Total penduduk miskin selama tahun 2021 hanya berkurang 1955 jiwa, atau hanya menurun 0.28% sepanjang tahun 2021.

Bar Chart Total Poor Population in Selected Province in Selected Year



Gambar 5.8 Bar Chart Total Poor Population in Jakarta-Banten 2021




Gambar 5.9 Line chart daily electricity demand in Jakarta-Banten 2022

Pada Gambar 5.9 dapat dilihat bahwa *electricity demand* di Jakarta-Banten pada tahun 2022 tidak mengalami peningkatan yang cukup signifikan. Dari Gambar 5.7 dan Gambar 5.9 dapat dilihat juga bahwa ketika memasuki awal bulan Mei pada tahun 2021 dan 2022, selalu terjadi penurunan *electricity demand* di Jakarta-Banten. Hal ini salah satunya disebabkan karena bulan pada bulan Mei tahun 2021 dan 2022 terdapat perayaan Hari Raya Idul Fitri, dimana banyak perusahaan, perkantoran, dan pabrik-pabrik yang berhenti beroperasi dan bereproduksi. Sehingga, menyebabkan *electricity demand* di Jakarta-Banten pada bulan Mei mengalami penurunan. Oleh karena itu, ketika memasuki akhir bulan April- awal bulan Mei, *electricity demand* di Jakarta-Banten selalu mengalami penurunan dibandingkan bulan sebelumnya.


Bar Chart Number Of Electricity Customer in Selected Province in Selected Year

Number of Electricity Customer (Monthly) in Jakarta-Banten in (2022)



Gambar 5.10 Bar Chart Number of Electricity Customer in Jakarta-Banten 2022

Pada Gambar 5.7 dan Gambar 5.9 dapat dilihat bahwa terdapat kemiripan pola dari kedua grafik *electricity demand* di provinsi Jakarta-Banten, dimana terjadi penurunan *electricity demand* di Jakarta-Banten ketika memasuki bulan Mei. Salah satu penyebab dari penurunan *electricity demand* di Jakarta-Banten pada bulan Mei adalah pada bulan tersebut terdapat hari raya Idul Fitri/lebaran, dimana seluruh perkantoran, perusahaan, dan pabrik-pabrik yang banyak menggunakan energi listrik terpaksa berhenti beroperasi dan berproduksi, karena hari libur. Sehingga *electricity demand*, pada bulan Mei tentunya akan menurun, jika seluruh perkantoran dan pabrik-pabrik, mesti berhenti beroperasi dan berproduksi karena hari libur. *Electricity demand* di Jakarta-Banten tahun 2022 tidak mengalami peningkatan signifikan salah satunya disebabkan karena Jumlah Pelanggan Listrik di Jakarta-Banten tidak mengalami peningkatan yang cukup signifikan (dapat dilihat pada Gambar 5.10). Pada awal tahun 2022, Jumlah Pelanggan Listrik di Jakarta-Banten mencapai 4,29 juta pelanggan. Sedangkan pada akhir tahun 2022, Jumlah Pelanggan Listrik di Jakarta-Banten mencapai 4,44 juta pelanggan. Artinya, selama tahun 2022, Jumlah Pelanggan Listrik di Jakarta-Banten hanya mengalami peningkatan sebesar 150 ribu pelanggan saja.




Gambar 5.11 Line chart Electricity Demand (Monthly) All Parameter in Jakarta-Banten

Gambar 5.11 merupakan grafik *line chart(monthly)* dari prediksi *electricity demand* pada provinsi Jakarta-Banten pada tahun 2021 hingga 2023 dengan menggunakan model *LSTM* dan menggunakan seluruh parameter data pendukung. Data pendukung lainnya meliputi Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain. Garis berwarna merah merupakan grafik *actual* berdasarkan *data real electricity demand* di Jakarta-Banten pada tahun 2021 hingga 2023. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* pada tahun 2021-2022 berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan.

Sedangkan grafik garis hitam merupakan prediksi dari *electricity demand* di Jakarta-Banten pada tahun 2023 dalam frekuensi *weekly*. Pada Gambar 5.11 dapat dilihat bahwa *electricity demand* mengalami *bottom* nya pada bulan Mei tahun 2021 dan 2022. Penurunan *electricity demand* pada provinsi Jakarta-Banten terjadi pada bulan Mei disebabkan karena pada Mei tahun 2021 dan 2022 sedang terjadi libur lebaran/nasional. Hari raya Idul fitri/lebaran pada tahun 2021 dan 2022 tepat jatuh pada bulan Mei. Hal ini menyebabkan, banyak perusahaan dan pabrik yang berhenti beroperasi dan memproduksi, sehingga *electricity demand* pada Jakarta-Banten mengalami penurunan. Berdasarkan Gambar 5.11, *electricity demand* berada pada *peak*nya pada bulan Oktober 2021 dan 2022. Hal tersebut menunjukkan pola bahwa setiap memasuki bulan Mei, maka *electricity demand* di Jakarta-Banten akan mengalami penurunan. Salah satu penyebabnya karena pada bulan tersebut, sedang terjadi libur lebaran/idul fitri, sehingga menyebabkan banyak perkantoran, pabrik,

dan perusahaan yang berhenti beroperasi dan memproduksi. Hal tersebut, turut menurunkan *electricity demand* di Jakarta-Banten pada bulan tersebut.




Gambar 5.12 Line chart Electricity Demand (Monthly) Top 5 Important Parameter in Jakarta-Banten

Gambar 5.12 merupakan grafik *line chart(monthly)* dari prediksi *electricity demand* pada provinsi Jakarta-Banten pada tahun 2021 hingga 2023 dengan menggunakan model *LSTM* dan hanya memakai 5 parameter data pendukung yang memiliki *correlation matrix* tertinggi. Data pendukung lainnya seperti Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain. Garis berwarna merah merupakan grafik *actual* berdasarkan *data real electricity demand* di Jakarta pada tahun 2021 hingga 2023. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* pada tahun 2021-2022 berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan.

Sedangkan grafik garis hitam merupakan prediksi dari *electricity demand* di Jakarta-Banten pada tahun 2023 dalam frekuensi *weekly*. Pada Gambar 5.12 dapat dilihat bahwa *electricity demand* mengalami *bottom* nya pada bulan Mei tahun 2021 dan 2022. Penurunan *electricity demand* pada provinsi Jakarta-Banten terjadi pada bulan Mei disebabkan karena pada Mei tahun 2021 dan 2022 sedang terjadi libur lebaran/nasional. Hari raya Idul fitri/lebaran pada tahun 2021 dan 2022 tepat jatuh pada bulan Mei. Hal ini menyebabkan, banyak perusahaan dan pabrik yang berhenti beroperasi dan memproduksi, sehingga *electricity demand* pada Jakarta-Banten mengalami penurunan. Berdasarkan Gambar 5.12, *electricity demand* berada pada *peaknya* pada bulan Oktober 2021 dan 2022. Hal tersebut menunjukan pola bahwa setiap memasuki bulan Mei, maka *electricity demand* di Jakarta-Banten akan mengalami penurunan. Salah satu penyebabnya karena pada bulan tersebut,

sedang terjadi libur lebaran/idul fitri, sehingga menyebabkan banyak perkantoran, pabrik, dan perusahaan yang berhenti beroperasi dan memproduksi. Hal tersebut, turut menurunkan *electricity demand* di Jakarta-Banten pada bulan tersebut.

Grafik pada Gambar 5.11 memiliki pattern yang sama seperti grafik *line chart* pada Gambar 5.12, hanya saja parameter yang digunakan untuk *training model* dan prediksi *electricity demand* berbeda jumlahnya. Grafik pada gambar 5.11 dan gambar 5.12, masih belum mampu memprediksi demand energi listrik di provinsi Jakarta-Banten dengan hasil yang akurat. Karena jika dilihat, garis grafik prediksi nya sangat berbeda, dengan garis demand listrik aktual pada tahun 2021-2022. Hal ini didukung juga dengan nilai R-Squared model yang menunjukkan hanya 0.11 baik pada Gambar 5.11 maupun Gambar 5.12, hal ini menyebabkan data historis demand listrik yang ada, tidak cukup kuat untuk membantu prediksi demand listrik di masa depan.




Gambar 5.13 Line chart electricity demand in Jawa Barat 2021

Gambar 5.13 merupakan *line chart weekly electricity demand* pada provinsi Jawa Barat di tahun 2021. Berdasarkan gambar tersebut, *electricity demand* pada provinsi Jawa Barat mengalami peningkatan dalam frekuensi *weekly* selama 2021. Hal tersebut, disebabkan salah satunya karena pada tahun 2021 terjadi peningkatan aktivitas dan kegiatan ekonomi pasca pandemi Covid-19 yang terjadi di seluruh dunia pada tahun 2020. Pada tahun 2021, banyak perkantoran dan pabrik-pabrik di Jawa Barat yang mulai recovery dan kembali beroperasi dan memproduksi, sehingga menyebabkan konsumsi energi listrik di Jawa Barat meningkat pasca pandemi Covid-19. Karena pabrik-pabrik dan perkantoran membutuhkan *demand* energi listrik yang cukup besar dalam operasional dan produksinya. Hal ini didukung juga dengan data Listrik Terjual di Jawa Barat pada tahun 2021 yang mengalami kenaikan (Gambar 5.14).


Data tersebut mendukung peningkatan *electricity demand* di Jawa Barat karena semakin tinggi Listrik Terjual maka akan menyebabkan nilai *electricity demand* pada provinsi tersebut

akan meningkat. Karena listrik yang terjual pada provinsi tersebut akan dikonsumsi atau dipakai oleh masyarakat/konsumen pada provinsi tersebut. Berdasarkan Gambar 5.14, Listrik Terjual di Jawa Barat per Januari 2021 mencapai 49,88 juta MW. Kemudian per akhir Desember 2021, Listrik Terjual di Jawa Barat mencapai 53,31 juta MW. Hal ini menandakan terjadi peningkatan sebesar 3.43 juta MW Listrik Terjual pada Jawa Barat di tahun 2021.

Bar Chart Electricity Sold in Selected Province in Selected Year



Gambar 5.14 Bar chart Electricity Sold in Jawa Barat 2021




Gambar 5.15 Line chart *weekly electricity demand* in Jawa Barat 2022


Pada Gambar 5.15 dapat dilihat bahwa *electricity demand* di Bali pada tahun 2022 tidak mengalami kenaikan yang cukup signifikan. Dari Gambar 5.13 dan Gambar 5.15 dapat dilihat juga bahwa ketika memasuki bulan Mei pada tahun 2021 dan 2022, selalu terjadi penurunan *electricity demand* di Jawa Barat. Hal ini salah satunya disebabkan karena bulan Mei 2021 dan 2022 merupakan tanggal Hari Raya Idul Fitri, dimana banyak perkantoran, perusahaan, dan pabrik-pabrik yang berhenti beroperasi dan berproduksi, sehingga *electricity demand* di Jawa Barat akan mengalami penurunan *electricity demand*. Oleh karena itu, ketika memasuki bulan Mei, *electricity demand* di Jawa Barat selalu mengalami penurunan dibandingkan dengan bulan sebelumnya. *Electricity demand* di Jawa Barat pada tahun 2022

tidak mengalami peningkatan yang cukup signifikan salah satunya disebabkan karena Jumlah Pelanggan Listrik di Jawa Barat tidak mengalami peningkatan yang tinggi/besar. Hal ini dapat dilihat pada Gambar 5.16, dimana Jumlah Pelanggan Listrik di Jawa Barat per Januari 2022 mencapai 15,76 juta pelanggan listrik. Sedangkan Jumlah Pelanggan Listrik di Jawa Barat per Desember 2022 mencapai 16,31 juta pelanggan listrik. Hal ini menunjukkan bahwa selama 2022, Jumlah Pelanggan Listrik di Jawa Barat hanya bertambah sebesar 544.554 pelanggan listrik.

Bar Chart Number Of Electricity Customer in Selected Province in Selected Year



Gambar 5.16 Bar chart Number of Electricity Customer in Jawa Barat 2022



Gambar 5.17 Line chart Electricity Demand (Weekly) All Parameter in Jawa Barat 2021-2025

Gambar 5.17 merupakan grafik *line chart(weekly)* dari prediksi *electricity demand* pada provinsi Jawa Barat pada tahun 2021 hingga 2025 dengan menggunakan model *LSTM* dan memakai seluruh data parameter pendukung (Gambar 5.17). Garis berwarna merah

merupakan grafik *actual* berdasarkan *data real electricity demand* di Jawa Barat pada tahun 2021 hingga 2023. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan. Sedangkan grafik garis hitam merupakan prediksi dari *electricity demand* di Jawa Barat pada tahun 2024-2025 dalam frekuensi *weekly*. Data pendukung lainnya seperti Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain. Pada Gambar 5.17 dapat dilihat juga bahwa *electricity demand* mengalami penurunan pada setiap memasuki bulan Mei setiap tahunnya. Hal ini diakibatkan karena pada bulan tersebut memasuki masa libur idul fitri atau lebaran, sehingga banyak pabrik, perusahaan dan perkantoran di Jawa Barat yang berhenti beroperasi dan memproduksi yang mengakibatkan *electricity demand* di Jawa Barat mengalami penurunan. Berdasarkan Gambar 5.17, *electricity demand* berada pada *peaknya* pada setiap memasuki bulan Oktober tiap tahunnya. Detail mengenai gambar grafik *line chart prediction electricity demand* pada provinsi lainnya dapat dilihat pada Lampiran 6 Analisa dan Evaluasi Hasil.

6. KESIMPULAN DAN SARAN

6.1 Kesimpulan

Dari hasil pengujian sistem yang telah dilakukan, didapatkan kesimpulan sebagai berikut:

1. Parameter yang dapat digunakan dalam membentuk model prediksi *demand* energi listrik regional meliputi: Jumlah Penduduk, PDRB, Listrik Terjual, Daya Terpasang, dan Jumlah Pelanggan Listrik.
2. Parameter Jumlah Penduduk dan PDRB sangat berpengaruh dalam prediksi *demand* energi listrik regional. Pengaruh parameter jumlah penduduk cukup tinggi, dimana semakin banyak jumlah penduduk maka *demand* energi listrik juga akan meningkat. Sedangkan parameter PDRB memiliki pengaruh yang cukup tinggi karena semakin tinggi PDRB pada suatu provinsi maka konsumsi listrik masyarakat akan meningkat.
3. Parameter Listrik Terjual dan Daya Terpasang juga berpengaruh dalam memprediksi *demand* energi listrik, karena semakin tinggi nilai listrik terjual dan daya terpasang maka energi listrik yang digunakan masyarakat juga akan meningkat. Hal tersebut juga berlaku pada parameter Jumlah Pelanggan Listrik, dimana semakin tinggi Jumlah Pelanggan Listrik pada suatu provinsi, maka akan meningkatkan konsumsi energi listrik pada provinsi tersebut. Karena semakin banyak jumlah pelanggan listrik, otomatis energi listrik yang dibutuhkan akan meningkat atau bertambah.
4. Performa model *machine learning* dan *deep learning* akan diuji dengan *error metric* meliputi *rmse*, *mae*, dan r^2 .
5. Model LSTM merupakan model terbaik dalam memprediksi *demand* energi listrik regional pada Pulau Jawa dan Bali karena memiliki nilai *rmse* dan *mae* terendah, serta nilai r^2 terbaik. LSTM memiliki nilai *rmse* 90.18, *mae* 76.29, dan r^2 0.51 pada saat pengujian di provinsi Bali (dapat dilihat pada Tabel 4.20).

6.2 Saran

Berikut saran untuk penelitian selanjutnya agar dapat meningkatkan hasil penelitian adalah sebagai berikut:

1. *Dataset* yang digunakan untuk proses *training and evaluation* model menggunakan *dataset* dengan jangka waktu yang lebih lama (5-10 tahun).

2. Mencoba beberapa model *machine learning* maupun *deep learning* lainnya, yang berbasis *time series prediction*.
3. Menggunakan data pendukung (seperti Jumlah penduduk, Jumlah pelanggan listrik, Jumlah penduduk miskin, dan data pendukung lainnya) dalam format data *weekly* atau *daily*.

DAFTAR REFERENSI

- Adimanggala, D. (2023, March 29). *Algoritme XGBoost dengan contohnya*. <https://dindaadi.medium.com/algoritme-xgboost-dengan-contohnya-28e958a3e2f6>
- Badan Pusat Statistik Provinsi Bali. (2023). *Jumlah listrik terjual menurut area pelayanan di Provinsi Bali*. <https://bali.bps.go.id/id/statistics-table/2/OTMjMg==/jumlah-listrik-terjual-menurut-area-pelayanan-di-provinsi-bali.html>
- Badan Pusat Statistik Provinsi Jakarta. (2023, October 23). *Jumlah penduduk miskin (ribu jiwa) menurut kabupaten/kota*. <https://jakarta.bps.go.id/id/statistics-table/2/OTA4IzI%3D/jumlah-penduduk-miskin--ribu-jiwa--menurut-kabupaten-kota.html>
- Badan Pusat Statistik Provinsi Jawa Tengah. (2023). *Jumlah dan persentase penduduk miskin menurut kabupaten/kota di Provinsi Jawa Tengah*. <https://jateng.bps.go.id/id/statistics-table/3/UkVkWGJVZFNWakl6VWxKVFQwWjVWwTISZDNabVFUMdkjMw%3D%3D/jumlah-dan-persentase-penduduk-miskin-menurut-kabupaten-kota-di-provinsi-jawa-tengah--2024.html>
- Badan Pusat Statistik Provinsi Jawa Timur. (2023). *Jumlah pelanggan listrik menurut UP3 PLN*. <https://jatim.bps.go.id/id/statistics-table/2/NTcwIzI=/jumlah-pelanggan-listrik-menurut-up3-pln.html>
- Banik, R., Das, P., Ray, S., & Biswas, A. (2020). Prediction of electrical energy consumption based on machine learning technique. *Electrical Engineering*, 103(2), 909–920. <https://doi.org/10.1007/s00202-020-01126-z>
- Belete, D. M., & Huchaiah, M. D. (2021). Grid search in hyperparameter optimization of machine learning models for prediction of HIV/AIDS test results. *International Journal of Computers and Applications*, 44(9), 875–886. <https://doi.org/10.1080/1206212x.2021.1974663>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/a:1010933404324>

- Chung, H., & Shin, K. (2018). Genetic algorithm-optimized long short-term memory network for stock market prediction. *Sustainability*, 10(10), 3765. <https://doi.org/10.3390/su10103765>
- Diyono, D., Cappon, H., Kujawa-Roeleveld, K., & Keesman, K. J. (2023). Designing sustainable domestic electricity supply from renewable energy mixes: Application to Java and Bali, Indonesia. *Energies*, 16(22), 7461. <https://doi.org/10.3390/en16227461>
- Freund, Y., & Schapire, R. E. (1996). Experiments with a new boosting algorithm. *International Conference on Machine Learning*, 148–156. <https://dl.acm.org/doi/10.5555/3091696.3091715>
- Goyal, P., Pandey, S., & Jain, K. (2018). *Deep learning for natural language processing*. Apress eBooks. <https://doi.org/10.1007/978-1-4842-3685-7>
- Hsia, J., & Lin, C. (2020). Parameter selection for linear support vector regression. *IEEE Transactions on Neural Networks and Learning Systems*, 31(12), 5639–5644. <https://doi.org/10.1109/tnnls.2020.2967637>
- Jain, A., Fandango, A., & Kapoor, A. (n.d.). *Tensorflow machine learning projects*. <https://www.oreilly.com/library/view/tensorflow-machine-learning/9781789132212/d3d388ea-3e0b-4095-b01e-a0fe8cb3e575.xhtml>
- Kementerian ESDM. (2024, February 20). *Tren penjualan listrik di Indonesia terus naik, ini strategi pemerintah penuhi demand*. <https://www.esdm.go.id/id/media-center/arsip-berita/tren-penjualan-listrik-di-indonesia-terus-naik-ini-strategi-pemerintah-penuhi-demand>
- Kuncoro, H. A., dan Dalimi, R (2005). Aplikasi jaringan syaraf tiruan untuk peramalan beban tenaga listrik jangka panjang pada sistem kelistrikan di Indonesia. *Jurnal Teknologi*, 19(3), 211-217.
- Li, X., Zhong, Y., Shang, W., Zhang, X., Shan, B., & Wang, X. (2022). Total electricity consumption forecasting based on transformer time series models. *Procedia Computer Science*, 214, 312–320. <https://doi.org/10.1016/j.procs.2022.11.180>
- Manaswi, N. K. (2018). *Deep learning with applications using python*. <https://doi.org/10.1007/978-1-4842-3516-4>

- Market research reports & consulting. (2023, March 21). <https://www.globaldata.com/store/report/pt-pln-persero/>
- Müller, A. C., & Guido, S. (2016). *Introduction to machine learning with python: A guide for data scientists*. <http://cds.cern.ch/record/2229831>
- Perusahaan Listrik Negara. (2024). *Laporan statistik PLN 2023*. <https://web.pln.co.id/statics/uploads/2024/07/Laporan-Statistik-2023-Ind.pdf>
- Reddy, G. V., Aitha, L. J., Poojitha, Ch., Shreya, A. N., Reddy, D. K., & Meghana, G. Sai. (2023). Electricity consumption prediction using machine learning. *E3S Web of Conferences*, 391, 01048. <https://doi.org/10.1051/e3sconf/202339101048>
- Rifais, A. (2019). *Prediksi konsumsi energi listrik menggunakan metode jaringan syaraf tiruan recurrent di PLN APJ Salatiga*. <https://lib.unnes.ac.id/36701/>
- Sahin, B., Udeh, K., Wanik, D. W., & Cerrai, D. (2024). Predicting energy demand using machine learning: Exploring temporal and weather-related patterns, variations, and impacts. *IEEE Access*, 12, 31824–31840. <https://doi.org/10.1109/access.2024.3370442>
- Saputra, A. A., Sari, B. N., & Rozikin, C. (2024). Penerapan algoritma extreme gradient boosting (xgboost) untuk analisis risiko kredit. *Jurnal Ilmiah Wahana Pendidikan*, 10(7), 27-36. <https://doi.org/10.5281/zenodo.10960080>
- Smola, A. J., & Schölkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing*, 14(3), 199–222. <https://doi.org/10.1023/b:stco.0000035301.49549.88>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). *Attention is all you need*. <https://doi.org/10.48550/arxiv.1706.03762>
- Wang, C., Deng, C., & Wang, S. (2020). Imbalance-xgboost: Leveraging weighted and focal losses for binary label-imbalanced classification with xgboost. *Pattern Recognition Letters*, 136, 190–197. <https://doi.org/10.1016/j.patrec.2020.05.035>
- Wuryani, N., & Agustiani, S. (2021). Random forest classifier untuk deteksi penderita Covid-19 berbasis citra CT scan. *Jurnal Teknik Komputer*, 7(2), 187–193. <https://doi.org/10.31294/jtk.v7i2.10468>

Yulianti, S. E. H., Soesanto, N. O., & Sukmawaty, N. Y. (2022). Penerapan metode extreme gradient boosting (xgboost) pada klasifikasi nasabah kartu kredit. *Journal of Mathematics Theory and Application*, 4(1), 21–26.
<https://doi.org/10.31605/jomta.v4i1.1792>

LAMPIRAN

Lampiran 1 Tabel *Hyperparameter Tuning Model Random Forest*

Tabel 10 Parameter Terbaik Random Forest pada Provinsi Jakarta-Banten

Ran k	Parameter	RMSE	MAE	R ²
1	'max_depth': 10, 'max_features': 0.8, 'min_samples_leaf': 500, 'min_samples_split': 2, 'n_estimators': 30	1117.62	945.00	0.08
2	'max_depth': 8, 'max_features': 0.8, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 30	1117.62	945.00	0.08
3	'max_depth': 8, 'max_features': 0.8, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 30	1117.62	945.00	0.08
4	'max_depth': 8, 'max_features': 0.8, 'min_samples_leaf': 500, 'min_samples_split': 2, 'n_estimators': 30	1117.62	945.00	0.08
5	'max_depth': 10, 'max_features': 0.8, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 30	1117.62	945.00	0.08
6	'max_depth': 10, 'max_features': 0.8, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 30	1117.62	945.00	0.08
7	'max_depth': 8, 'max_features': 1.0, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 30	1117.67	945.13	0.08
8	'max_depth': 10, 'max_features': 1.0, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 30	1117.67	945.13	0.08
9	'max_depth': 10, 'max_features': 1.0, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 30	1117.67	945.13	0.08
10	'max_depth': 8, 'max_features': 1.0, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 30	1117.67	945.13	0.08

Tabel 10 Parameter Terbaik Model Random Forest pada Provinsi Jawa Barat

Ran k	Parameter	RMSE	MAE	R ²
1	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 450, 'min_samples_split': 5, 'n_estimators': 200	579.29	470.06	0.06
2	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 450, 'min_samples_split': 2, 'n_estimators': 200	579.29	470.06	0.06
3	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 450, 'min_samples_split': 10, 'n_estimators': 200	579.29	470.06	0.06
4	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 450, 'min_samples_split': 2, 'n_estimators': 150	579.30	470.07	0.06
5	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 450, 'min_samples_split': 5, 'n_estimators': 150	579.30	470.07	0.06
6	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 450, 'min_samples_split': 10, 'n_estimators': 150	579.30	470.07	0.06
7	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 500, 'min_samples_split': 2, 'n_estimators': 150	579.30	470.11	0.06
8	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 150	579.30	470.11	0.06

9	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 150	579.30	470.11	0.06
10	'max_depth': 3, 'max_features': 0.2, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 200	579.35	470.15	0.06

Tabel 10 Parameter Terbaik Model Random Forest pada Provinsi Central Java-DIY

Ran k	Parameter	RMSE	MAE	R ²
1	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 150, 'min_samples_split': 10, 'n_estimators': 50	448.72	378.95	0.03
2	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 150, 'min_samples_split': 2, 'n_estimators': 50	448.72	378.95	0.03
3	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 120, 'min_samples_split': 5, 'n_estimators': 50	448.72	378.95	0.03
4	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 120, 'min_samples_split': 2, 'n_estimators': 50	448.72	378.95	0.03
5	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 140, 'min_samples_split': 5, 'n_estimators': 50	448.72	378.95	0.03
6	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 140, 'min_samples_split': 10, 'n_estimators': 50	448.72	378.95	0.03
7	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 120, 'min_samples_split': 10, 'n_estimators': 50	448.72	378.95	0.03
8	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 140, 'min_samples_split': 2, 'n_estimators': 50	448.72	378.95	0.03
9	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 150, 'min_samples_split': 5, 'n_estimators': 50	448.72	378.95	0.03
10	'max_depth': 3, 'max_features': 0.8, 'min_samples_leaf': 140, 'min_samples_split': 2, 'n_estimators': 50	448.74	378.96	0.03

Tabel 10 Parameter Terbaik Model Random Forest pada Provinsi East Java

Ran k	Parameter	RMSE	MAE	R ²
1	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 500, 'min_samples_split': 2, 'n_estimators': 100	524.11	435.51	0.05
2	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 100	524.11	435.51	0.05
3	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 100	524.11	435.51	0.05
4	'max_depth': 3, 'max_features': 0.3, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 100	524.12	435.51	0.05
5	'max_depth': 3, 'max_features': 0.3, 'min_samples_leaf': 500, 'min_samples_split': 2, 'n_estimators': 100	524.12	435.51	0.05
6	'max_depth': 3, 'max_features': 0.3, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 100	524.12	435.51	0.05
7	'max_depth': 3, 'max_features': 0.5, 'min_samples_leaf': 500, 'min_samples_split': 2, 'n_estimators': 100	524.15	435.53	0.05
8	'max_depth': 3, 'max_features': 0.5, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 100	524.15	435.53	0.05
9	'max_depth': 3, 'max_features': 0.5, 'min_samples_leaf': 500, 'min_samples_split': 5, 'n_estimators': 100	524.15	435.53	0.05
10	'max_depth': 3, 'max_features': 1.0, 'min_samples_leaf': 500, 'min_samples_split': 10, 'n_estimators': 150	524.29	435.64	0.05

Lampiran 2 Tabel *Hyperparameter Tuning Model XGBoost*

Tabel 10 Parameter Terbaik Model XGBoost pada Provinsi Jakarta-Banten

Ran k	Parameter	RMSE	MAE	R ²
1	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.5	1121.12	945.26	0.07
2	'colsample_bytree': 0.4, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.5	1121.22	945.28	0.07
3	'colsample_bytree': 0.3, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.5	1121.24	945.28	0.07
4	'colsample_bytree': 0.3, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 300, 'subsample': 0.4	1121.37	945.04	0.07
5	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 200, 'subsample': 0.5	1121.43	945.70	0.07
6	'colsample_bytree': 0.4, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 300, 'subsample': 0.4	1121.44	945.07	0.07
7	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 300, 'subsample': 0.4	1121.48	945.14	0.07
8	'colsample_bytree': 0.4, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 200, 'subsample': 0.5	1121.50	945.70	0.07
9	'colsample_bytree': 0.3, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 200, 'subsample': 0.5	1121.56	945.73	0.07
10	'colsample_bytree': 0.4, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 200, 'subsample': 0.4	1121.73	945.79	0.07

Tabel 10 Parameter Terbaik Model XGBoost pada Provinsi Jawa Barat

Ran k	Parameter	RMSE	MAE	R ²
1	'colsample_bytree': 0.7, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.3	580.99	472.53	0.05
2	'colsample_bytree': 0.7, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 200, 'subsample': 0.3	581.08	472.14	0.05
3	'colsample_bytree': 0.7, 'learning_rate': 0.02, 'max_depth': 3, 'n_estimators': 150, 'subsample': 0.3	581.17	473.73	0.05
4	'colsample_bytree': 0.7, 'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 250, 'subsample': 0.3	581.19	473.42	0.05
5	'colsample_bytree': 0.5, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 200, 'subsample': 0.3	581.19	472.25	0.05
6	'colsample_bytree': 0.7, 'learning_rate': 0.02, 'max_depth': 3, 'n_estimators': 150, 'subsample': 0.5	581.33	474.04	0.05
7	'colsample_bytree': 0.3, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 200, 'subsample': 0.3	581.38	472.61	0.05
8	'colsample_bytree': 0.7, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 150, 'subsample': 0.3	581.49	471.92	0.05
9	'colsample_bytree': 0.5, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.3	581.55	473.00	0.05
10	'colsample_bytree': 0.7, 'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 200, 'subsample': 0.3	581.68	473.52	0.05

Tabel 10 Parameter Terbaik Model XGBoost pada Provinsi Central Java-DIY

Ran k	Parameter	RMSE	MAE	R ²
1	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 260, 'subsample': 0.3	452.22	380.98	0.02
2	'colsample_bytree': 0.6, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 260, 'subsample': 0.3	452.22	380.98	0.02
3	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 260, 'subsample': 0.4	452.23	381.01	0.02
4	'colsample_bytree': 0.6, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 260, 'subsample': 0.4	452.23	381.01	0.02
5	'colsample_bytree': 0.6, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.4	452.25	381.01	0.02
6	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.4	452.25	381.01	0.02
7	'colsample_bytree': 0.6, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 270, 'subsample': 0.3	452.25	381.00	0.02
8	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 270, 'subsample': 0.3	452.25	381.00	0.02
9	'colsample_bytree': 0.6, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.3	452.25	381.00	0.02
10	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.3	452.25	381.00	0.02

Tabel 10 Parameter Terbaik Model XGBoost pada Provinsi East Java

Ran k	Parameter	RMSE	MAE	R ²
1	'colsample_bytree': 0.3, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 150, 'subsample': 0.3	527.05	437.45	0.04
2	'colsample_bytree': 0.5, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 150, 'subsample': 0.5	527.14	437.56	0.04
3	'colsample_bytree': 0.5, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 150, 'subsample': 0.3	527.14	437.50	0.04
4	'colsample_bytree': 0.3, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 150, 'subsample': 0.5	527.15	437.54	0.04
5	'colsample_bytree': 0.7, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 150, 'subsample': 0.5	527.15	437.56	0.04
6	'colsample_bytree': 0.3, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.3	527.19	437.38	0.04
7	'colsample_bytree': 0.7, 'learning_rate': 0.02, 'max_depth': 2, 'n_estimators': 150, 'subsample': 0.3	527.24	437.57	0.04
8	'colsample_bytree': 0.7, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.3	527.26	437.41	0.04
9	'colsample_bytree': 0.5, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.3	527.28	437.42	0.04
10	'colsample_bytree': 0.3, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 250, 'subsample': 0.7	527.31	437.45	0.04

Lampiran 3 Tabel *Hyperparameter Tuning Model Support Vector Regression*

Tabel 10 Parameter Terbaik Model SVR pada Provinsi Jakarta-Banten

Ran k	Parameter	RMSE	MAE	R ²
1	'C': 500, 'epsilon': 500, 'kernel': 'linear'	1130.57	953.04	0.06

2	'C': 200, 'epsilon': 500, 'kernel': 'linear'	1130.59	953.05	0.06
3	'C': 100, 'epsilon': 500, 'kernel': 'linear'	1130.75	953.13	0.06
4	'C': 100, 'epsilon': 500, 'kernel': 'rbf'	1135.99	955.79	0.05
5	'C': 200, 'epsilon': 500, 'kernel': 'rbf'	1136.73	956.31	0.04
6	'C': 500, 'epsilon': 500, 'kernel': 'rbf'	1137.68	956.95	0.04
7	'C': 200, 'epsilon': 200, 'kernel': 'linear'	1137.70	954.51	0.04
8	'C': 500, 'epsilon': 200, 'kernel': 'linear'	1137.74	954.56	0.04
9	'C': 100, 'epsilon': 200, 'kernel': 'linear'	1137.96	954.63	0.04
10	'C': 500, 'epsilon': 100, 'kernel': 'linear'	1139.47	955.09	0.04

Tabel 10 Parameter Terbaik Model SVR pada Provinsi Jawa Barat

Ran k	Parameter	RMSE	MAE	R ²
1	'C': 1, 'epsilon': 1, 'kernel': 'linear'	566.57	460.79	0.04
2	'C': 1, 'epsilon': 0.1, 'kernel': 'linear'	566.58	460.80	0.04
3	'C': 1, 'epsilon': 0.01, 'kernel': 'linear'	566.59	460.80	0.04
4	'C': 0.1, 'epsilon': 1, 'kernel': 'linear'	567.09	460.85	0.04
5	'C': 0.1, 'epsilon': 0.1, 'kernel': 'linear'	567.12	460.86	0.04
6	'C': 0.1, 'epsilon': 0.01, 'kernel': 'linear'	567.13	460.87	0.04
7	'C': 0.01, 'epsilon': 1, 'kernel': 'linear'	574.30	466.25	0.01
8	'C': 0.01, 'epsilon': 0.1, 'kernel': 'linear'	574.32	466.26	0.01
9	'C': 0.01, 'epsilon': 0.01, 'kernel': 'linear'	574.33	466.27	0.01
10	'C': 1, 'epsilon': 0.01, 'kernel': 'rbf'	575.76	468.93	0.01

Tabel 10 Parameter Terbaik Model SVR pada Provinsi Central Java-DIY

Ran k	Parameter	RMSE	MAE	R ²
1	'C': 2, 'epsilon': 0.1, 'kernel': 'linear'	447.82	378.48	0.03
2	'C': 2, 'epsilon': 0.01, 'kernel': 'linear'	447.83	378.48	0.03
3	'C': 3, 'epsilon': 0.1, 'kernel': 'linear'	447.83	378.48	0.03
4	'C': 3, 'epsilon': 0.01, 'kernel': 'linear'	447.83	378.48	0.03
5	'C': 3, 'epsilon': 0.3, 'kernel': 'linear'	447.84	378.49	0.03
6	'C': 2, 'epsilon': 0.3, 'kernel': 'linear'	447.84	378.49	0.03
7	'C': 4, 'epsilon': 0.3, 'kernel': 'linear'	447.99	378.58	0.03
8	'C': 4, 'epsilon': 0.1, 'kernel': 'linear'	448.00	378.58	0.03
9	'C': 4, 'epsilon': 0.01, 'kernel': 'linear'	448.00	378.58	0.03
10	'C': 4, 'epsilon': 0.3, 'kernel': 'rbf'	450.88	380.16	0.01

Tabel 10 Parameter Terbaik Model SVR pada Provinsi East Java

Ran k	Parameter	RMSE	MAE	R ²
1	'C': 4, 'epsilon': 0.1, 'kernel': 'linear'	534.42	443.10	0.01
2	'C': 4, 'epsilon': 0.01, 'kernel': 'linear'	534.43	443.10	0.01
3	'C': 4, 'epsilon': 0.3, 'kernel': 'linear'	534.43	443.10	0.01
4	'C': 3, 'epsilon': 0.3, 'kernel': 'linear'	534.45	443.08	0.01
5	'C': 3, 'epsilon': 0.1, 'kernel': 'linear'	534.47	443.09	0.01
6	'C': 3, 'epsilon': 0.01, 'kernel': 'linear'	534.47	443.10	0.01
7	'C': 2, 'epsilon': 0.3, 'kernel': 'linear'	534.53	443.08	0.01
8	'C': 2, 'epsilon': 0.1, 'kernel': 'linear'	534.55	443.10	0.01
9	'C': 2, 'epsilon': 0.01, 'kernel': 'linear'	534.56	443.10	0.01
10	'C': 4, 'epsilon': 0.1, 'kernel': 'rbf'	537.46	445.35	0.01

Lampiran 4 Tabel *Hyperparameter Tuning Model LSTM*

Tabel 10 Parameter Terbaik Model LSTM pada Provinsi Jakarta-Banten

Trial	Parameter	loss	val_loss
1	'num_units': 80, 'learning_rate': 0.005, 'batch_size': 128	1364578.50	1151336.25
2	'num_units': 26, 'learning_rate': 0.002, 'batch_size': 32	1313923.75	1150971.50
3	'num_units': 35, 'learning_rate': 0.007, 'batch_size': 64	1369706.50	1150873.87
4	'num_units': 68, 'learning_rate': 0.031, 'batch_size': 128	1293740.00	1157195.62
5	'num_units': 24, 'learning_rate': 0.003, 'batch_size': 64	1357506.12	1148415.87
6	'num_units': 36, 'learning_rate': 0.051, 'batch_size': 32	1361668.12	1156268.625
7	'num_units': 123, 'learning_rate': 0.002, 'batch_size': 32	1336791.25	1153758.50
8	'num_units': 49, 'learning_rate': 0.182, 'batch_size': 32	40012996.00	39859540.00
9	'num_units': 37, 'learning_rate': 0.0469, 'batch_size': 32	1455552.00	1151435.00
10	'num_units': 19, 'learning_rate': 0.092, 'batch_size': 16	1518536.50	1173254.37

Tabel 10 Parameter Terbaik Model LSTM pada Provinsi Jawa Barat

Trial	Parameter	loss	val_loss
1	'num_units': 10, 'learning_rate': 0.007, 'batch_size': 128	331165.31	399161.56
2	'num_units': 111, 'learning_rate': 0.003, 'batch_size': 32	324780.00	400094.65
3	'num_units': 112, 'learning_rate': 0.002, 'batch_size': 16	334300.59	407467.09
4	'num_units': 66, 'learning_rate': 0.002, 'batch_size': 64	328117.81	406993.93
5	'num_units': 102, 'learning_rate': 0.098, 'batch_size': 128	353232.68	406910.28
6	'num_units': 105, 'learning_rate': 0.023, 'batch_size': 128	347876.28	405710.18
7	'num_units': 91, 'learning_rate': 0.182, 'batch_size': 128	25821628.0	25627272.0
8	'num_units': 83, 'learning_rate': 0.119, 'batch_size': 16	327924.59	404175.53
9	'num_units': 62, 'learning_rate': 0.005, 'batch_size': 128	330860.15	407470.37
10	'num_units': 123, 'learning_rate': 0.003, 'batch_size': 16	316498.43	404484.34

Tabel 10 Parameter Terbaik Model LSTM pada Provinsi Central Java-DIY

Trial	Parameter	loss	val_loss
1	'num_units': 118, 'learning_rate': 0.002, 'batch_size': 64	204213.15	202960.40
2	'num_units': 11, 'learning_rate': 0.006, 'batch_size': 64	197370.96	202710.76
3	'num_units': 93, 'learning_rate': 0.0035, 'batch_size': 64	217688.71	202731.92
4	'num_units': 28, 'learning_rate': 0.061, 'batch_size': 128	12247116.0	11958128.0
5	'num_units': 39, 'learning_rate': 0.005, 'batch_size': 128	202939.60	202675.92
6	'num_units': 64, 'learning_rate': 0.109, 'batch_size': 64	205685.04	203266.17
7	'num_units': 53, 'learning_rate': 0.003, 'batch_size': 128	200091.85	202879.57
8	'num_units': 46, 'learning_rate': 0.093, 'batch_size': 128	222446.95	202837.37
9	'num_units': 53, 'learning_rate': 0.144, 'batch_size': 64	215071.35	203465.60
10	'num_units': 75, 'learning_rate': 0.009, 'batch_size': 128	208156.89	203544.20

Tabel 10 Parameter Terbaik Model LSTM pada Provinsi East Java

Trial	Parameter	loss	val_loss
1	'num_units': 21, 'learning_rate': 0.022, 'batch_size': 16	311176.96	248568.45
2	'num_units': 95, 'learning_rate': 0.043, 'batch_size': 16	295937.03	250176.46
3	'num_units': 11, 'learning_rate': 0.136, 'batch_size': 32	364617.93	249659.45
4	'num_units': 16, 'learning_rate': 0.031, 'batch_size': 16	295151.34	249526.92
5	'num_units': 123, 'learning_rate': 0.013, 'batch_size': 128	293184.75	254652.34
6	'num_units': 97, 'learning_rate': 0.006, 'batch_size': 128	302668.06	250995.06
7	'num_units': 111, 'learning_rate': 0.002, 'batch_size': 64	299330.53	249952.82
8	'num_units': 84, 'learning_rate': 0.047, 'batch_size': 16	312059.28	248375.92

9	'num_units': 15, 'learning_rate': 0.036, 'batch_size': 64	294551.46	251886.20
10	'num_units': 101, 'learning_rate': 0.013, 'batch_size': 16	295725.90	249103.12

Lampiran 5 Tabel *Hyperparameter Tuning Model Transformer*

Tabel 10 Parameter Terbaik Model Transformer pada Provinsi Jakarta-Banten

Trial	Parameter	loss	val_loss
1	'num_layers': 4, 'd_model': 128, 'num_heads': 6, 'dff': 224, 'rate': 0.176, 'batch_size': 16	1571142.87	1166960.50
2	'num_layers': 4, 'd_model': 160, 'num_heads': 2, 'dff': 80, 'rate': 0.426, 'batch_size': 32	1587472.62	1201994.50
3	'num_layers': 3, 'd_model': 144, 'num_heads': 2, 'dff': 80, 'rate': 0.594, 'batch_size': 64	46036500.00	1302880.87
4	'num_layers': 5, 'd_model': 32, 'num_heads': 4, 'dff': 224, 'rate': 0.454, 'batch_size': 64	1747072.37	1178542.62
5	'num_layers': 2, 'd_model': 160, 'num_heads': 2, 'dff': 112, 'rate': 0.201, 'batch_size': 32	1564380.37	1163092.25
6	'num_layers': 3, 'd_model': 144, 'num_heads': 2, 'dff': 176, 'rate': 0.584, 'batch_size': 16	1573387.62	1331807.00
7	'num_layers': 4, 'd_model': 128, 'num_heads': 6, 'dff': 112, 'rate': 0.385, 'batch_size': 64	1589981.62	1233038.37
8	'num_layers': 3, 'd_model': 32, 'num_heads': 4, 'dff': 64, 'rate': 0.177, 'batch_size': 128	1910216.00	1155545.00
9	'num_layers': 5, 'd_model': 32, 'num_heads': 3, 'dff': 208, 'rate': 0.541, 'batch_size': 128	1561564.25	1167787.00
10	'num_layers': 2, 'd_model': 96, 'num_heads': 5, 'dff': 64, 'rate': 0.3012, 'batch_size': 64	1588804.12	1165623.00

Tabel 10 Parameter Terbaik Model Transformer pada Provinsi Jawa Barat

Trial	Parameter	loss	val_loss
1	'num_layers': 2, 'd_model': 224, 'num_heads': 2, 'dff': 192, 'rate': 0.428, 'batch_size': 128	368481.53	438080.81
2	'num_layers': 6, 'd_model': 64, 'num_heads': 6, 'dff': 224, 'rate': 0.190, 'batch_size': 16	373206.84	416614.28
3	'num_layers': 5, 'd_model': 80, 'num_heads': 2, 'dff': 128, 'rate': 0.424, 'batch_size': 32	9189773.0	449658.40
4	'num_layers': 5, 'd_model': 224, 'num_heads': 2, 'dff': 224, 'rate': 0.525, 'batch_size': 64	373143.31	521302.0
5	'num_layers': 2, 'd_model': 48, 'num_heads': 5, 'dff': 64, 'rate': 0.106, 'batch_size': 128	327756.43	409461.12
6	'num_layers': 4, 'd_model': 192, 'num_heads': 2, 'dff': 224, 'rate': 0.254, 'batch_size': 128	377355.25	436127.81
7	'num_layers': 1, 'd_model': 80, 'num_heads': 2, 'dff': 128, 'rate': 0.256, 'batch_size': 128	364450.87	430932.93
8	'num_layers': 6, 'd_model': 160, 'num_heads': 2, 'dff': 160, 'rate': 0.529, 'batch_size': 16	378036.56	467957.68
9	'num_layers': 3, 'd_model': 144, 'num_heads': 6, 'dff': 224, 'rate': 0.266, 'batch_size': 128	379623.06	435788.40
10	'num_layers': 1, 'd_model': 176, 'num_heads': 2, 'dff': 176, 'rate': 0.200, 'batch_size': 32	6956411.50	465753.90

Tabel 10 Parameter Terbaik Model Transformer pada Provinsi Central Java-DIY

Trial	Parameter	loss	val_loss
1	'num_layers': 5, 'd_model': 160, 'num_heads': 2, 'dff': 80, 'rate': 0.488, 'batch_size': 64	235374.28	305203.25
2	'num_layers': 5, 'd_model': 144, 'num_heads': 2, 'dff': 192, 'rate': 0.403, 'batch_size': 128	8766487.00	253449.15
3	'num_layers': 6, 'd_model': 176, 'num_heads': 2, 'dff': 224, 'rate': 0.545, 'batch_size': 32	232921.82	252012.76
4	'num_layers': 1, 'd_model': 144, 'num_heads': 6, 'dff': 192, 'rate': 0.232, 'batch_size': 16	195780.40	267111.71
5	'num_layers': 6, 'd_model': 224, 'num_heads': 2, 'dff': 112, 'rate': 0.486, 'batch_size': 128	7852071.50	450423.90
6	'num_layers': 4, 'd_model': 48, 'num_heads': 3, 'dff': 208, 'rate': 0.454, 'batch_size': 32	33109.84	233969.35
7	'num_layers': 5, 'd_model': 160, 'num_heads': 2, 'dff': 192, 'rate': 0.508, 'batch_size': 64	5877220.00	252935.70
8	'num_layers': 1, 'd_model': 64, 'num_heads': 2, 'dff': 112, 'rate': 0.283, 'batch_size': 64	193908.87	205004.00
9	'num_layers': 1, 'd_model': 160, 'num_heads': 2, 'dff': 192, 'rate': 0.395, 'batch_size': 16	233233.32	466525.65
10	'num_layers': 1, 'd_model': 160, 'num_heads': 2, 'dff': 144, 'rate': 0.381, 'batch_size': 64	194424.51	229176.75

Tabel 10 Parameter Terbaik Model Transformer pada Provinsi East Java

Trial	Parameter	loss	val_loss
1	'num_layers': 5, 'd_model': 32, 'num_heads': 2, 'dff': 208, 'rate': 0.466, 'batch_size': 128	326473.81	252358.18
2	'num_layers': 1, 'd_model': 144, 'num_heads': 2, 'dff': 96, 'rate': 0.141, 'batch_size': 32	7271350.50	249267.79
3	'num_layers': 1, 'd_model': 144, 'num_heads': 6, 'dff': 160, 'rate': 0.335, 'batch_size': 64	11319918.0	277166.15
4	'num_layers': 5, 'd_model': 192, 'num_heads': 2, 'dff': 144, 'rate': 0.358, 'batch_size': 16	336137.09	278279.03
5	'num_layers': 6, 'd_model': 32, 'num_heads': 4, 'dff': 224, 'rate': 0.229, 'batch_size': 64	17199964.0	260510.15
6	'num_layers': 1, 'd_model': 32, 'num_heads': 5, 'dff': 208, 'rate': 0.445, 'batch_size': 16	279423.37	256284.95
7	'num_layers': 6, 'd_model': 64, 'num_heads': 2, 'dff': 80, 'rate': 0.329, 'batch_size': 64	14363561.0 0	252933.71
8	'num_layers': 3, 'd_model': 160, 'num_heads': 2, 'dff': 160, 'rate': 0.1156, 'batch_size': 32	325748.37	255823.42
9	'num_layers': 3, 'd_model': 192, 'num_heads': 2, 'dff': 192, 'rate': 0.417, 'batch_size': 32	328781.84	275662.18
10	'num_layers': 6, 'd_model': 80, 'num_heads': 6, 'dff': 80, 'rate': 0.387, 'batch_size': 16	325590.09	264737.18


Lampiran 6 Analisa dan Evaluasi Hasil




Gambar Line chart *weekly electricity demand* in Jawa Tengah-DIY 2021

Gambar diatas merupakan *line chart weekly electricity demand* pada provinsi Jawa Tengah-DIY di tahun 2021. Berdasarkan gambar tersebut, *electricity demand* pada provinsi Jawa Tengah-DIY mengalami peningkatan *electricity demand* selama 2021. Dari Gambar diatas, dapat dilihat bahwa selama tahun 2021, *electricity demand* di Jawa Tengah-DIY mengalami penurunan/*bottom* pada tanggal 13-14 Mei 2021. Hal ini disebabkan karena pada bulan tersebut sedang terjadi libur idul fitri/lebaran. Hal tersebut, menyebabkan banyak perusahaan dan pabrik-pabrik yang berhenti beroperasi dan memproduksi, sehingga *electricity demand* di Jawa Tengah-DIY pada bulan Mei mengalami penurunan. Data tersebut juga didukung dengan Jumlah Pelanggan Listrik di Jawa Tengah-DIY pada tahun 2021, yang tidak mengalami penurunan yang signifikan. Berdasarkan Gambar dibawah ini, dapat dilihat bahwa Jumlah Pelanggan Listrik di Jawa Tengah-DIY pada Januari 2021 bernilai 6,01 juta pelanggan listrik, sedangkan di akhir tahun 2021 Jumlah Pelanggan Listrik di Jawa Tengah-DIY mencapai 6,23 juta pelanggan listrik. Hal ini berarti, Jumlah Pelanggan Listrik selama tahun 2021 meningkat sebesar 213.524 pelanggan listrik, atau meningkat sebesar 3.54% sepanjang tahun 2021.

Bar Chart Number Of Electricity Customer in Selected Province in Selected Year



Gambar Line chart *weekly* electricity demand in Jawa Tengah-DIY 2021




Gambar Line chart *weekly* electricity demand in Jawa Tengah-DIY 2022


Pada Gambar diatas dapat dilihat bahwa *electricity demand* di Jawa Tengah-DIY pada tahun 2022 tidak mengalami kenaikan yang cukup signifikan. Dari Gambar Line chart *weekly* electricity demand in Jawa Tengah-DIY 2021 dan Gambar diatas dapat dilihat juga bahwa ketika memasuki bulan Mei pada tahun 2021 dan 2022, selalu terjadi penurunan *electricity demand* di Jawa Tengah-DIY. Hal ini salah satunya disebabkan karena bulan Mei 2021 dan 2022 merupakan tanggal Hari Raya Idul Fitri, dimana banyak perkantoran, perusahaan, dan pabrik-pabrik yang berhenti beroperasi dan berproduksi, sehingga *electricity demand* di Jawa Tengah-DIY akan mengalami penurunan *electricity demand*. Oleh karena itu, ketika memasuki bulan Mei, *electricity demand* di Jawa Tengah-DIY selalu mengalami penurunan dibandingkan dengan bulan sebelumnya. *Electricity demand* di Jawa Tengah-DIY pada tahun 2022 tidak mengalami peningkatan yang cukup signifikan salah satunya disebabkan karena Total Penduduk Miskin di Jawa Tengah-DIY tidak mengalami penurunan yang cukup

signifikan/besar. Hal ini dapat dilihat pada Gambar dibawah ini, dimana Total Penduduk Miskin di Jawa Tengah-DIY per Januari 2022 mencapai 2,20 juta jiwa. Sedangkan Total Penduduk Miskin di Jawa Tengah-DIY per Desember 2022 mencapai 2,16 juta jiwa. Hal ini menunjukkan bahwa selama 2022, Total Penduduk Miskin di Jawa Tengah-DIY hanya berkurang sebesar 43.320 ribu jiwa.

Bar Chart Total Poor Population in Selected Province in Selected Year



Gambar Bar chart total poor population in Jawa Tengah-DIY 2022




Gambar Line chart Electricity Demand (Weekly) All Parameter in Jawa Tengah-DIY 2021-2025

Gambar diatas merupakan grafik *line chart(weekly)* dari prediksi *electricity demand* pada provinsi Jawa Tengah-DIY pada tahun 2021 hingga 2025 dengan menggunakan model *LSTM*

dan memakai seluruh data parameter pendukung. Garis berwarna merah merupakan grafik *actual* berdasarkan *data real electricity demand* di Jawa Tengah-DIY pada tahun 2021 hingga 2023. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan. Sedangkan grafik garis hitam merupakan prediksi dari *electricity demand* di Jawa Tengah-DIY pada tahun 2024-2025 dalam frekuensi *weekly*. Data pendukung lainnya seperti Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain.


Pada Gambar diatas dapat dilihat juga bahwa *electricity demand* mengalami penurunan pada setiap memasuki bulan Mei setiap tahunnya. Hal ini diakibatkan karena pada bulan tersebut memasuki, masa libur idul fitri atau lebaran, sehingga banyak pabrik, perusahaan dan perkantoran di Jawa Tengah-DIY yang berhenti beroperasi dan berproduksi yang mengakibatkan *electricity demand* di Jawa Tengah-DIY mengalami penurunan. Berdasarkan Gambar diatas, *electricity demand* berada pada *peaknya* setiap memasuki bulan Oktober-awal November setiap tahunnya. Berdasarkan Gambar diatas, hasil prediksi *electricity demand* untuk tahun 2024-2025 tidak terlalu baik hasilnya, karena grafik prediksi *electricity demand* di Jawa Tengah-DIY untuk tahun 2024-2025 dengan model LSTM, grafiknya cenderung tidak seperti pola pada data aktual tahun 2021-2023. Sehingga model LSTM tidak dapat menangkap pola *electricity demand* pada data aktual. Berdasarkan matrix evaluation table pada Gambar diatas juga menunjukkan bahwa nilai *R-Squared* pada LSTM di Jawa Tengah-DIY hanya mencapai 0.12. Hal ini berarti bahwa prediksi *electricity demand* pada tahun 2024-2025, hanya dapat menjelaskan sekitar 12% variansi data dari nilai aktual/historis *electricity demand* yang sebenarnya.



Gambar Line chart Electricity Demand (Weekly) Top 5 Parameter in Jawa Tengah-DIY 2021-2025

Gambar diatas merupakan grafik *line chart(weekly)* dari prediksi *electricity demand* pada provinsi Jawa Tengah-DIY pada tahun 2021 hingga 2025 dengan menggunakan model *LSTM* dan hanya menggunakan Top 5 parameter data pendukung yang memiliki *correlation matrix* tertinggi. Parameter data pendukung lainnya meliputi Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain. Garis berwarna merah merupakan grafik *actual* berdasarkan *data real electricity demand* di Jawa Tengah-DIY pada tahun 2021 hingga 2023. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan. Sedangkan grafik garis hitam merupakan prediksi dari *electricity demand* di Jawa Tengah-DIY pada tahun 2024 hingga 2025 dalam frekuensi *weekly*.

Pada Gambar diatas dapat dilihat juga bahwa *electricity demand* mengalami penurunan pada setiap memasuki bulan Mei setiap tahunnya. Hal ini diakibatkan karena pada bulan tersebut memasuki, masa libur idul fitri atau lebaran, sehingga banyak pabrik, perusahaan dan perkantoran di Jawa Tengah-DIY yang berhenti beroperasi dan memproduksi yang mengakibatkan *electricity demand* di Jawa Tengah-DIY mengalami penurunan. Berdasarkan Gambar diatas, *electricity demand* berada pada *peaknya* setiap memasuki bulan Oktober-awal November setiap tahunnya. Berdasarkan Gambar diatas, hasil prediksi *electricity demand* untuk tahun 2024-2025 sangat buruk hasilnya, karena grafik prediksi *electricity demand* di Jawa Tengah-DIY untuk tahun 2024-2025 dengan model *LSTM*, grafiknya sangat berbeda pola/*pattern* dibandingkan dengan data aktual tahun 2021-2023. Sehingga model *LSTM* tidak dapat menangkap pola *electricity demand* pada data aktual. Berdasarkan *matrix evaluation table* pada Gambar diatas juga menunjukkan bahwa nilai *R-Squared* pada *LSTM* di Jawa Tengah-DIY hanya mencapai 0.12. Hal ini berarti bahwa prediksi *electricity demand* pada tahun 2024-2025, hanya dapat menjelaskan sekitar 12% variansi data dari nilai aktual/historis *electricity demand* yang sebenarnya.




Gambar Line chart *weekly electricity demand* in Jawa Timur 2021


Gambar diatas merupakan *line chart weekly electricity demand* pada provinsi Jawa Timur di tahun 2021. Berdasarkan gambar tersebut, *electricity demand* pada provinsi Jawa Timur mengalami peningkatan dalam frekuensi *weekly* selama 2021. Hal tersebut, disebabkan salah satunya karena pada tahun 2021 terjadi peningkatan aktivitas dan kegiatan ekonomi pasca pandemi Covid-19 yang terjadi di seluruh dunia pada tahun 2020. Pada tahun 2021, banyak perkantoran dan pabrik-pabrik di Jawa Timur yang mulai recovery dan kembali beroperasi dan memproduksi, sehingga menyebabkan konsumsi energi listrik di Jawa Timur meningkat pasca pandemi Covid-19. Karena pabrik-pabrik dan perkantoran membutuhkan *demand* energi listrik yang cukup besar dalam operasional dan produksinya. Hal ini di dukung juga dengan data Listrik Terjual di Jawa Timur pada tahun 2021 yang mengalami kenaikan.

Data tersebut mendukung peningkatan *electricity demand* di Jawa Timur karena semakin tinggi Listrik Terjual maka akan menyebabkan nilai *electricity demand* pada provinsi tersebut akan meningkat. Karena listrik yang terjual pada provinsi tersebut akan dikonsumsi atau dipakai oleh masyarakat/konsumen pada provinsi tersebut. Berdasarkan Gambar dibawah ini, Listrik Terjual di Jawa Timur per Januari 2021 mencapai 37,61 juta MW. Kemudian per akhir Desember 2021, Listrik Terjual di Jawa Timur mencapai 39,45 juta MW. Hal ini menandakan terjadi peningkatan sebesar 1.84 juta MW Listrik Terjual pada Jawa Timur di tahun 2021.

Bar Chart Electricity Sold in Selected Province in Selected Year



Gambar Bar chart Electricity Sold in Jawa Timur 2021




Gambar Line chart *weekly* electricity demand in Jawa Timur 2022

Gambar diatas merupakan *line chart weekly electricity demand* pada provinsi Jawa Timur di tahun 2022. Berdasarkan gambar tersebut, *electricity demand* pada provinsi Jawa Timur mengalami peningkatan dalam frekuensi *weekly* selama 2022. Hal ini di dukung juga dengan data Jumlah Pelanggan Listrik di Jawa Timur pada tahun 2022 yang mengalami kenaikan (Gambar dibawah ini).


Data tersebut mendukung peningkatan *electricity demand* di Jawa Timur karena semakin banyak Jumlah Pelanggan Listrik maka akan menyebabkan nilai *electricity demand* pada provinsi tersebut akan meningkat. Karena Jumlah Pelanggan Listrik yang tinggi pada provinsi tersebut akan menyebabkan konsumsi listrik pada provinsi Jawa Timur akan meningkat. Berdasarkan Gambar dibawah ini, Jumlah Pelanggan Listrik di Jawa Timur per Januari 2022 mencapai 12,86 juta pelanggan listrik. Kemudian per akhir Desember 2022, Jumlah Pelanggan Listrik di Jawa Timur mencapai 13,27 juta pelanggan listrik. Hal ini

menandakan terjadi peningkatan sebesar 410.349 ribu pelanggan listrik pada Jawa Timur di tahun 2022.

Bar Chart Number Of Electricity Customer in Selected Province in Selected Year



Gambar Bar chart Jumlah Pelanggan Listrik in Jawa Timur 2022




Gambar Line chart Electricity Demand (Weekly) All Parameter in Jawa Timur 2021-2023

Gambar diatas merupakan grafik *line chart(weekly)* dari prediksi *electricity demand* pada provinsi Jawa Timur pada tahun 2021 hingga 2023 dengan menggunakan model *LSTM* dan memakai seluruh parameter data pendukung. Data pendukung lainnya seperti Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain. Garis berwarna merah merupakan grafik *actual* berdasarkan *data real electricity demand* di Jawa Timur pada tahun 2021 hingga 2022. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan. Sedangkan grafik garis hitam

merupakan prediksi dari *electricity demand* di Jawa Timur pada tahun 2023 dalam frekuensi *weekly*.

Berdasarkan Gambar diatas dapat dilihat juga bahwa *electricity demand* mengalami penurunan/*bottom* pada bulan Mei pada tahun 2021 dan tahun 2022. Hal ini disebabkan karena, pada Mei 2021 dan Mei 2022 sedang terjadi libur idul fitri/lebaran, yang menyebabkan banyak pabrik, perkantoran, dan perusahaan yang berhenti beroperasi dan berproduksi. Sehingga *electricity demand* di provinsi Jawa Timur pada Mei 2021 dan Mei 2022 mengalami penurunan. Sedangkan Grafik *line chart* pada Gambar diatas mengalami peningkatan pada bulan Oktober 2021 dan Oktober 2022. Hal ini terjadi karena, pada bulan Oktober sudah memasuki musim kemarau/panas. Sehingga, masyarakat banyak yang menggunakan peralatan elektronik seperti AC dan Kipas angin yang dapat meningkatkan *electricity demand* di Jawa Timur.



Gambar Line chart Electricity Demand (Weekly) All Parameter in Jawa Timur 2021-2023

Gambar diatas merupakan grafik *line chart(weekly)* dari prediksi *electricity demand* pada provinsi Jawa Timur pada tahun 2021 hingga 2023 dengan menggunakan model *LSTM* dan hanya memakai 5 parameter data pendukung yang memiliki *correlation matrix* tertinggi berdasarkan pada pengujian model. Parameter data pendukung lainnya meliputi Data Jumlah Penduduk, Data Pelanggan Listrik, Data PDRB, Data Jumlah Penduduk Miskin, dan lain-lain. Garis berwarna merah merupakan grafik *actual* berdasarkan *data real electricity demand* di Jawa Timur pada tahun 2021 hingga 2022. Sedangkan garis berwarna biru merupakan grafik *data modelled train data* berdasarkan *data historical* beserta data-data pendukung lain, dalam memprediksi *electricity demand* di masa depan. Sedangkan grafik

garis hitam merupakan prediksi dari *electricity demand* di Jawa Timur pada tahun 2023 dalam frekuensi *weekly*.

Grafik pada Gambar diatas memiliki pola *chart* yang sama seperti grafik *line chart* pada Gambar *Line chart Electricity Demand (Weekly) All Parameter* in Jawa Timur 2021-2023, hanya saja parameter yang digunakan untuk *training model* dan prediksi *electricity demand* berbeda jumlahnya. Pada Gambar diatas dapat dilihat juga bahwa *electricity demand* mengalami penurunan/*bottom* pada bulan Mei pada tahun 2021 dan tahun 2022. Hal ini disebabkan karena, pada Mei 2021 dan Mei 2022 sedang terjadi libur idul fitri/lebaran, yang menyebabkan banyak pabrik, perkantoran, dan perusahaan yang berhenti beroperasi dan memproduksi. Sehingga *electricity demand* di provinsi Jawa Timur pada Mei 2021 dan Mei 2022 mengalami penurunan. Sedangkan Grafik *line chart* pada Gambar diatas mengalami peningkatan pada bulan Oktober 2021 dan Oktober 2022. Hal ini terjadi karena, pada bulan Oktober sudah memasuki musim kemarau/panas. Sehingga, masyarakat banyak yang menggunakan peralatan elektronik seperti AC dan Kipas angin yang dapat meningkatkan *electricity demand* di Jawa Timur. Berdasarkan matrix evaluation table pada Gambar diatas, dapat dilihat bahwa *error metric* pada model LSTM di Jawa Timur cukup buruk, karena hasil *R-Squared* nya bernilai negatif. Hal ini berarti bahwa model tidak mampu memprediksi *electricity demand* di masa depan, berdasarkan data aktual *electricity demand* pada tahun 2021-2022.